Analisis Perilaku Pengunjung Toko Retail dengan Computer Vision dan Multimodal Transformer Terintegrasi untuk Optimalisasi Strategi Bisnis

Pradana Yahya Abdillah
Universitas Gadjah Mada
yahyaabdillah98@gmail.com

Lisa Olivia Putri Maharani
Universitas Gadjah Mada
lisaolivia130@gmail.com

Muhammad Zufar Syaafi'
Universitas Gadjah Mada
zufar.syaafie@gmail.com

Abstract

Perumusan strategi bisnis di sektor retail membutuhkan analisis data yang tepat dan relevan dengan kondisi nyata toko, salah satunya melalui pemahaman terhadap pola perilaku pengunjung di dalam toko tersebut. Hal tersebut mendukung inovasi untuk mengembangkan sistem analitik berbasis *Artificial Intelligence* yang terintegrasi dengan *computer vision* dan *multimodal transformer*. Sistem dirancang dengan memanfaatkan deteksi objek dan segmentasi menggunakan YOLO, pelacakan individu dengan ByteTrack, analisis kepadatan dan *dwell-time*, serta klasifikasi aksi melalui TimeSFormer yang telah dilatih untuk domain rekaman CCTV retail. *Pipeline* dari sistem dirancang untuk memproses data visual menjadi *heatmap* pergerakan pengunjung, statistik interaksi terhadap rak, dan *insight* yang dapat ditindaklanjuti untuk mendukung pengambilan keputusan berbasis data. Hasil evaluasi menunjukkan bahwa *finetuning* YOLOv11-seg mencapai *precision* sebesar 94,73% dan *recall* 73,37% dalam segmentasi rak, sedangkan *finetuning* TimeSFormer mencapai akurasi 75,0% pada klasifikasi aksi pengunjung. Sistem berhasil mengidentifikasi perilaku konsumen dan memberikan rekomendasi strategis berbasis analisis *traffic*, *engagement*, dan kualitas interaksi, menunjukkan potensi besar penerapan AI dalam meningkatkan efektivitas tata letak toko dan konversi penjualan di lingkungan retail.

1 Pendahuluan

1.1 Latar Belakang

Dalam era retail modern, optimalisasi tata letak produk dan peningkatan efektivitas penjualan menjadi kunci utama dalam strategi operasional toko. Salah satu pendekatan strategis untuk mencapai hal ini adalah dengan memanfaatkan data pengamatan langsung terhadap perilaku pengunjung. CCTV yang tersebar di berbagai sudut toko menyimpan potensi besar sebagai sumber informasi visual mengenai alur pergerakan pelanggan, pola interaksi terhadap rak, hingga intensitas kunjungan ke area tertentu.

Namun, pemanfaatan data visual dari CCTV secara manual bersifat tidak efisien, memakan waktu, dan rawan bias. Selain itu, mayoritas video pengamatan toko memiliki sudut pandang *oblique* (samping–atas), berbeda dari mayoritas *dataset* pelatihan yang menggunakan sudut *top-down*. Hal ini menimbulkan tantangan dalam hal *domain shift* yang berdampak pada performa model [1]. Oleh

karena itu, diperlukan pendekatan berbasis visi komputer dan *multimodal transformer* yang mampu secara otomatis memahami dan menganalisis perilaku pengunjung dari rekaman video CCTV untuk mendukung pengambilan keputusan yang berbasis data.

Solusi ini mengembangkan sebuah *pipeline* analisis perilaku terintegrasi yang menggabungkan beberapa komponen utama, yaitu segmentasi rak, pelacakan individu, analisis kepadatan pengunjung dan *dwell-time*, serta klasifikasi aksi menggunakan TimeSFormer. Sistem ini memungkinkan untuk melakukan visualisasi *heat-map* dan statistik interaksi per rak, serta mampu memberikan *insight* yang dapat langsung digunakan untuk menyarankan optimasi tata letak toko dan strategi promosi produk.

1.2 Manfaat dan Kontribusi

Secara praktis, solusi ini ditujukan untuk pemilik toko, manajer operasional, dan pelaku bisnis retail dalam mengoptimalkan tata letak dan peningkatan konversi penjualan berdasarkan pemahaman perilaku aktual pelanggan. Sistem ini memungkinkan mendukung penyusunan ulang rak secara objektif dengan didasarkan pada data kepadatan, durasi interaksi, dan jenis aksi yang dilakukan di setiap rak.

Secara akademis, solusi ini berkontribusi dalam eksplorasi gabungan antara teknik visi komputer, *object tracking*, *video transformer* (TimeSFormer), dan integrasi analitik perilaku dalam konteks *retail intelligence*. Solusi ini juga mengeksplorasi bagaimana *domain adaptation* dapat meningkatkan kinerja model ketika berpindah dari *dataset training* ke data *real-world* CCTV toko. Eksperimen dan evaluasi dilakukan secara menyeluruh untuk menunjukkan efektivitas pendekatan *end-to-end* yang diusulkan.

1.3 Batasan

Beberapa batasan yang perlu dicatat dalam studi ini:

1. Data rekaman CCTV merupakan data yang *privacy sensitive*, sehingga evaluasi sistem dilakukan pada data rekaman CCTV terbatas yang ditemukan di internet dari satu lokasi toko retail tertentu.
2. Label aksi yang digunakan terbatas pada enam kelas utama dari MERL Dataset, yaitu *Reach to Shelf*, *Retract from Shelf*, *Hand in Shelf*, *Inspect Product*, *Inspect Shelf*, dan *Background*.
3. *Heat-map* dan *dwell-time* dihitung berdasarkan ID *bounding-box* dan belum mempertimbangkan estimasi kerumunan secara agregat multi-kamera.

2 Kajian Teori

2.1 Instance Segmentation

Instance segmentation merupakan salah satu tugas penting dalam visi komputer yang bertujuan untuk mengidentifikasi dan memisahkan setiap objek individual dalam sebuah gambar secara *pixel-wise*. Berbeda dengan *semantic segmentation* yang hanya memberikan label kelas untuk setiap piksel tanpa membedakan antar objek yang berbeda dalam kelas yang sama, *instance segmentation* menghasilkan mask unik untuk masing-masing *instance* objek [2].

Pendekatan klasik dalam *instance segmentation* umumnya mengadopsi pipeline dua tahap (*two-stage pipeline*). Pada tahap pertama, dilakukan deteksi objek untuk menentukan *bounding box* yang mengelilingi setiap objek, misalnya dengan menggunakan metode *region proposal.* Pada tahap kedua, dilakukan prediksi mask piksel di dalam area yang terdeteksi tersebut, seperti yang diterapkan dalam Mask R-CNN [2]. Meskipun metode dua tahap ini menghasilkan akurasi yang tinggi, namun prosesnya cenderung lambat karena melibatkan pemisahan deteksi dan segmentasi.

Sebagai alternatif, beberapa penelitian memperkenalkan pendekatan satu tahap (*one-stage pipeline*) yang mengintegrasikan deteksi dan segmentasi ke dalam satu proses *end-to-end*, sehingga meningkatkan efisiensi dan memungkinkan aplikasi secara *real-time* [3]. Pendekatan ini secara langsung memprediksi mask instance bersamaan dengan kelas dan lokasi objek, tanpa memerlukan tahap proposal wilayah terlebih dahulu.

2.2 Multi-object Tracking

Multi-object Tracking (MOT) adalah salah satu bidang dalam visi komputer yang bertujuan untuk mengidentifikasi serta melacak posisi objek bergerak dalam data video secara kontinu. MOT bekerja dengan mempertahankan identitas unik tiap objek walaupun menghadapi gangguan-gangguan. Secara umum, MOT terbagi dalam dua pendekatan utama, yaitu *tracking-by-detection* dan *joint detection and tracking*. Pada metode pertama, objek akan dideteksi pada setiap frame menggunakan detektor seperti Faster R-CNN atau YOLO, lalu hasil deteksi tersebut dikaitkan antar frame untuk membentuk lintasan menggunakan Filter Kalman dan algoritma Hungarian [4]. Di sisi lain, pendekatan joint detection and tracking menggabungkan deteksi dan pelacakan secara bersamaan dalam satu kerangka kerja *end-to-end*.

Dalam konteks *tracking-by-detection*, YOLO (You Only Look Once) merupakan salah satu detektor yang paling banyak digunakan karena kecepatan dan efisiensinya. YOLO adalah *one-stage detector* yang secara langsung memprediksi posisi *bounding box* dan kelas objek dalam satu tahap jaringan saraf, tanpa memerlukan tahap proposal wilayah seperti pada pendekatan dua tahap [5]. Hal ini memungkinkan YOLO untuk mencapai deteksi objek secara *real-time* sehingga sering digunakan bersama algoritma pelacakan seperti SORT atau DeepSORT untuk membangun sistem pelacakan multi-objek.

2.3 Heat-map & Dwell-time

Heat-map dan dwell-time merupakan dua teknik fundamental untuk memahami pola pergerakan manusia di dalam suatu ruang. Heat-map digunakan untuk memvisualisasikan konsentrasi keramaian dengan mengakumulasi lokasi orang selama periode waktu tertentu. Salah satu metode umum yang digunakan untuk membangun heat-map adalah *Kernel Density Estimation* (KDE), yang menghitung distribusi spasial dari jejak posisi orang dalam area pengamatan [6]. Dalam konteks video *surveillance* dan *retail analytics*, data posisi orang diperoleh dari hasil deteksi dan pelacakan objek. Heat-map ini memberikan gambaran zona-zona dengan kepadatan pengunjung yang tinggi maupun rendah sehingga membantu analisis perancangan tata ruang atau pengelolaan keramaian.

Sementara itu, dwell-time adalah metrik perilaku penting dalam lingkungan retail fisik yang mengukur berapa lama seseorang berada di area tertentu seperti rak, lorong, atau area promosi. Dalam penelitian ini, dwell-time dihitung dengan mencatat durasi kehadiran masing-masing ID hasil tracking di dalam sebuah poligon yang merepresentasikan area rak atau zona analisis. Penggunaan metrik ini dapat menunjukkan tingkat ketertarikan pengunjung terhadap area tertentu, serta menjadi tolok ukur efektivitas penataan ruang dan promosi produk.

2.4 Action Detection dengan TimeSFormer

TimeSFormer adalah arsitektur video classification tanpa konvolusi (convolution-free), yang hanya menggunakan mekanisme *self-attention* untuk memahami hubungan spasial dan temporal dalam video [7]. Model ini merupakan perluasan dari Vision Transformer (ViT), yang awalnya dirancang untuk gambar statis, ke domain video dengan memandang video sebagai urutan patch dari frame individu. Setiap patch (ukuran 16×16 piksel) diproyeksikan menjadi vektor embedding, diberi posisi temporal, lalu diproses sebagai token oleh Transformer encoder.

Salah satu inovasi utama dari TimeSFormer adalah skema *divided attention*, di mana perhatian temporal dan perhatian spasial dipisahkan dan diterapkan secara terpisah dalam setiap blok. Hal ini berbeda dengan desain standar Transformer yang menggabungkan keduanya dalam satu operasi, dan terbukti memberikan akurasi terbaik untuk klasifikasi aksi dibandingkan desain lain yang diuji dalam studi tersebut. Hal ini berbeda dengan pendekatan terdahulu oleh Singh et al. [9] yang menggunakan multi-stream CNN dan LSTM dua arah (MSB-RNN) dengan person-centric bounding box sebagai input utama model, pendekatan kami menggunakan TimeSFormer sebagai model transformer murni berbasis full-frame. Bounding box hanya digunakan pada tahap inferensi untuk tracking ID dan pemotongan klip aksi, bukan sebagai input eksplisit selama pelatihan model.

TimeSFormer dilatih awal pada dataset berskala besar seperti Kinetics-400 dan Kinetics-600, dan menunjukkan performa setara atau lebih baik dari model CNN 3D seperti I3D dan SlowFast, terutama dalam efisiensi inferensi dan kemampuan menangani video berdurasi panjang. Dalam penelitian ini, model TimeSFormer `base` digunakan sebagai inti model untuk klasifikasi aksi pen-

gunjung toko, dengan pendekatan fine-tuning pada MERL Dataset (perspektif top-down) dan domain adaptation ke video CCTV-like. Dengan kemampuannya menangkap konteks aksi dalam jangkauan temporal yang luas, TimeSFormer sangat relevan untuk memahami perilaku kompleks di lingkungan retail.

2.5 Domain Adaptation

Model TimeSFormer yang awalnya dilatih menggunakan MERL Shopping Dataset (dengan perspektif top-down) diadaptasi ke domain video dengan kamera menyerupai CCTV toko nyata yang memiliki sudut pandang yang lebih relevan untuk CCTV retail. Mengingat jumlah video target yang terbatas (sekitar 50 klip), pendekatan fine-tuning yang efisien diperlukan untuk meminimalkan overfitting. Untuk itu, digunakan strategi source-free domain adaptation yang tidak memerlukan akses ke data domain sumber saat pelatihan ulang [8]. Fine-tuning dilakukan dengan menggunakan bobot kelas (class-weighted loss) untuk menangani ketidakseimbangan distribusi aksi, serta diterapkan `EarlyStoppingCallback` untuk mencegah overfitting lebih lanjut.

3 Solusi Usulan

Solusi yang dikembangkan merupakan sistem analitik berbasis AI model untuk mendapatkan *actionable business insight* dari rekaman CCTV retail dengan integrasi teknologi *Computer Vision* dan *Action Recognition*. Pipeline sistem dirancang untuk melakukan deteksi, pelacakan, segmentasi, dan klasifikasi perilaku pelanggan dalam konteks spasial dan temporal. Pendekatan ini memberikan *insight* pada manajemen toko dalam membuat keputusan berbasis data, seperti pengaturan tata letak rak, estimasi waktu pelanggan, optimalisasi display produk, dan navigasi pola belanja pelanggan.

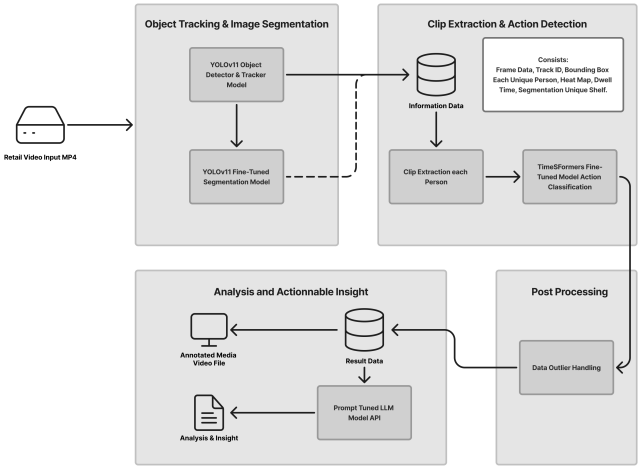


Figure 1: Arsitektur *pipeline* sistem solusi.

3.1 Shelf Segmentation

Shelf segmentation bertujuan untuk mendeteksi dan memetakan setiap rak display retail dari rekaman CCTV. Pendekatan ini mengintegrasikan model YOLOv11-seg yang dilengkapi segmentation head untuk deteksi dan masking object hingga tingkat piksel. Model dilatih lagi dari data images yang telah dikumpulkan dan dianotasi untuk dapat mendeteksi rak dari berbagai sudut pandang secara presisi. Keluaran dari tahap ini berupa area segmentasi dan unique ID untuk setiap rak yang terdeteksi.

3.2 People Detection, Counting, Tracking

Tahap ini merupakan inti dari pipeline analisis perilaku, di mana solusi ini mengadopsi pendekatan *tracking-by-detection* yang efisien untuk mengidentifikasi, melacak, dan menghitung pergerakan pengunjung secara individual dari rekaman CCTV. Proses dimulai dengan model deteksi objek YOLO yang telah dilatih sebelumnya (*pre-trained*), yang memproses setiap *frame* video untuk mendeteksi semua objek yang termasuk dalam kelas *person*. Hasil dari deteksi ini, berupa *bounding box* untuk setiap orang, kemudian diteruskan ke algoritma pelacakan ByteTrack. Algoritma ini bertugas untuk menghubungkan deteksi orang yang sama di antara frame-frame yang berurutan dan memberikan sebuah ID pelacakan yang unik serta konsisten untuk setiap individu.

Dengan adanya ID unik yang terlacak secara konsisten, proses penghitungan pengunjung menjadi akurat dan informatif. Jumlah total pengunjung unik selama periode observasi dapat ditentukan dengan menghitung total ID unik yang telah dihasilkan. Selain itu, sistem juga mampu menyediakan data jumlah orang secara *real-time* per frame, yang sangat berguna untuk menganalisis tingkat kepadatan dan keramaian toko pada waktu-waktu tertentu.

3.3 Heat-map & Dwell-time Analytics

Setelah setiap pengunjung terdeteksi dan mendapatkan ID unik melalui proses pelacakan, sistem secara otomatis mengolah data posisi mereka untuk menghasilkan dua metrik analisis utama, yaitu *heat-map* dan *dwell-time*.

Untuk mendapatkan *heat-map*, sistem mengagregasi seluruh koordinat posisi pengunjung dari setiap *frame* video untuk membangun sebuah *heat-map* visual. Visualisasi ini secara intuitif menunjukkan ”hotspot” atau zona dengan konsentrasi pengunjung tertinggi dan ”coldspot” atau area yang jarang dikunjungi. Ini membantu manajemen toko untuk secara cepat mengidentifikasi area yang paling banyak menarik lalu lintas pelanggan, yang sangat berguna untuk penempatan produk unggulan atau materi promosi.

Selanjutnya, dengan memanfaatkan ID pelacakan yang konsisten, sistem menghitung *dwell-time* misalnya di depan sebuah rak spesifik. Metrik ini berfungsi sebagai indikator tingkat ketertarikan atau engagement pelanggan. *Dwell-time* yang tinggi dapat menandakan ketertarikan mendalam terhadap produk di rak tersebut, sementara *dwell-time* yang rendah di area dengan traffic tinggi bisa mengindikasikan bahwa area tersebut hanya dilewati tanpa menarik perhatian.

3.4 Action Detection dengan TimeSFormer

Untuk mengenali aksi pengunjung seperti *reach*, *inspect*, atau *retract*, digunakan arsitektur TimeSFormer [7] yang dibangun sepenuhnya di atas mekanisme *self-attention* spasial-temporal tanpa konvolusi. TimeSFormer mampu menangkap dependensi jangka panjang dalam video dan telah terbukti efektif pada benchmark aksi berskala besar seperti Kinetics-400. Adapun proses yang dilakukan adalah sebagai berikut.

a) Pre-training: Model diinisialisasi dari `facebook/timesformer-base-k400` yang telah dilatih pada dataset Kinetics-400. Ini memberikan pemahaman awal tentang aksi manusia secara umum.

b) Fine-tuning: Model dilatih ulang pada MERL Shopping Dataset yang terdiri dari 5.648 klip aksi pengunjung toko (kamera top-down). Proses dilakukan selama 5 epoch dengan batch size 2. Karena label aksi tidak seimbang, digunakan perhitungan bobot kelas untuk memperbaiki kontribusi tiap kelas pada loss.

c) Domain Adaptation: Untuk mengatasi perbedaan domain antara data top-down dan CCTV toko (kamera miring), dilakukan fine-tuning lebih lanjut menggunakan 50 video CCTV-like berlabel aksi. Diterapkan learning rate rendah (1×10^{-5}) dan `EarlyStopping`, dengan model terbaik pada epoch ke-12 dari total 15.

Prediksi aksi dilakukan pada klip video berdurasi 20 detik, diperoleh dari hasil pelacakan ID pengunjung. Setiap prediksi dikaitkan dengan posisi rak terdekat menggunakan bounding-box overlap, sehingga memungkinkan analisis perilaku per rak yang presisi dan berbasis data.

4 Hasil Eksperimen dan Pengujian

4.1 Shelf Segmentation

Langkah finetuning dan training Model YOLOv11-seg bertujuan untuk meningkatkan akurasi deteksi dan segmentasi pada rak barang di domain retail dengan menggunakan dataset Shelf Segmentation. Dataset ini terdiri dari 428 gambar dari berbagai sudut pandang beserta anotasinya dengan area masking. Telah dilakukan pula data splitting dan data augmentation seperti flip, crop, rotation, shear, hue, saturation, brightness, exposure, blue, hingga noise sebagai optimalisasi performa model dalam data variatif.

Model dilatih menggunakan arsitektur YOLOv11 versi small selama maksimal 100 epoch menggunakan konfigurasi batch size 8, ukuran input 640, dan device GPU (CUDA 0) dengan framework Ultralytics. Mekanisme EarlyStopping juga diterapkan untuk efisiensi training dan menghindari overfitting. Model terbaik disimpan saat epoch ke-39, ketika tidak ada peningkatan metrik selama 30 epoch berturut-turut. Evaluasi model kemudian dilakukan pada 18 gambar validasi yang mengandung 49 instance rak.

Table 1: Evaluasi validasi YOLOv11s-seg

Metrik	**Nilai**
Precision (mean)	0.9473
Recall (mean)	0.7337
F1-Score (mean)	0.8268
mAP@0.5 (mask)	0.8332
mAP@0.5:0.95 (mask)	0.5663

Model menunjukkan kemampuan generalisasi yang baik terhadap variasi visual, meskipun pelatihan dilakukan dengan dataset berukuran relatif kecil. Kontribusi augmentasi data terhadap robustness model terlihat signifikan, terutama dalam menghadapi noise pencahayaan dan variasi sudut pengambilan gambar. Selain evaluasi numerik, inferensi visual menunjukkan bahwa segmentasi mask mampu mengikuti bentuk rak dengan baik, bahkan dalam skenario kompleks seperti tumpang tindih objek.



Figure 2: Hasil inference model segmentasi.

4.2 Action Detection

Model TimeSFormer kami diuji dalam dua skenario utama: (1) domain top-down menggunakan MERL Shopping Dataset dan (2) domain nyata berupa video CCTV toko dengan kamera oblique. Untuk skenario pertama, model dilatih menggunakan 5.648 klip aksi dari MERL Shopping Dataset [9], dengan konfigurasi frozen backbone, batch size kecil (2), dan fine-tuning selama 5 epoch. Evaluasi pada validation set menghasilkan akurasi mencapai $\sim 67-70\%$, sedangkan akurasi pada test set mencapai **59.1%**. Ini dapat dianggap cukup baik mengingat pendekatan kami hanya menggunakan satu stream full-frame, tanpa pelacakan aktor atau optical flow seperti pada baseline MSB-RNN [9] yang mencapai mAP 80.31%.

Pada skenario kedua, dilakukan domain adaptation terhadap data CCTV-like yang direkam sendiri dengan keterbatasan jumlah yang jauh lebih sedikit. Dataset ini terdiri dari 50 video aksi dengan

sudut kamera oblique, pencahayaan terang, serta noise dan tata letak yang mirip dengan toko retail. Fine-tuning dilakukan dari model hasil pelatihan MERL dengan konfigurasi learning rate rendah (1×10^{-5}), class weighting untuk mengatasi imbalance, serta `EarlyStopping` untuk mencegah overfitting. Evaluasi pada data CCTV-like menunjukkan peningkatan performa yang signifikan, dengan akurasi prediksi mencapai **75.0%**. Hal ini menandakan bahwa meskipun terdapat domain shift antara data pelatihan dan aplikasi nyata, model tetap dapat beradaptasi secara efektif.

Untuk integrasi end-to-end dalam pipeline perilaku, aksi diprediksi pada potongan video sepanjang 250-300 frame yang diekstrak berdasarkan ID pelacakan dari ByteTrack. Bounding box dari pelacakan digunakan hanya saat inferensi, untuk mengisolasi masing-masing individu. Prediksi aksi tersebut kemudian dikaitkan ke posisi rak menggunakan overlap spasial antar bounding box dan segmentasi rak.

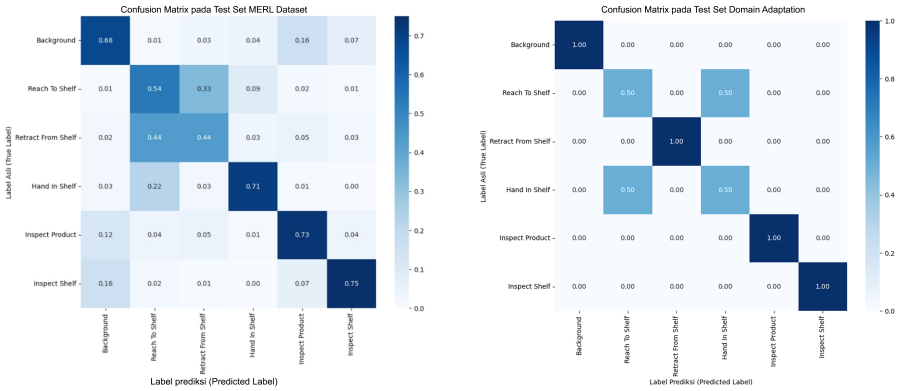


Figure 3: Perbandingan confusion matrix TimeSFormer MERL-CCTV.

Berdasarkan Gambar 3, terlihat bahwa pada test set MERL Shopping Dataset, model mengalami sedikit kebingungan membedakan antara aksi *Reach to Shelf* dan *Retract from Shelf*. Hal ini dapat dimaklumi karena aksi-aksi pada dataset MERL dengan posisi kamera top-down tersebut melibatkan gerakan tangan yang serupa dengan arah berlawanan atau target yang berdekatan, dan semuanya dilakukan dalam konteks posisi berdiri di depan rak.

Sementara itu, pada hasil domain adaptation terhadap dataset pribadi CCTV-like dengan jumlah jauh lebih sedikit, confusion matrix menunjukkan bahwa model jauh lebih yakin terhadap aksi-aksi utama seperti *Inspect Shelf* dan *Inspect Product* (angka akurasi yang tinggi juga dipengaruhi oleh banyaknya dataset), namun tetap menunjukkan kebingungan pada kasus *Reach to Shelf* yang kadang diklasifikasikan sebagai *Hand in Shelf*. Ini dapat disebabkan oleh keterbatasan sudut pandang kamera oblique yang membuat awal dan akhir gerakan tangan terlihat mirip. Secara keseluruhan, pola kesalahan yang muncul mengindikasikan bahwa untuk meningkatkan akurasi lebih lanjut, diperlukan konteks temporal lebih panjang atau sinyal visual tambahan seperti arah tangan atau posisi objek. Ini juga mengindikasikan perlu lebih banyak dataset untuk training yang saat ini masih cukup terbatas. Meski begitu, model sudah cukup baik dalam membedakan gerakan-gerakan (action) pada kamera dan stream CCTV.

Table 2: Perbandingan metrik TimeSFormer MERL-CCTV

Kelas Aksi	**MERL-Shopping**			**CCTV-like**		
	Precision	**Recall**	**F1**	**Precision**	**Recall**	**F1**
Reach to Shelf	0.52	0.54	0.53	0.50	0.50	0.50
Inspect Product	0.67	0.73	0.70	1.00	1.00	1.00
Retract from Shelf	0.52	0.44	0.47	1.00	1.00	1.00
Hand in Shelf	0.61	0.71	0.65	0.50	0.50	0.50
Inspect Shelf	0.84	0.75	0.79	1.00	1.00	1.00
Background	0.54	0.68	0.60	1.00	1.00	1.00

Selain evaluasi kuantitatif, dilakukan pula visualisasi hasil inferensi dalam bentuk overlay pada video asli. Setiap individu ditampilkan dengan bounding box dan label aksi yang berubah dinamis sesuai prediksi model.



Figure 4: Contoh overlay prediksi aksi individu.

Secara keseluruhan, hasil ini menunjukkan bahwa model TimeSFormer tidak hanya mampu mengenali aksi pada dataset saat training, tetapi juga cukup robust saat diterapkan di toko nyata. Kemampuan ini menjadi fondasi kuat untuk mendukung komponen berikutnya dalam pipeline, yaitu visualisasi heatmap, analisis dwell-time, dan rekomendasi optimalisasi tata letak berbasis pola perilaku aktual pengunjung.

4.3 Ringkasan Perilaku Pengunjung

Sebagai sintesis akhir dari keseluruhan analisis, kami memetakan setiap rak ke dalam sebuah *Arketipe Perilaku*. Arketipe ini merupakan label kualitatif yang merangkum performa rak berdasarkan kombinasi tiga metrik utama: (1) *traffic* (diukur melalui jumlah interaksi unik), (2) tingkat perhatian (dwell time rata-rata), dan (3) kualitas interaksi (dari hasil analisis alur perilaku).

Table 3: Ringkasan arketipe perilaku teragregasi per rak

Rak	Interaksi Unik	Rata-rata Dwell (s)	Arketipe Perilaku
shelf_1	12	1.12	Traffic Tinggi, Engagement Rendah
shelf_9	11	1.29	Traffic Tinggi, Engagement Rendah
shelf_6	10	4.21	Interaksi Positif Namun Ragu
shelf_8	8	0.45	Low Engagement Zone
shelf_2	4	0.92	Low Engagement Zone
shelf_3	4	0.32	Low Engagement Zone
shelf_4	4	6.54	High Attention, Low Conversion
shelf_5	1	6.46	Passive Attention (No Physical Engagement)

Hasil pemetaan arketipe menunjukkan bahwa rak `shelf_4` memiliki potensi tinggi karena menarik perhatian mendalam dan menjadi satu-satunya rak dengan indikasi konversi, meski masih didominasi keraguan. Rak `shelf_6` juga menunjukkan interaksi positif namun selalu berujung pada pembatalan, menandakan ketertarikan awal yang gagal dikonversi. `Shelf_1` dan `shelf_9` merupakan titik dengan traffic tinggi, namun engagement rendah, sehingga perlu peningkatan daya tarik visual atau strategi promosi. Sementara itu, `shelf_5` menjadi anomali karena berhasil menahan perhatian cukup lama, tetapi tanpa aksi fisik apa pun, mengindikasikan potensi visual tanpa eksekusi pesan yang kuat. Adapun `shelf_2`, `shelf_3`, dan `shelf_8` masuk dalam zona engagement rendah, kemungkinan akibat penempatan yang tidak strategis atau kurangnya relevansi produk. Temuan ini menegaskan bahwa metrik seperti traffic dan dwell time perlu ditafsirkan bersama pola perilaku untuk menghasilkan insight yang benar-benar strategis.

5 Analisis dan Pembahasan Hasil

Bagian ini akan menyajikan analisis mendalam atas perilaku pengunjung yang terekam pada video CCTV sebuah toko retail (20 detik) melalui pipeline visi komputer yang telah dikembangkan.

Data dianalisis dari segi keterlibatan fisik terhadap rak serta alur aksi yang dihasilkan oleh model. Meskipun pengamatan ini hanya merupakan *snapshot* dari waktu yang sangat singkat, hasil analisisnya menunjukkan potensi kuat untuk memberi wawasan perilaku konsumen dan merancang tata letak yang lebih strategis.

5.1 Heat-map

Untuk membantu interpretasi spasial, Gambar 6 memperlihatkan *heat-map* kehadiran pengunjung selama durasi CCTV. Wilayah padat warna semakin cerah menunjukkan area dengan frekuensi kehadiran tinggi, yang banyak berkorelasi dengan lokasi rak-rak aktif.

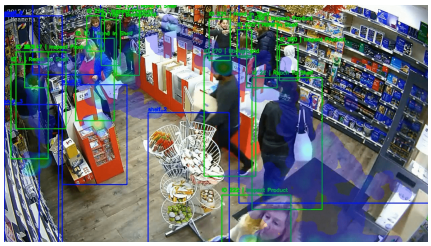


Figure 5: Overlay Pipeline pada CCTV

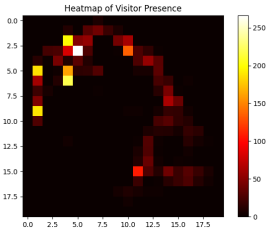


Figure 6: Heatmap pengunjung

Dari heatmap terlihat bahwa pengunjung cenderung bergerak mengikuti lintasan melingkar yang menyapu sebagian besar rak. Pergerakan ini berujung pada area dengan kepadatan tertinggi, yang kemungkinan merupakan zona kasir atau titik keluar. Hal ini memberikan insight strategis: area dengan intensitas kehadiran tinggi tersebut memiliki potensi besar sebagai titik visual exposure. Oleh karena itu, produk-produk impulsif—seperti camilan kecil, minuman ringan, atau barang kebutuhan harian—sebaiknya ditempatkan di titik ini guna meningkatkan peluang tertariknya pengunjung selama waktu tunggu pelanggan.

5.2 Analisis Deskriptif Visual dan Interaksi

Untuk memperoleh gambaran awal mengenai efektivitas masing-masing rak dalam menarik perhatian pengunjung, kami melakukan analisis deskriptif terhadap data interaksi fisik yang terekam selama durasi CCTV retail tersebut. Fokus utama pada tahap ini adalah memahami sejauh mana rak-rak yang tersedia berhasil mendorong terjadinya keterlibatan awal—baik dalam bentuk aksi fisik seperti menjangkau rak, mengambil produk, maupun hanya berdiri mengamati. Analisis dilakukan dengan memetakan dua indikator kunci: (1) jumlah total interaksi fisik yang terjadi pada setiap rak, dan (2) distribusi jenis aksi yang berhasil dipicu oleh masing-masing rak. Kedua metrik ini memberikan landasan penting sebelum kita masuk ke interpretasi perilaku yang lebih mendalam pada tahap selanjutnya.

5.2.1 Total Interaksi (Action) per Rak

Gambar 7 menunjukkan jumlah total interaksi fisik seperti *reach*, *inspect*, dan *hand-in* yang terjadi di depan masing-masing rak selama 20 detik observasi.

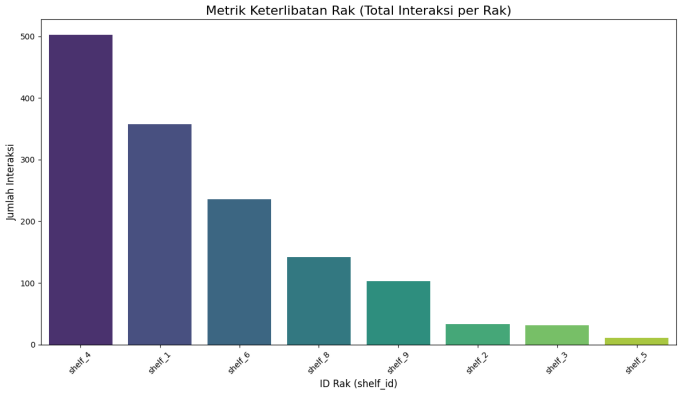


Figure 7: Total interaksi fisik per rak.

Dari grafik ini terlihat bahwa `shelf_4` merupakan rak dengan tingkat interaksi tertinggi, disusul oleh `shelf_1` dan `shelf_6`. Sementara itu, rak seperti `shelf_2`, `shelf_3`, dan terutama `shelf_5` hampir tidak menarik interaksi fisik sama sekali. Temuan ini menjadi indikator awal efektivitas rak dalam memicu perhatian pengunjung secara fisik.

5.2.2 Distribusi Aksi per Rak

Gambar 8 menampilkan distribusi jenis aksi yang terjadi pada tiap rak. Aksi diklasifikasikan menjadi enam kelas, yaitu *Reach to Shelf*, *Inspect Product*, *Hand in Shelf*, *Retract from Shelf*, *Inspect Shelf*, dan *Background*.

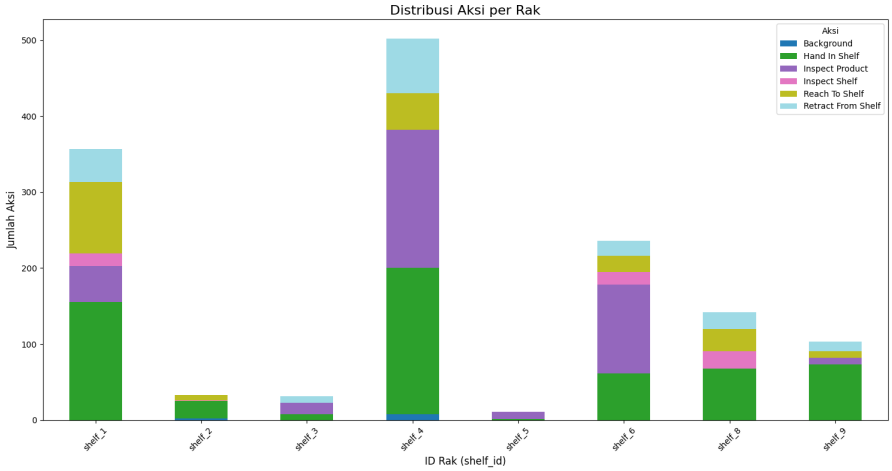


Figure 8: Distribusi jenis aksi per rak.

Distribusi ini memperlihatkan bahwa `shelf_4` tidak hanya mendominasi jumlah interaksi, tetapi juga memiliki variasi aksi yang cukup lengkap. Aksi *Inspect Product* dan *Hand in Shelf* mendominasi rak ini. Sebaliknya, rak seperti `shelf_5` hanya mengandung satu jenis aksi minor, mengindikasikan kurangnya keterlibatan pengunjung. Visualisasi ini juga menunjukkan bahwa interaksi tidak hanya dipengaruhi oleh posisi rak, tetapi juga oleh bagaimana rak tersebut berhasil menciptakan pemicu awal untuk aksi berikutnya.

5.3 Analisis Inferensial Perilaku dan Efektivitas Rak

Setelah mengobservasi metrik interaksi dan distribusi aksi secara umum, tahap selanjutnya adalah melakukan analisis inferensial terhadap efektivitas masing-masing rak. Tujuan utama dari tahap ini adalah mengevaluasi apakah interaksi awal yang terjadi pada sebuah rak benar-benar menghasilkan ketertarikan pada suatu produk atau bahkan keputusan pembelian (diindikasikan dari aksi lanjutan), atau justru berhenti sebagai interaksi pasif saja.

Dalam konteks ini, kami mendefinisikan sebuah ”efektivitas rak” sebagai kemampuan rak untuk menghasilkan interaksi yang berujung positif, bukan hanya menarik perhatian sesaat pembeli saja. Oleh karena itu, kami mencoba bahwa untuk seluruh rangkaian aksi pengunjung yang dimulai dari *Reach to Shelf* diurutkan dan diklasifikasikan menjadi tiga jenis alur perilaku berdasarkan outcomenya:

- Konversi Sukses (Hijau): Pengunjung menjangkau dan mengambil produk, lalu tidak mengembalikannya dalam durasi observasi. Ini merupakan bentuk interaksi paling bernilai dan mengindikasikan ketertarikan yang cukup tinggi.
- Keraguan dan Pembatalan (Oranye): Pengunjung menjangkau produk, kemudian menginspeksi dan akhirnya mengembalikannya. Ini menunjukkan adanya ketertarikan awal yang cukup kuat namun gagal meyakinkan hingga keputusan akhir.
- Gagal Menarik Minat (Merah): Tidak terjadi aksi *Reach*, atau terjadi interaksi ringan tanpa kelanjutan signifikan. Ini mencerminkan bahwa rak tersebut tidak cukup menarik atau tidak relevan bagi pengunjung saat itu.

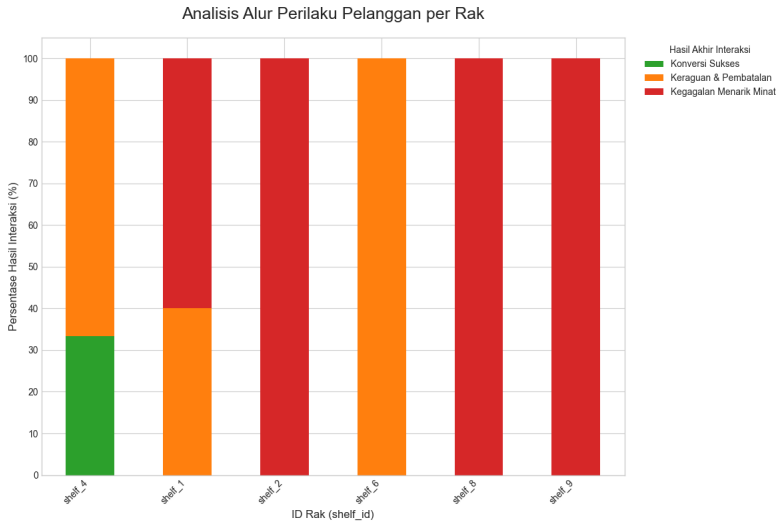


Figure 9: Distribusi outcome perilaku pengunjung.

Berdasarkan analisis perilaku pengunjung, setiap rak menunjukkan karakteristik interaksi yang berbeda. `shelf_4`, misalnya, menjadi satu-satunya rak yang berhasil menghasilkan konversi sukses. Meskipun demikian, sekitar 67% interaksi di rak ini justru berakhir dengan keraguan dan pembatalan. Hal ini mengindikasikan bahwa walaupun rak tersebut mampu menarik perhatian dan mendorong interaksi yang mendalam, mayoritas pengunjung pada akhirnya belum merasa yakin untuk membeli produk yang ditawarkan. Oleh karena itu, direkomendasikan untuk melakukan evaluasi ulang terhadap aspek produk, seperti harga dan posisinya, guna mengurangi keraguan pembeli.

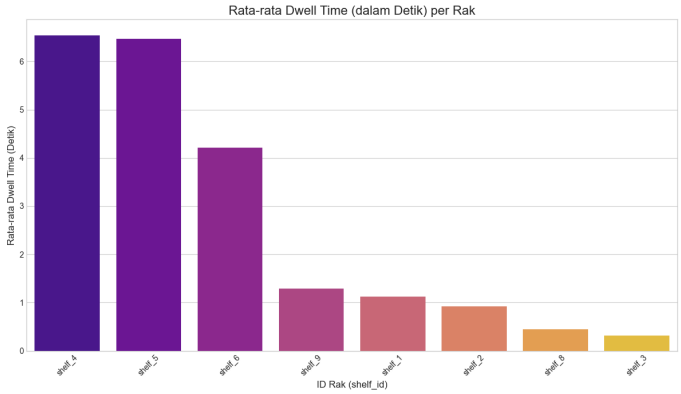


Figure 10: Waktu yang dihabiskan seorang pelanggan di suatu rak.

Di sisi lain, `shelf_5` menunjukkan fenomena yang kontras, dengan daya tarik visual yang tinggi namun tanpa adanya interaksi fisik. Rak ini berhasil mencatat *dwell-time* yang tinggi pada Gambar 10, yang menandakan bahwa pengunjung memperhatikannya, tetapi tidak ada satu pun yang terdorong untuk menyentuh (*reach*) atau memeriksa (*inspect*) produk. Potensi visual rak ini terlihat menonjol, tetapi tidak cukup menarik untuk memicu aksi lebih lanjut, sehingga disarankan untuk memperbaiki layout agar pesan visualnya lebih jelas dan mendorong interaksi.

Sementara itu, `shelf_1`, `shelf_6`, dan rak-rak lainnya secara umum masuk dalam kategori gagal menarik minat karena tingkat interaksinya yang sangat rendah dan tidak memicu aksi yang berarti. Kegagalan ini kemungkinan disebabkan oleh dua faktor, yaitu produk yang ditawarkan tidak relevan bagi pengunjung pada saat itu, atau posisi rak yang kurang strategis. Untuk mengatasi hal ini, direkomendasikan untuk melakukan eksperimen lebih lanjut, seperti menerapkan promosi visual, meningkatkan pencahayaan, atau mencoba penempatan ulang produk untuk melihat apakah ada peningkatan interaksi.

6 Kesimpulan dan Saran

Solusi ini berhasil mengembangkan sistem analitik perilaku pengunjung retail yang mengintegrasikan visi komputer dan multimodal transformer. Model YOLOv11-seg mencapai precision 94.73% untuk segmentasi rak, sementara TimeSFormer mencapai akurasi 75.0% setelah domain adaptation untuk klasifikasi aksi. Sistem berhasil mengidentifikasi arketipe perilaku pengunjung dan memberikan insight strategis: shelf 4 memiliki konversi tertinggi meski dengan tingkat keraguan 67%, pengunjung bergerak dalam pola melingkar dengan konsentrasi tertinggi di area kasir, dan terdapat 5 tipe perilaku berbeda yang dapat digunakan untuk optimasi tata letak.

Insight yang dihasilkan dari sistem memberikan dasar kuat bagi pengambilan keputusan bisnis berbasis data. Dengan memahami pola pergerakan dan interaksi pengunjung, pemilik toko dapat mengoptimalkan penataan produk, merancang ulang layout toko untuk meningkatkan konversi, serta menyesuaikan strategi pemasaran di area dengan *engagement* rendah. Pendekatan ini menjadikan AI sebagai alat transformasional dalam meningkatkan efisiensi operasional dan manajemen bisnis, sekaligus mendorong peningkatan penjualan secara strategis.

Saran untuk pengembangan sistem lebih lanjut dapat melakukan perluasan dataset guna meningkatkan generalisasi model, implementasi integrasi multi-kamera, dan pengembangan sistem *real-time processing* untuk monitoring operasional harian. Sementara untuk implementasi praktis, dapat dicoba untuk menempatkan produk impulsif di area dengan *traffic* tinggi seperti dekat kasir, dan menerapkan strategi promosi khusus untuk rak dengan engagement rendah. Kemudian, untuk penelitian lanjutan perlu dilakukan validasi sistem pada berbagai jenis toko retail, integrasi data penjualan aktual untuk validasi korelasi, dan studi longitudinal untuk memahami tren perubahan perilaku pengunjung.

References

[1] Wei, P., Kong, L., Qu, X., Ren, Y., Xu, Z., Jiang, J., & Yin, X. (2023). Unsupervised Video Domain Adaptation for Action Recognition: A Disentanglement Perspective. *arXiv preprint arXiv:2208.07365*.

[2] He, K., Gkioxari, G., Dollár, P., & Girshick, R. (2017). Mask R-CNN. *arXiv preprint arXiv:1703.06870*.

[3] Bolya, D., Zhou, C., Xiao, F., & Lee, Y. J. (2019). YOLACT: Real-time instance segmentation. *Proceedings of the IEEE/CVF international conference on computer vision.*

[4] Bewley, A., Ge, Z., Ott, L., Ramos, F., & Upcroft, B. (2017). Simple online and realtime tracking. *arXiv preprint arXiv:1602.00763.*

[5] Redmon, J., Divvala, S., Girshick, R., & Farhadi, A. (2016). You only look once: Unified, real-time object detection. *arXiv preprint arXiv:1506.02640.*

[6] Silverman, B. W. (1986). Density estimation for statistics and data analysis. *Chapman and Hall.*

[7] Bertasius, G., Wang, H., & Torresani, L. (2021). Is Space-Time Attention All You Need for Video Understanding? *arXiv preprint arXiv:2102.05095*.

[8] Yu, Z., Li, J., Du, Z., Zhu, L., & Shen, H. T. (2023). A Comprehensive Survey on Source-free Domain Adaptation. *arXiv preprint arXiv:2302.11803*.

[9] Singh, B., Marks, T. K., Jones, M., Tuzel, O., & Shao, M. (2016). A Multi-Stream Bi-Directional Recurrent Neural Network for Fine-Grained Action Detection. *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pp. 1961–1970.