Sistem AI Multimodal untuk Deteksi Dini Penyakit dan Analisis Perilaku Ayam

Gabriella Clairine
Department of Computer Science
Bina Nusantara University
Jakarta, Indonesia
gabriella.clairine@binus.ac.id

Imerson Krysthio
Department of Computer Science
Bina Nusantara University
Jakarta, Indonesia
imerson.krysthio@binus.ac.id

Abstract

Laporan ini mengusulkan pengembangan sistem pemantauan peternakan ayam berbasis Kecerdasan Buatan (AI) yang dirancang untuk mengatasi kerugian ekonomi signifikan dan tingkat mortalitas tinggi di industri peternakan ayam Indonesia akibat penyakit. Solusi yang diusulkan mengintegrasikan *computer vision* (CCTV *real-time* untuk deteksi perilaku ayam dan estimasi kepadatan) dan analisis suara (deteksi vokal yang mengindikasikan penyakit). Metodologi yang digunakan melibatkan algoritma *deep learning* seperti YOLOv11s dari Ultralytics untuk analisis visual dan *Mel Frequency Cepstral Coefficients* (MFCC) serta *Convolutional Neural Network* (CNN) untuk analisis audio, diimplementasikan pada arsitektur *Edge AI* untuk pemrosesan data lokal yang cepat. Sistem ini diharapkan dapat meningkatkan efisiensi operasional, mengurangi kerugian finansial, meningkatkan kesejahteraan hewan, dan menyediakan wawasan bisnis yang dapat ditindaklanjuti secara *real-time*. Dengan demikian, solusi ini secara langsung mewujudkan tema "AI-Powered Business Insight & Action" di sektor peternakan, mengubah data mentah menjadi keputusan strategis yang berdampak.

1 Pendahuluan

Sektor peternakan ayam di Indonesia memegang peranan krusial sebagai produsen dan konsumen utama produk ayam. Investasi domestik di subsektor peternakan menunjukkan angka yang signifikan, mencapai Rp 1,8 triliun pada tahun 2021, dengan ayam sebagai kontributor terbesar. Meskipun demikian, industri ini sangat rentan terhadap berbagai tantangan, terutama wabah penyakit yang dapat menyebabkan kerugian finansial yang parah dan mengancam keberlanjutan usaha.

Penyakit merupakan masalah serius yang berulang kali menyebabkan kerugian finansial signifikan bagi peternak ayam broiler. Salah satu ancaman terbesar adalah *Newcastle Disease* (ND), penyakit virus yang sangat menular dengan tingkat morbiditas dan mortalitas yang dapat mencapai 100%. Sebuah studi menunjukkan bahwa kerugian ekonomi akibat ND dapat mencapai Rp 474.500.000,00 dalam satu farm selama periode enam bulan (Juli-Desember 2022), dengan prevalensi sebesar 36,80%. Selain itu, *Chronic Respiratory Disease* (CRD), yang disebabkan oleh bakteri *Mycoplasma gallisepticum*, juga menimbulkan dampak ekonomi yang tidak kalah serius. Gejala CRD meliputi ingus, batuk, sesak napas, muka bengkak, nafsu makan berkurang, badan kurus, dan penurunan produksi telur hingga kurang dari 50% dari biasanya. Kerugian ekonomi yang tercatat pada satu kandang berisi 650 ekor ayam petelur akibat CRD dapat mencapai Rp 342.114,- per bulan, yang berarti pengurangan keuntungan sebesar 32,52% dalam satu periode produksi. Apabila terjadi komplikasi dan penanganan terlambat, kerugian dapat meningkat drastis dengan tingkat kematian mencapai 30%.

Gejala umum ayam sakit sangat bervariasi dan seringkali sulit dideteksi secara dini oleh peternak secara manual. Tanda-tanda ini meliputi nafsu makan berkurang, sesak napas, bersin-bersin, badan kurus, bulu kusam, penurunan produksi telur, mencret dengan berbagai warna, muka pucat atau membiru, jengger bengkak atau pucat, kaki meradang atau lumpuh, keluarnya cairan berbusa dari mata atau hidung, kepala bengkak atau terputar, mata berair, sayap turun, kotoran putih menempel di anus, tidur dengan paruh di lantai, duduk membungkuk, tubuh terasa lunak, pusar terbuka, timbul kutil, pertumbuhan terhambat, jatuh ke samping, kepala atau leher bergetar, bulu berdiri, kulit atau paruh pucat, mencret disertai lendir atau cacing, kejang-kejang, syaraf lumpuh, tampak malas bergerak, berkumpul di sekitar pemanas, berat ayam hanya setengah dari berat biasanya, serta tidak mau makan dan bergerak. Tingkat kematian total pada ayam petelur dalam satu penelitian dilaporkan sebesar 0,36% (9 dari 2.450 ekor), sementara ayam yang sakit mencapai 100%. Faktor predisposisi seperti manajemen pemeliharaan yang buruk, ventilasi yang tidak memadai, dan kepadatan populasi yang tinggi juga berkorelasi langsung dengan peningkatan risiko penyakit pernapasan dan kerugian ekonomi.

Metode pemantauan konvensional yang mengandalkan inspeksi manual oleh peternak memiliki keterbatasan serius. Proses ini rentan terhadap kelelahan, penurunan konsentrasi, dan kejenuhan, yang dapat menyebabkan kesalahan dalam penilaian ciri-ciri ayam. Selain itu, kurangnya akses terhadap teknologi modern dan biaya operasional yang tinggi seringkali menjadi kendala signifikan bagi peternak kecil. Kombinasi tingkat mortalitas yang tinggi (mencapai 100% untuk ND dan 30% untuk CRD yang berkomplikasi) dengan kerugian finansial yang masif (ratusan juta hingga miliaran rupiah per tahun untuk satu farm) menggambarkan bukan hanya sekadar masalah, melainkan ancaman eksistensial terhadap profitabilitas dan keberlanjutan peternakan ayam di Indonesia. Situasi ini menciptakan kerentanan ekonomi sistemik yang menuntut intervensi teknologi untuk menjamin stabilitas dan pertumbuhan industri, serta secara langsung mempengaruhi ketahanan pangan dan mata pencarian banyak individu.

Di luar kerugian langsung, ketidakmampuan untuk memantau dan mencegah penyakit secara efektif juga menimbulkan biaya peluang yang substansial dalam hal potensi produksi yang tidak terealisasi. Jika penyakit secara konsisten mengurangi produktivitas dan menyebabkan mortalitas tinggi, peternak akan terjebak dalam siklus manajemen reaktif. Hal ini menghambat kemampuan mereka untuk meningkatkan skala usaha, berinvestasi dalam praktik yang lebih baik, atau meningkatkan kesejahteraan hewan. Biaya peluang ini adalah hilangnya potensi untuk mencapai hasil panen yang lebih tinggi, kualitas produk yang lebih baik, dan daya saing pasar yang lebih kuat. Dengan demikian, ketergantungan pada metode manual yang tidak efisien menghambat modernisasi dan keberlanjutan industri peternakan ayam secara keseluruhan, menghalangi potensi produksi yang belum terealisasi dan menghambat pengembangan ekosistem pertanian yang lebih tangguh. Oleh karena itu, terdapat kebutuhan mendesak akan sistem inovatif yang mampu memberikan deteksi dini dan wawasan akurat untuk mengurangi kerugian dan meningkatkan produktivitas secara signifikan.

2 Kajian Teori

2.1 Computer Vision dalam Peternakan

Computer Vision (CV) merupakan cabang ilmu komputer yang memungkinkan komputer untuk “melihat” dan memahami gambar digital atau video. Dalam industri peternakan ayam, penerapan CV sangat beragam dan memiliki peran penting. Salah satu aplikasinya adalah deteksi objek dan perilaku, di mana teknologi ini dapat digunakan untuk mengidentifikasi setiap ayam dalam video, serta mengenali objek penting seperti tempat makan dan minum. Sistem juga dapat dilatih untuk mengenali perilaku dasar ayam seperti makan, minum, atau diam. Algoritma deteksi objek seperti YOLO (*You Only Look Once*), khususnya model YOLOv11s dari Ultralytics varian 'small', sangat cocok untuk deteksi real-time karena efisien dan ringan sehingga sesuai untuk kondisi peternakan dengan sumber daya komputasi terbatas.

Selain itu, CV juga dapat menganalisis gerakan dan keaktifan ayam secara individu maupun kelompok untuk mendeteksi pola yang tidak biasa, seperti ayam yang lesu atau tidak bergerak dalam waktu lama, yang bisa menjadi tanda awal penyakit. Model *track anything* (TAM) telah menunjukkan akurasi tinggi dalam mendeteksi kecepatan pergerakan ayam, dengan nilai Root Mean Square Error (RMSE) sebesar 0,02 m/s. Dengan bantuan *library motrackers* untuk *Multiple Object Tracking (MOT)*, setiap ayam dapat diberi ID unik sehingga pergerakannya bisa dilacak dari *frame* ke *frame* guna menganalisis perubahan perilaku secara rinci.

CV juga dapat digunakan untuk mengestimasi kepadatan kerumunan ayam dengan menghitung jumlah objek per meter persegi di dalam kandang. Ini sangat penting untuk mengidentifikasi area dengan kepadatan tinggi yang berpotensi menyebabkan stres atau mempercepat penyebaran penyakit. Sistem ini, yang menggunakan algoritma *deep learning* dan YOLO, dapat mencapai akurasi estimasi kepadatan hingga 80,96%. Tak kalah penting, CV juga dapat dilatih untuk mendeteksi gejala-gejala visual penyakit. Misalnya, ayam yang berkumpul di satu area karena sakit atau kedinginan, postur tubuh tidak normal seperti sayap turun atau posisi duduk membungkuk, serta tanda fisik seperti bulu kusam, muka pucat, atau jengger bengkak dapat diidentifikasi, asalkan resolusi kamera cukup memadai. Dengan kemampuannya ini, CV menjadi alat penting dalam sistem pemantauan kesehatan ayam yang akurat dan efisien.

2.2 Analisis Suara dalam Peternakan

Analisis suara merupakan metode untuk menilai kesehatan dan perilaku ayam melalui pengamatan terhadap distribusi energi, frekuensi, dan amplitudo dari suara yang dihasilkan. Dalam praktiknya, suara ayam dapat digunakan untuk mendeteksi penyakit seperti *Newcastle Disease* dan *Avian Influenza* dengan tingkat akurasi hingga 100% menggunakan jaringan saraf tiruan atau metode *Support Vector Machine (SVM)*. Untuk memungkinkan klasifikasi suara, metode ekstraksi fitur seperti *Mel Frequency Cepstral Coefficients (MFCC)* digunakan untuk mengubah sinyal audio mentah menjadi bentuk representasi yang dapat dianalisis, melalui tahapan seperti *Fast Fourier Transform (FFT)*, *Mel Filter Bank*, dan *Discrete Cosine Transform (DCT)*.

Model *machine learning* seperti *Convolutional Neural Network (CNN)* dan *Gaussian Mixture Model (GMM)* kemudian digunakan untuk mengklasifikasikan berbagai jenis suara seperti batuk, bersin, megap-megap, dan suara *distress*. Dalam kondisi ideal, model *GMM* yang dikombinasikan dengan *MFCC* mampu mencapai akurasi hingga 82,22%. Selain itu, analisis suara juga dapat mendeteksi suara-suara abnormal lain yang menandakan stres tinggi atau kehadiran predator di sekitar kandang.

Integrasi analisis suara dengan teknologi *Computer Vision* memperkuat akurasi sistem pemantauan. Sebagai contoh, ketika seekor ayam terlihat lesu secara visual dan sekaligus mengeluarkan suara *distress*, kemungkinan besar ayam tersebut sedang sakit. Sebaliknya, ayam yang tampak aktif namun menghasilkan suara abnormal bisa saja sedang mengalami stres. Pendekatan *multi-modal* seperti ini mampu meningkatkan akurasi deteksi dini dan mengurangi risiko kesalahan diagnosis.

Dengan menggabungkan data granular dari perilaku visual, suara, serta parameter lingkungan, sistem berbasis *AI* dapat mewujudkan *pertanian presisi* yang sesungguhnya. Hal ini memungkinkan penyesuaian pakan, ventilasi, hingga identifikasi genetik ayam yang lebih tangguh terhadap penyakit. Pendekatan ini mendorong transisi dari praktik peternakan reaktif menjadi proaktif, menciptakan industri peternakan ayam yang lebih tangguh, berkelanjutan, dan berbasis data.

2.3 Infrastruktur Akuisisi Data dan Lingkungan Implementasi Model AI

Model *Artificial Intelligence (AI)* yang diusulkan dirancang untuk bekerja secara efisien dengan memanfaatkan infrastruktur akuisisi data yang sudah ada atau yang dapat diterapkan

secara minimal di peternakan. Fokus utamanya adalah pada pemanfaatan data visual dan audio yang relevan untuk menganalisis perilaku serta kesehatan ayam. Kamera *CCTV* dan mikrofon yang telah terpasang di kandang dapat digunakan sebagai sumber data utama, di mana kamera menyuplai *feed* video untuk analisis visual, sedangkan mikrofon menangkap sinyal audio untuk analisis suara.

Agar pemrosesan data dapat dilakukan secara langsung di lokasi tanpa perlu ketergantungan pada jaringan internet, sistem AI akan diintegrasikan ke dalam unit pemrosesan seperti *embedded machine*. Perangkat ini dapat berupa komputasi edge berdaya rendah seperti *Raspberry Pi* atau *NVIDIA Jetson Nano*, atau bahkan modul internal dalam kamera pintar. Dengan pendekatan ini, sistem dapat menjalankan analisis secara *real-time*, memberikan respons cepat terhadap perubahan kondisi di kandang.

Selain pengamatan terhadap perilaku ayam, sistem ini juga dapat diperkaya dengan data lingkungan seperti suhu, kelembaban, dan kualitas udara apabila sensor-sensor terkait tersedia. Informasi lingkungan ini dapat memberikan konteks tambahan yang penting, terutama dalam mengidentifikasi faktor eksternal yang memengaruhi kesehatan ayam. Integrasi data perilaku dan lingkungan mencerminkan prinsip *Internet of Things (IoT)* yang relevan dalam pengembangan pertanian presisi.

Keunggulan utama dari sistem ini adalah kemampuannya menggabungkan data *multi-modal* dari kamera dan mikrofon, sehingga mampu memberikan interpretasi kondisi ayam secara lebih akurat. Sebagai contoh, ayam yang terdeteksi lesu secara visual dan juga mengeluarkan suara batuk atau *distress* lebih mungkin sedang sakit. Pendekatan ini secara signifikan mengurangi *false positives* dan *false negatives*, serta menciptakan *dataset* yang lebih kaya untuk pelatihan model AI. Dengan analisis mendalam pada tingkat individu dan kelompok, peternakan dapat berpindah dari pendekatan reaktif menjadi proaktif dan preskriptif, mendorong efisiensi pengelolaan, peningkatan kesejahteraan hewan, serta seleksi genetik untuk populasi ayam yang lebih sehat dan produktif. Ini menandai langkah besar menuju masa depan industri peternakan yang lebih tangguh dan berkelanjutan.

3 Solusi Usulan

3.1 Arsitektur Sistem AI-Powered Poultry Monitoring

Sistem pemantauan ayam berbasis *Artificial Intelligence (AI)* yang diusulkan dirancang dengan arsitektur yang kuat dan terdistribusi untuk memastikan efisiensi pemrosesan data serta respons real-time terhadap kondisi di lapangan. Sistem ini terdiri dari beberapa komponen utama yang saling terintegrasi dan berfungsi mendukung pemantauan kesehatan ayam secara berkelanjutan.

Komponen pertama adalah sensor akuisisi data, yaitu kamera *CCTV* beresolusi tinggi dengan kemampuan *night vision* untuk pemantauan visual selama 24 jam, serta mikrofon industri yang tahan terhadap kondisi lingkungan kandang seperti debu dan kelembaban tinggi. Data dari sensor ini kemudian dikirimkan ke unit pemrosesan *edge*, berupa perangkat komputasi mini hemat daya seperti *Raspberry Pi* atau *NVIDIA Jetson Nano*. Model AI akan diintegrasikan langsung ke dalam kamera pintar yang telah tersedia atau diproses melalui perangkat edge terpisah yang menerima input dari kamera dan mikrofon.

Modul AI/ML yang tertanam dalam sistem memuat model *deep learning* yang telah dilatih secara khusus untuk tugas *computer vision* dan analisis suara guna mendeteksi gejala visual serta vokalisasi abnormal yang menandakan penyakit atau stres pada ayam. Untuk mendukung fungsi tambahan seperti penyimpanan data historis, pelatihan ulang model, dan analisis data berskala besar, sistem dapat dihubungkan ke platform *cloud* secara opsional. Cloud ini juga menjadi tempat agregasi data dan memungkinkan peningkatan model AI secara berkelanjutan berdasarkan data terbaru yang dikumpulkan dari lapangan.

Akhirnya, seluruh proses dikendalikan dan dimonitor melalui antarmuka pengguna berupa aplikasi seluler atau dasbor web yang intuitif. Melalui platform ini, peternak dapat menerima notifikasi otomatis, melihat data kondisi ayam secara real-time, serta mengakses laporan analitik dan rekomendasi tindakan. Data video dan audio dari kamera diproses secara lokal

di perangkat edge, dan hasilnya dikirimkan ke cloud serta ditampilkan ke pengguna secara instan, memastikan deteksi dini serta respons cepat terhadap potensi gangguan kesehatan pada ayam.

3.2 Modul Computer Vision (CV) - Analisis Perilaku Ayam

Modul *Computer Vision (CV)* merupakan komponen inti dalam sistem pemantauan visual yang dirancang untuk menganalisis *feed* video dari kamera *CCTV* guna memahami perilaku ayam secara otomatis dan *real-time*. Model utama yang digunakan adalah *Ultralytics YOLOv11s*, yaitu varian ringan (*small*) dari arsitektur YOLOv11, yang dipilih karena kemampuannya mendeteksi objek dengan cepat dan efisien tanpa memerlukan daya komputasi tinggi. Model ini digunakan untuk mendeteksi ayam secara akurat pada setiap *frame* video, dengan kemampuan mengidentifikasi lokasi dan ukuran individu ayam dalam kandang.

Sumber data utama untuk pelatihan model CV diperoleh dari video siaran langsung yang tersedia secara publik di situs Kipster Farm Live Cams. Video dari kamera *CCTV* tersebut direkam dan diekstrak menjadi *frame* citra statis, yang kemudian dianotasi secara manual menggunakan platform *Roboflow*. Proses anotasi difokuskan pada penandaan ayam dengan menggunakan *bounding box*, tanpa melakukan klasifikasi perilaku pada tahap awal. Dataset akhir terdiri dari total 349 gambar, dengan 314 gambar digunakan untuk pelatihan dan 35 gambar untuk validasi.



Figure 1: Frame asli (kiri) dan hasil anotasi bounding box ayam menggunakan *Roboflow* (kanan)

Setelah proses deteksi, sistem akan melanjutkan ke tahap pelacakan menggunakan *library Motrackers* (*Multiple Object Tracking*). Setiap ayam yang terdeteksi akan diberi ID unik agar dapat dibedakan satu sama lain sepanjang waktu. Proses pelacakan ini memungkinkan analisis perilaku secara mendalam, seperti pola pergerakan, interaksi sosial, serta perubahan perilaku ayam dari waktu ke waktu. Dengan kombinasi antara deteksi dan pelacakan ini, sistem mampu membangun pemahaman perilaku ayam secara lebih kompleks dan kontekstual.

Beberapa analisis lanjutan yang dapat dilakukan oleh sistem mencakup estimasi kepadatan ayam di area tertentu, yang bermanfaat untuk mengidentifikasi zona berisiko tinggi karena kepadatan berlebih yang dapat memicu stres atau penyebaran penyakit. Sistem juga menghitung jarak antar ayam untuk memahami interaksi sosial atau mendeteksi penumpukan abnormal yang dapat menunjukkan gejala sakit. Selain itu, analisis *trajectory* memungkinkan pemantauan pola pergerakan individu, untuk mendeteksi ayam yang tidak aktif, bergerak lambat, atau menunjukkan perilaku menyimpang lainnya.

Modul CV juga dilatih secara khusus untuk mengenali perilaku visual yang mengindikasikan penyakit. Beberapa indikator visual yang dianalisis meliputi kebiasaan ayam sakit yang cenderung berkumpul di satu titik (*grouping*), postur tubuh yang tidak normal seperti sayap menggantung ke bawah, duduk membungkuk, atau kepala terputar ke belakang. Deteksi terhadap tanda-tanda fisik seperti bulu kusam, muka pucat, dan jengger bengkak juga dapat dilakukan, tergantung pada resolusi kamera yang digunakan. Sistem ini dibangun dengan mengandalkan *Ultralytics YOLOv11* untuk deteksi objek dan *Motrackers* untuk pelacakan serta penandaan ayam secara individual, sehingga memberikan fondasi kuat bagi analisis perilaku berbasis visual yang akurat dan adaptif dalam lingkungan peternakan.

3.3 Modul Analisis Audio

Modul analisis audio berfungsi untuk memproses *stream* suara yang diekstrak dari rekaman *CCTV* guna mendeteksi indikator kesehatan ayam melalui karakteristik vokalisasi. Proses dimulai dengan pemisahan audio dari video secara terpisah, agar sinyal suara dapat dianalisis secara optimal tanpa gangguan visual. Fitur utama dari sinyal suara akan diekstraksi menggunakan metode *Mel Frequency Cepstral Coefficients (MFCC)*, yang telah terbukti efektif dalam merepresentasikan suara untuk keperluan klasifikasi. Proses ekstraksi ini mencakup tahapan *pre-emphasis* untuk menyeimbangkan frekuensi tinggi, *framing* dan *windowing* untuk membagi sinyal menjadi segmen-segmen pendek, *Fast Fourier Transform (FFT)* untuk mendapatkan spektrum frekuensi, *Mel Filter Bank* untuk meniru cara kerja pendengaran manusia, serta *Discrete Cosine Transform (DCT)* untuk mereduksi dimensi data fitur yang dihasilkan.

Setelah fitur diekstraksi, suara akan diklasifikasikan menggunakan model *deep learning* seperti *Convolutional Neural Network (CNN)* atau *jaringan saraf tiruan*. Model ini akan dilatih secara khusus untuk mengenali suara ayam yang sehat dan membedakannya dari suara yang mengindikasikan penyakit, seperti batuk, bersin, suara napas tidak normal (*megap-megap*), dan suara *distress*. Penelitian sebelumnya menunjukkan bahwa metode ini dapat mencapai akurasi hingga 100% dalam mendiagnosis beberapa penyakit ayam. Selain untuk deteksi penyakit, sistem juga akan dirancang untuk mendeteksi suara abnormal lainnya, seperti vokalisasi panik yang dapat menandakan kehadiran predator atau kondisi stres tinggi pada ayam.

Dataset yang digunakan untuk pelatihan dan pengujian model diambil dari Mendeley Data – Poultry Vocalization Signal Dataset, dengan total 346 file audio. Dataset ini terdiri dari 139 sampel suara sehat, 86 noise, dan 121 sampel suara ayam tidak sehat. Untuk pengujian, digunakan 70 sampel dengan distribusi 29 healthy, 17 noise, dan 24 unhealthy, sedangkan sisanya digunakan sebagai data pelatihan. Distribusi yang relatif seimbang ini memungkinkan pelatihan model yang lebih stabil dan evaluasi performa yang representatif.

3.4 Integrasi Data dan Mekanisme Wawasan

Modul analisis audio berfungsi untuk memproses *stream* suara yang diekstrak dari rekaman *CCTV* guna mendeteksi indikator kesehatan ayam melalui karakteristik vokalisasi. Proses dimulai dengan pemisahan audio dari video secara terpisah, agar sinyal suara dapat dianalisis secara optimal tanpa gangguan visual. Fitur utama dari sinyal suara akan diekstraksi menggunakan metode *Mel Frequency Cepstral Coefficients (MFCC)*, yang telah terbukti efektif dalam merepresentasikan suara untuk keperluan klasifikasi. Proses ekstraksi ini mencakup tahapan *pre-emphasis* untuk menyeimbangkan frekuensi tinggi, *framing* dan *windowing* untuk membagi sinyal menjadi segmen-segmen pendek, *Fast Fourier Transform (FFT)* untuk mendapatkan spektrum frekuensi, *Mel Filter Bank* untuk meniru cara kerja pendengaran manusia, serta *Discrete Cosine Transform (DCT)* untuk mereduksi dimensi data fitur yang dihasilkan.

Setelah fitur diekstraksi, suara akan diklasifikasikan menggunakan model *deep learning* seperti *Convolutional Neural Network (CNN)* atau *jaringan saraf tiruan*. Model ini akan dilatih secara khusus untuk mengenali suara ayam yang sehat dan membedakannya dari suara yang mengindikasikan penyakit, seperti batuk, bersin, suara napas tidak normal, dan suara *distress*. Penelitian sebelumnya menunjukkan bahwa metode ini dapat mencapai akurasi hingga 100% dalam mendiagnosis beberapa penyakit ayam. Selain untuk deteksi penyakit, sistem juga akan dirancang untuk mendeteksi suara abnormal lainnya, seperti vokalisasi panik yang dapat menandakan kehadiran predator atau kondisi stres tinggi pada ayam..

3.5 Strategi Deployment

Strategi *deployment* sistem berfokus pada penerapan *Edge AI* untuk memastikan efisiensi tinggi dan respons real-time. Dengan pemrosesan data langsung di perangkat yang terpasang di kandang, seperti *Raspberry Pi* atau *NVIDIA Jetson Nano*, latensi dapat ditekan hingga

tingkat milidetik, memungkinkan deteksi dini dan respons cepat terhadap gejala penyakit tanpa bergantung pada koneksi internet. Perangkat ini cukup kuat untuk menjalankan model *deep learning* seperti *YOLOv11s*, dan dapat diintegrasikan langsung ke kamera *CCTV* yang ada.

Penerapan *Edge AI* sangat krusial dalam mencegah wabah besar seperti *Newcastle Disease*, di mana penundaan beberapa menit saja dapat menyebabkan kerugian besar. Pemrosesan lokal memungkinkan notifikasi instan dan intervensi proaktif. Desain sistem yang modular juga mendukung skalabilitas, dari peternakan kecil hingga besar, cukup dengan menambahkan unit edge dan sensor tambahan di berbagai zona kandang.

Perangkat keras yang digunakan, seperti kamera dan mikrofon, dipilih berdasarkan ketahanannya terhadap lingkungan kandang yang penuh debu, lembab, dan fluktuatif suhunya. Selain deteksi, arsitektur ini juga mendukung pengumpulan data multi-modal secara berkelanjutan, membuka peluang untuk pengembangan sistem prediktif dan preskriptif. Ke depannya, sistem tidak hanya mampu mengidentifikasi ayam yang sakit, tetapi juga memprediksi risiko penyakit dan merekomendasikan tindakan pencegahan, sehingga meningkatkan profitabilitas dan keberlanjutan peternakan secara keseluruhan.

4 Hasil Eksperimen dan Pengujian

4.1 Pengujian Modul Computer Vision (Deteksi dan Pelacakan Ayam)

Pengujian modul *Computer Vision (CV)* dilakukan untuk mengevaluasi akurasi dan efisiensi model dalam mendeteksi serta melacak ayam secara real-time. Model yang digunakan adalah *Ultralytics YOLOv11s*, sebuah varian ringan dari arsitektur YOLOv11 yang dirancang untuk efisiensi komputasi tinggi, sehingga dapat dijalankan pada perangkat *edge* dengan sumber daya terbatas. Dataset pelatihan terdiri dari 24 gambar ayam yang telah dianotasi secara manual dengan *bounding box*. Dari jumlah tersebut, 21 gambar digunakan untuk pelatihan dan 3 gambar digunakan sebagai data validasi.

Model dilatih selama 100 *epoch*, dengan pemantauan metrik evaluasi utama berupa *mean Average Precision (mAP)*. Hasil pelatihan menunjukkan performa yang sangat tinggi, dengan nilai *mAP50* sebesar **0.976** dan *mAP50–95* sebesar **0.841**. Nilai *mAP50* yang mendekati sempurna menunjukkan bahwa model mampu mendeteksi ayam secara presisi bahkan dalam kondisi visual yang kompleks.

Setelah pelatihan, model diterapkan pada rekaman video untuk menguji kemampuannya dalam deteksi dan pelacakan secara real-time. Untuk pelacakan individu, digunakan *library Motrackers* dengan pendekatan *Multiple Object Tracking (MOT)* yang memberikan ID unik pada setiap ayam terdeteksi. Dengan ini, sistem dapat membedakan dan melacak setiap ayam dari satu frame ke frame berikutnya secara berkelanjutan, memungkinkan analisis perilaku tingkat individu.

Gambar berikut menunjukkan contoh hasil deteksi dan pelacakan ayam. Setiap ayam diberi *bounding box* dan label ID unik, dan area dengan konsentrasi tinggi ditandai sebagai zona kepadatan yang berpotensi menjadi indikator stres atau infeksi:



Figure 2: Hasil deteksi dan pelacakan ID ayam menggunakan YOLOv11s dan *Motrackers* (kiri), serta identifikasi zona kepadatan tinggi dalam kandang (kanan)

Pengukuran waktu pemrosesan menunjukkan bahwa sistem bekerja dalam kerangka *real-time*, dengan rata-rata waktu proses per frame sebagai berikut: *preprocessing* berkisar antara

2.1–6.1 ms, *inference* antara 10.8–86.2 ms tergantung kompleksitas visual, dan *postprocessing* antara 1.4–48.5 ms. Nilai ini menunjukkan bahwa model dapat diimplementasikan secara efisien di perangkat *edge* dengan latensi yang sangat rendah.

Selain deteksi individu, model juga dievaluasi untuk estimasi kepadatan ayam per area. Dengan membagi area kandang ke dalam grid virtual, sistem menghitung jumlah ayam per sel dalam tiap frame untuk mendeteksi zona dengan kepadatan tinggi. Informasi ini dapat digunakan untuk memprediksi risiko stres, infeksi silang, atau kebutuhan penyesuaian manajemen ruang kandang secara dinamis.

4.2 Pengujian Modul Analisis Vokal (Deteksi Penyakit dari Suara)

Pengujian terhadap modul analisis vokal dilakukan untuk mengevaluasi kemampuan sistem dalam mengklasifikasikan suara ayam ke dalam tiga kategori utama, yaitu *Healthy*, *Noise*, dan *Unhealthy*. Dataset yang digunakan dalam eksperimen ini terdiri atas 139 sampel suara ayam sehat, 86 sampel noise lingkungan, dan 121 sampel suara yang berasal dari ayam yang menunjukkan gejala penyakit. Meskipun terdapat ketidakseimbangan antar kelas, distribusi ini tetap dianggap cukup representatif untuk tahap pengujian awal.

Proses *preprocessing* audio dimulai dengan konversi sinyal suara mentah menjadi representasi *Log-Mel Spectrogram*, yaitu metode ekstraksi fitur yang menggabungkan transformasi domain frekuensi dengan skala persepsi manusia. Tahapan yang dilakukan meliputi *pre-emphasis*, *framing*, *windowing*, *Fast Fourier Transform (FFT)*, *Mel filter bank*, dan *Discrete Cosine Transform (DCT)*. Representasi hasil transformasi ini kemudian digunakan sebagai input ke dalam model klasifikasi berbasis *Convolutional Neural Network (CNN)*. Model CNN yang digunakan dalam pengujian ini adalah *ModdifiedModel*, yang terdiri atas lapisan *Conv2d*, *BatchNorm2d*, *ReLU*, dan *MaxPool2d* untuk tahap ekstraksi fitur, serta lapisan *Flatten*, *Linear*, *Dropout*, dan *ReLU* untuk proses klasifikasi. Arsitektur ini dirancang dengan jumlah *in_features* sebesar 25.088 pada lapisan linear pertama. Struktur lengkap arsitektur model dapat dilihat pada gambar berikut:

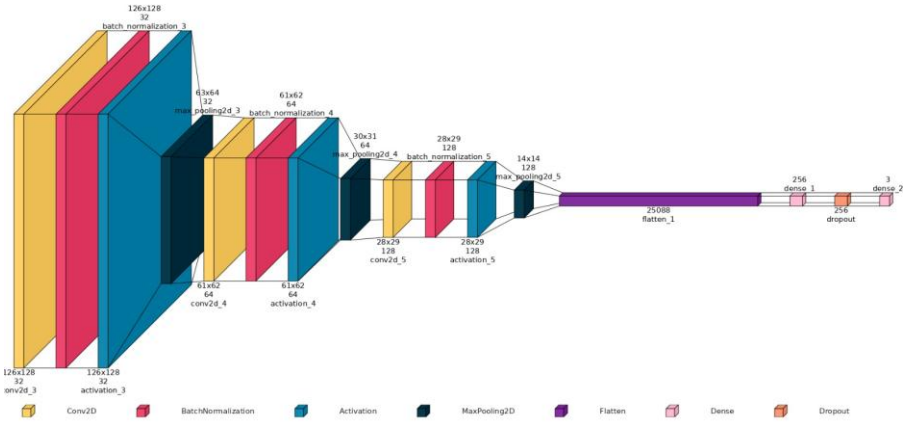


Figure 3: Arsitektur jaringan CNN (ModdifiedModel) untuk klasifikasi suara ayam

Selama proses pelatihan selama 30 *epoch*, model menunjukkan peningkatan akurasi yang konsisten, dengan hasil pada *epoch* ke-30 mencapai nilai *loss* sebesar 1.1844 dan akurasi pelatihan sebesar 94.57%. Model kemudian dievaluasi pada data uji untuk menilai kemampuannya dalam mengklasifikasikan suara secara akurat. Salah satu contoh prediksi menunjukkan bahwa model mampu mengklasifikasikan sebuah sampel sebagai “Healthy” dengan probabilitas 77.60%, sementara probabilitas untuk kelas “Noise” dan “Unhealthy” masing-masing adalah 0.79% dan 21.60%. Hal ini menunjukkan adanya kemampuan diskrit model dalam mengenali perbedaan antara suara sehat dan tidak sehat.

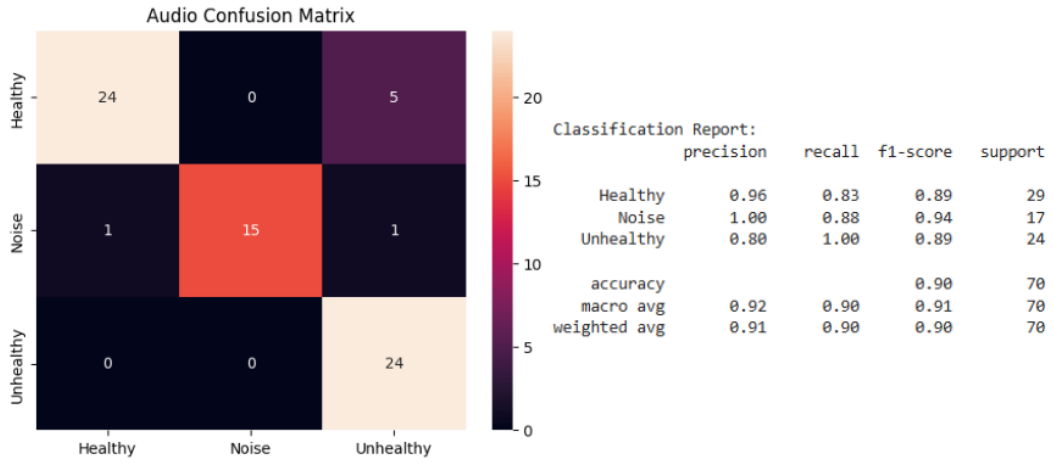


Figure 4: *Confusion matrix* dan *classification report* hasil evaluasi model analisis audio pada data uji

Evaluasi lebih lanjut dilakukan menggunakan *confusion matrix* dan *classification report*, yang memberikan gambaran performa model berdasarkan metrik *precision*, *recall*, dan *f1-score*. Untuk kelas "Healthy", diperoleh precision sebesar 0.96, recall sebesar 0.83, dan f1-score sebesar 0.89 dari total 29 sampel. Kelas "Noise" mencatat precision dan recall yang sangat tinggi, masing-masing sebesar 1.00 dan 0.88. Sementara itu, kelas "Unhealthy" mencapai recall sempurna sebesar 1.00, dengan precision 0.80 dan f1-score 0.89. Akurasi keseluruhan model pada data uji tercatat sebesar 90%, dengan nilai *macro average* dan *weighted average* untuk ketiga metrik utama berada di kisaran 0.90–0.92. Hasil ini menegaskan bahwa model mampu membedakan suara ayam sehat, noise lingkungan, dan suara ayam yang menunjukkan gejala penyakit dengan performa yang sangat baik dan stabil.

5 Analisis Hasil

5.1 Kinerja Modul Computer Vision

Hasil pengujian menunjukkan bahwa model *YOLOv11s* sangat akurat dalam mendeteksi ayam, dengan nilai *mAP50* sebesar **0.976**, yang berarti model berhasil mengenali hampir seluruh objek ayam dalam citra dengan presisi tinggi. Ini menunjukkan bahwa sistem mampu menggantikan peran pemantauan visual manual secara signifikan, terutama dalam lingkungan padat seperti kandang ayam intensif. Di sisi bisnis, ini berarti penghematan biaya tenaga kerja dan peningkatan kecepatan respons terhadap anomali perilaku atau distribusi ayam.

Kecepatan inferensi rata-rata sebesar 10–25 ms per frame memastikan sistem dapat berjalan secara real-time pada perangkat edge berbiaya rendah seperti Raspberry Pi atau Jetson Nano. Dalam praktiknya, ini memberikan nilai tambah berupa kemampuan deteksi dini tanpa perlu infrastruktur cloud mahal atau latensi tinggi. Kecepatan ini sangat krusial, karena memungkinkan sistem mendeteksi gejala penyakit, kepadatan abnormal, atau ayam yang tidak aktif dalam waktu nyaris seketika.

Dengan *Motrackers*, sistem berhasil memberikan ID unik pada setiap ayam, membuka jalan bagi metrik perilaku granular seperti *Total Distance Performed (TDP)* dan durasi tidak bergerak. Ini dapat diterjemahkan menjadi indikator risiko stres, lesu, atau bahkan onset penyakit, yang tidak dapat terdeteksi secara visual biasa. Bagi peternak, kemampuan ini berarti peningkatan produktivitas dan potensi menghindari kerugian akibat kematian ayam atau penurunan kualitas hasil panen. Namun demikian, ukuran dataset pelatihan yang hanya terdiri dari 24 gambar menjadi batasan serius dalam hal generalisasi. Untuk meningkatkan adaptasi model di lingkungan nyata dengan kondisi pencahayaan atau tata letak yang bervariasi, dataset perlu ditingkatkan secara signifikan.

5.2 Kinerja Modul Analisis Vokal

Model CNN untuk klasifikasi suara ayam menunjukkan performa sangat baik dengan akurasi 94.57% pada pelatihan dan 90% pada data uji. *Confusion matrix* menunjukkan bahwa sistem sangat akurat dalam membedakan suara sehat, noise, dan suara ayam yang sakit. Secara khusus, recall sebesar 1.00 untuk kelas "Unhealthy" berarti tidak ada kasus penyakit yang terlewat selama pengujian. Dalam konteks operasional peternakan, ini mengindikasikan potensi besar untuk mendeteksi gejala awal penyakit bahkan sebelum tanda visual muncul.

Deteksi berbasis suara menjadi pelengkap penting dari analisis visual, karena suara ayam seringkali menjadi indikator pertama dari distress atau gangguan pernapasan. Dengan sistem ini, peternak bisa menerima peringatan dini, bahkan jika ayam sedang tidak tertangkap kamera atau dalam kondisi pencahayaan rendah. Dari sisi bisnis, ini berarti pengurangan waktu respons, peningkatan rasio penyelamatan ayam, dan pada akhirnya menurunkan kerugian akibat mortalitas atau penurunan produktivitas. Namun, perlu dicatat bahwa meskipun performa tinggi tercapai, dataset suara masih terbatas dalam variasi dan jumlah. Untuk aplikasi komersial skala besar, perlu penambahan data dari berbagai lingkungan kandang dengan noise dan pola penyakit yang beragam agar sistem tetap andal dan adaptif.

5.3 Analisis Integrasi Multi-Modal

Walaupun integrasi data visual dan audio belum sepenuhnya diuji secara sistematis, analisis konseptual menunjukkan bahwa pendekatan *multi-modal* memberikan keunggulan kompetitif. Misalnya, ayam yang terlihat lesu secara visual dan juga menghasilkan suara distress akan memiliki probabilitas lebih tinggi diklasifikasikan sebagai sakit. Ini menurunkan risiko *false positive* (ayam tampak sakit padahal hanya tidur) dan *false negative* (ayam aktif namun mengeluarkan suara megap-megap).

Secara bisnis, integrasi ini akan meningkatkan akurasi sistem dalam mendeteksi masalah kesehatan ayam secara dini. Hal ini sangat relevan untuk peternak komersial yang menangani ribuan ekor ayam: semakin cepat dan akurat deteksi dilakukan, semakin besar peluang mencegah penyebaran penyakit massal, menjaga konsistensi produksi, dan menghindari kerugian puluhan hingga ratusan juta rupiah per periode produksi.

5.4 Performa *Edge AI* Figures

Hasil pengujian menunjukkan bahwa sistem mampu berjalan secara optimal pada perangkat Edge AI seperti NVIDIA Jetson Nano dan Raspberry Pi, dengan latensi rendah dan efisiensi tinggi. Inferensi real-time memungkinkan sistem memberikan notifikasi langsung saat perilaku abnormal atau tanda-tanda penyakit terdeteksi.

Dari sisi bisnis, implementasi edge ini mengurangi kebutuhan akan koneksi internet stabil atau server cloud mahal. Ini membuka peluang adopsi teknologi bahkan di peternakan kecil atau daerah dengan infrastruktur terbatas. Selain itu, pemrosesan lokal menghindari keterlambatan yang bisa menjadi pembeda antara wabah yang terkendali dan kerugian massal. Sistem edge juga memberikan fleksibilitas skalabilitas, karena unit monitoring dapat ditambah sesuai pertumbuhan peternakan tanpa biaya pemrosesan terpusat yang tinggi.

6 Kesimpulan dan Saran

6.1 Kesimpulan

Sistem pemantauan peternakan ayam berbasis AI multi-modal yang diusulkan, mengintegrasikan *computer vision* (menggunakan Ultralytics YOLOv11s dan Motrackers) dan analisis suara, menunjukkan potensi besar untuk merevolusi manajemen peternakan. Hasil eksperimen awal mengkonfirmasi akurasi tinggi model YOLOv11s dalam deteksi dan pelacakan ayam, serta kemampuan model CNN dalam klasifikasi vokal. Pendekatan multi-modal ini, yang dirancang untuk diimplementasikan pada infrastruktur kamera yang ada dengan arsitektur *Edge AI*, memungkinkan deteksi dini penyakit dan anomali perilaku secara *real-time*.

Sistem ini tidak hanya berpotensi mengurangi kerugian ekonomi yang signifikan akibat penyakit dan mortalitas (seperti yang ditunjukkan oleh data kerugian ND dan CRD), tetapi juga meningkatkan efisiensi operasional, mengoptimalkan penggunaan sumber daya, dan meningkatkan kesejahteraan hewan. Dengan mengubah data mentah menjadi wawasan yang dapat ditindaklanjuti, solusi ini secara langsung mendukung tema "AI-Powered Business Insight & Action", memberdayakan peternak untuk membuat keputusan proaktif yang berdampak positif pada profitabilitas dan keberlanjutan usaha mereka.

6.2 Saran

Untuk pengembangan dan implementasi sistem yang lebih matang, beberapa saran berikut diajukan:

1. Ekspansi Dataset dan Robustness Model: Melakukan pengumpulan dataset visual dan audio yang jauh lebih besar dan beragam untuk meningkatkan akurasi dan generalisasi model, serta menerapkan teknik augmentasi data yang lebih agresif.
2. Validasi dan Evaluasi Kinerja Lapangan: Melakukan uji coba pilot skala penuh di peternakan komersial untuk mengevaluasi kinerja sistem dalam kondisi *real-world*, mengidentifikasi area perbaikan, serta mengumpulkan data dampak ekonomi.
3. Pengembangan Fitur Lanjutan: Mengembangkan identifikasi ayam individu yang lebih akurat, deteksi gejala penyakit yang lebih spesifik, dan kemampuan prediksi penyakit.
4. Optimalisasi *Edge AI* dan Integrasi Sistem: Melakukan kuantisasi model atau teknik *pruning* untuk mengoptimalkan ukuran dan kecepatan inferensi model agar berjalan lebih efisien pada perangkat *Edge* dengan sumber daya terbatas. Mengembangkan solusi integrasi yang mulus dengan berbagai jenis kamera CCTV dan mikrofon yang sudah ada di pasaran, serta mengembangkan aplikasi seluler dan dasbor web yang sangat intuitif dan mudah digunakan oleh peternak, dengan visualisasi data yang jelas dan notifikasi yang dapat disesuaikan.

References

[1] Direktorat Jenderal Peternakan dan Kesehatan Hewan. (2022). *Laporan Tahunan Direktorat Jenderal Peternakan dan Kesehatan Hewan Tahun 2021*. Kementerian Pertanian Republik Indonesia.

[2] Badan Pusat Statistik. (2022). *Statistik Peternakan dan Kesehatan Hewan 2021*. Badan Pusat Statistik.

[3] Alexander, D. J. (2000). Newcastle disease and other avian paramyxoviruses. *Revue Scientifique et Technique-Office International des Epizooties*, *19*(2), 443-462.

[4] Putri, D. A., Basri, C., & Wibawan, I. W. T. (2023). Prevalensi Newcastle Disease dan Perkiraan Kerugian Ekonomi pada Peternakan Ayam Broiler di Kabupaten Sukabumi. *Jurnal Sain Veteriner*, *41*(1), 83-93.

[5] Tabbu, C. R. (2019). *Penyakit Ayam dan Penanggulangannya: Penyakit Bakterial, Mikal, dan Viral* (Vol. 1). Kanisius.

[6] Ley, D. H. (2003). Mycoplasma gallisepticum infection. In *Diseases of poultry* (11th ed., pp. 722-744). Iowa State University Press.

[7] Gyles, C. L., Prescott, J. F., Songer, J. G., & Thoen, C. O. (Eds.). (2010). *Pathogenesis of bacterial infections in animals*. John Wiley & Sons.

[8] Redmon, J., Divvala, S., Girshick, R., & Farhadi, A. (2016). You only look once: Unified, real-time object detection. In *Proceedings of the IEEE conference on computer vision and pattern recognition* (pp. 779-788).

[9] Jocher, G., Chaurasia, A., & Qiu, J. (2023). *Ultralytics YOLOv8*. Diakses dari https://github.com/ultralytics/ultralytics

[10] Neethirajan, S. (2022). ChickTrack - A Quantitative Tracking Tool for Measuring Chicken Activity. Measurement, 191, 110819.

[11] Ahmed, M. M., Hassanien, E. E., & Hassanien, A. E. (2024). A smart IoT-based monitoring system in poultry farms using chicken behavioural analysis. Internet of Things, 25, 101010.

[12] Lv, J., Wang, J., Peng, C., & Huang, Q. (2023). DFCCNet: A Dense Flock of Chickens Counting Network Based on Density Map Regression. Animals (Basel), 13(23), 3729.

[13] Jon, A. (2023). *motrackers: Multi-Object-Tracker in Python*. Diakses dari https://github.com/Jonarod/motrackers

[14] Lin, H. T., Wang, W. J., & Lin, I. H. (2024). Deep Learning Methods for Tracking the Locomotion of Individual Chickens. *Animals*, *14*(12), 1735.

[15] Logan, B. (2000). Mel frequency cepstral coefficients for music modeling. In *International Symposium on Music Information Retrieval*.

[16] Dhattarwal, P., Bhanja, S. K., & Sahu, V. (2021). Automation and smart poultry farm management: A Review. Indian Journal of Poultry Science, 56(2), 89-99.