Otomatisasi Verifikasi Dini Klaim *Return–Refund* Multilingual pada *Marketplace* menggunakan *Early Fusion Multimodal Transformer*

Dastin Rangga Berani
Departemen Matematika
Universitas Indonesia
dstnrangga@gmail.com

Muhammad Fayyed As Shidqi
Fakultas Ilmu Komputer
Universitas Indonesia
fayyed76@gmail.com

Raihan Akbar
Fakultas Ilmu Komputer
Universitas Indonesia
akbarraihan2005@gmail.com

Abstract

Proses *return-refund* menjadi salah satu aspek penting dalam menjaga kepuasan konsumen. Kebijakan *return–refund* yang cepat dan tepat menjadi salah satu nilai jual bagi perusahaan *marketplace* yang tidak hanya mendorong loyalitas pelanggan, tetapi juga memacu peningkatan intensitas dan volume transaksi. Meski demikian, keterbukaan kebijakan ini juga dapat dimanfaatkan oleh oknum tidak bertanggung jawab untuk melakukan klaim palsu atau tidak valid. Klaim tidak valid tersebut dapat menyebabkan kerugian finansial dan juga bertambahnya beban operasional akibat verifikasi yang masih perlu dilakukan secara manual sepenuhnya. Dalam upaya untuk melakukan mitigasi penipuan dan mempersingkat proses verifikasi, penelitian ini memberikan inovasi berupa penggunaan model klasfikasi *multimodal transformer* dengan metode *early fusion*. Klasifikasi multimodal tersebut bertujuan untuk melakukan verifikasi dini klaim *return-refund* yang masuk secara otomatis. Dengan metrik akurasi dan dataset yang tim peneliti bangun, hasil dari implementasi model multimodal menunjukkan performa mencapai 88.43% (DINOv2 untuk citra + Qwen3 untuk teks) dan 89.81% (ResNet 50 untuk citra + Qwen3 untuk teks). Selain itu, penelitian ini juga menunjukkan bahwa pemanfaatan multimodalitas memberikan keunggulan performa (88.43%) dibandingkan hanya satu modalitas saja (46.76% untuk citra dan 87.96% untuk teks).

1 Pendahuluan

1.1 Latar Belakang

Dalam ekosistem *marketplace* seperti Shopee, Amazon, Tokopedia, Lazada, dan lainnya, mekanisme pengajuan *return–refund* merupakan salah satu aspek penting dalam menjaga kepuasan konsumen. Ketika konsumen menerima barang yang tidak sesuai harapan—baik dari segi kualitas, spesifikasi, maupun ketepatan pengiriman—mereka diberi hak untuk mengembalikan produk (*return*) atau memperoleh pengembalian dana (*refund*) [1]. Proses ini umumnya diawali dengan pengajuan permohonan *return–refund* melalui *platform*, verifikasi oleh penjual atau tim Customer Service (CS), pengambilan atau pengiriman balik barang oleh konsumen, inspeksi kondisi fisik produk, dan akhirnya pemrosesan *return–refund* pada konsumen. Kebijakan *return–refund* yang cepat dan tepat

menjadi salah satu nilai jual bagi perusahaan *marketplace* yang tidak hanya mendorong loyalitas konsumen, tetapi juga memacu peningkatan intensitas dan volume transaksi [2 3 4].

Meski demikian, keterbukaan kebijakan ini juga dapat dimanfaatkan oleh oknum tidak bertanggung jawab untuk melakukan klaim palsu. Pelaku mungkin sengaja merusak kemasan, mengirim barang berbeda, dan/atau memanipulasi bukti transaksi agar tampak layak dikembalikan. *Fraud* semacam ini merupakan fenomena yang terus berkembang dan menjadi tantangan besar bagi perusahaan. Menurut laporan Narvar 2024, terdapat 52% kasus *fraud return-refund* yang terjadi, meningkat 16% jika dibandingkan kasus di tahun 2023 [5]. Andaikan masalah ini dibiarkan, potensi kerugian yang ada sangat signifikan. Menurut laporan tahunan 2024 *Consumer Returns in the Retail Industry Report* yang diterbitkan oleh Appriss Retail dan Deloitte, *fraud return-refund* di industri ritel AS menyebabkan kerugian langsung sebesar $103 miliar USD bagi para *retailer* [6].

Selain kerugian finansial, beban operasional akibat klaim *return–refund* palsu juga sangat signifikan. Setiap klaim palsu di *marketplace* biasanya membutuhkan waktu verifikasi oleh penjual atau tim CS selama 15–20 menit. Jika jumlah klaim palsu mencapai ribuan per hari, total waktu yang terbuang dapat menembus ratusan jam kerja setiap bulan. Hal ini tidak hanya menurunkan efisiensi operasional dan meningkatkan biaya, tetapi juga berpotensi mengganggu kualitas layanan bagi pelanggan yang benar-benar membutuhkan bantuan. Padahal, waktu penanganan klaim *return-refund* merupakan hal yang krusial. Data dari laporan Narvar 2023 menunjukkan bahwa 47% pembeli menuntut pengembalian dana dalam waktu 24 jam dan 86% menganggap proses *return-refund* yang lambat sebagai alasan utama untuk tidak bertransaksi kembali. Menariknya, 62% konsumen bahkan bersedia membayar biaya kecil demi mendapatkan *return-refund* instan, membuka peluang keunggulan baru bagi pelaku *marketplace* yang inovatif [7].

Untuk mengatasi masalah tersebut, tim peneliti mengusulkan integrasi teknologi canggih yang memanfaatkan *Artificial Intelligence* dalam sistem pemrosesan klaim *return–refund* di *marketplace*. Tujuannya adalah menciptakan sistem yang dapat melakukan verifikasi dini terhadap klaim yang masuk secara otomatis. Dengan memanfaatkan model transformer state-of-the-art seperti DINOv2 (self-**DI**stillation with **NO** labels) untuk citra [8] dan Qwen3 Embedding untuk teks [9], data citra dan teks tersebut dapat direpresentasikan dengan sangat baik. Untuk menggabungkan kedua modalitas yang berada dalam ruang vektor berbeda ini, kami mengusulkan penggunaan metode *early fusion* dengan diikuti *classifier* berupa Gradient Boosting Tree [10]. Kombinasi ini diharapkan menciptakan sistem yang tidak hanya cepat tapi juga sangat akurat. Dengan adanya integrasi ini, diharapkan klaim palsu dapat diidentifikasi dengan akurasi tinggi dan waktu verifikasi manual oleh penjual atau tim CS dapat dipangkas, sehingga meningkatkan efektivitas mitigasi penipuan dan menurunkan biaya operasional secara substansial.

1.2 Manfaat dan Kontribusi

Secara praktis, fokus penelitian ini adalah pada peningkatan efisiensi dan akurasi sistem verifikasi klaim *return–refund* di *marketplace*. Dalam operasional harian, klaim palsu terhadap *return–refund* dapat menyebabkan kerugian finansial yang signifikan, baik berupa pengurangan stok barang maupun pengembalian dana yang tidak sah. Selain itu, verifikasi manual atas ribuan klaim setiap harinya membebani penjual atau tim Customer Service dan memperlambat waktu penyelesaian kasus, yang berdampak pada penurunan kepuasan pelanggan. Dengan mengusulkan penggunaan model *multimodal transformer*, penelitian ini bertujuan untuk menurunkan tingkat penipuan serta mengurangi beban waktu penanganan kasus oleh penjual atau tim CS, sehingga meningkatkan profitabilitas sekaligus efisiensi operasional. Solusi inovasi berbasis teknologi ini sekaligus juga secara praktis mendukung Sustainable Development Goals (SDGs) ke-9, terkhusus pada target 9.5 yang bertujuan meningkatkan pemanfaatan teknologi di sektor industri. [1]

Secara akademis, penelitian ini berupaya menjawab beberapa pertanyaan kunci berikut.

- Bagaimana pengaruh representasi fitur dari model *transformer* seperti DINOv2 (untuk citra) dan Qwen3 Embedding (untuk teks) terhadap performa klasifikasi klaim *return–refund* jika dibandingkan kombinasi model *transformer* dan konvensional lainnya?
- Bagaimana pengaruh perbedaan model Gradient Boosting yang digunakan dalam peningkatan akurasi klasifikasi klaim *return-refund*?

[1] https://globalgoals.org/goals/9-industry-innovation-and-infrastructure/

- Sejauh mana model multimodal (gabungan teks dan gambar) memberikan keunggulan dibandingkan pendekatan unimodal dalam tugas verifikasi klaim *return–refund*?

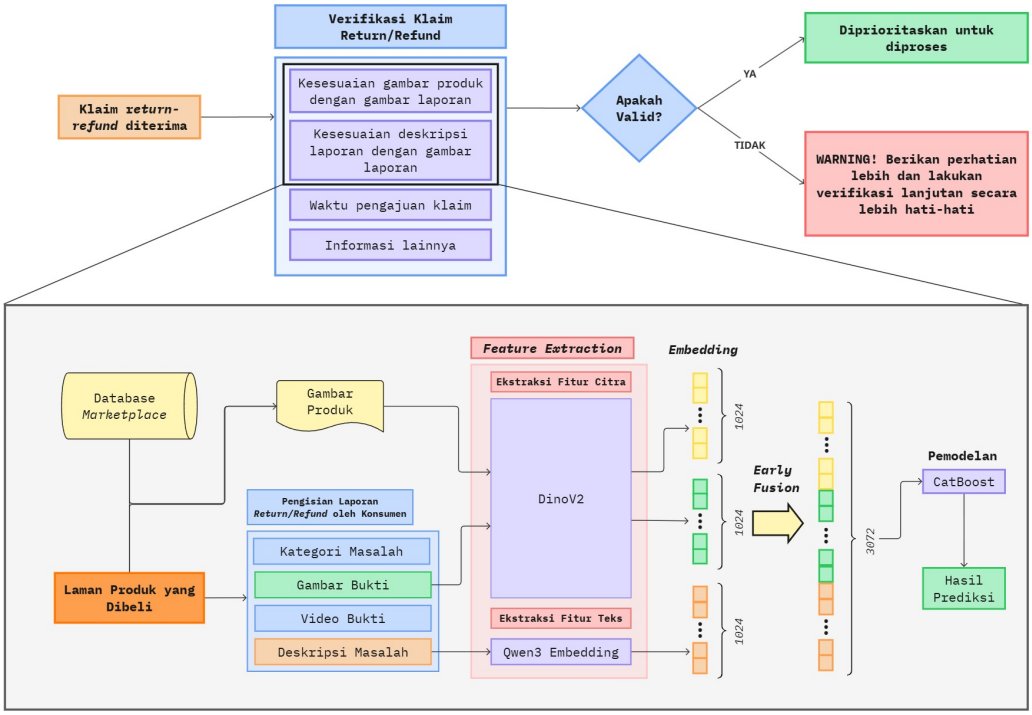
Penelitian ini diharapkan dapat memberikan kontribusi dalam kajian penerapan model multimodal pada domain *marketplace*, khususnya untuk menyelesaikan permasalahan verifikasi otomatis yang berdampak langsung pada efisiensi operasional dan mitigasi potensi *fraud*.

1.3 Batasan Penelitian

Pendekatan yang disajikan dalam studi ini memiliki beberapa keterbatasan yang perlu diperhatikan sebagai berikut.

- Informasi pada laporan klaim *return–refund* yang disertakan dalam prediksi hanya informasi berupa gambar produk, bukti masalah (berupa gambar) yang terdapat pada produk, dan deskripsi laporan.
- Seluruh proses pelatihan model mengasumsikan bahwa label "palsu" dan "valid" pada klaim *return–refund* telah diberikan dengan akurat.
- Hasil prediksi model pada praktisnya hanya digunakan sebagai indikasi awal apakah suatu klaim termasuk valid atau tidak, dengan keputusan akhir tetap ditentukan oleh penjual atau tim CS setelah diverifikasi lebih lanjut.

1.4 Simulasi Implementasi Model



Gambar 1: Alur implementasi model

Proses verifikasi klaim *return–refund* di *marketplace* dimulai segera setelah konsumen mengajukan *request* melalui laman produk yang dibeli. Dalam klaim *return-refund* tersebut, konsumen akan menyampaikan kategori masalah yang dialami, deskripsi masalah, serta melampirkan bukti berupa gambar dan video. Beberapa aspek yang perlu diperhatikan dalam verifikasi klaim *return–refund* adalah:

- Kesesuaian gambar produk dengan gambar bukti yang dilampirkan;
- Kesesuaian deskripsi laporan dengan gambar laporan dan/atau gambar bukti yang dilampirkan;
- Waktu pengajuan klaim;

- Informasi lainnya.

Keempat aspek di atas awalnya dilakukan secara manual oleh penjual atau tim CS. Namun, dengan implementasi model *transformer multimodal* yang dibangun, proses verifikasi ini (terkhusus pada dua poin pertama) dapat dilakukan secara otomatis. Perubahan ini secara praktis dapat memotong waktu verifikasi klaim secara signifikan, terutama di situasi terdapat sangat banyak klaim yang masuk.

Untuk mengimplementasikan model, deskripsi dan gambar bukti dari klaim yang masuk tadi akan digunakan. Secara paralel, *platform* juga mengambil gambar produk dari *database* internal *marketplace* untuk keperluan perbandingan dengan gambar bukti yang dilampirkan. Selanjutnya, semua gambar—baik gambar produk maupun gambar yang dilampirkan—dimasukkan ke dalam *encoder* DINOv2, yang mengubahnya menjadi vektor representasi (*embedding*) berdimensi 1024. Sementara itu, teks deskripsi masalah diubah menjadi *embedding* berdimensi 1024 juga menggunakan model Qwen3 Embedding. Ketiga vektor ini kemudian digabungkan melalui metode *Early Fusion*, menghasilkan *embedding* berukuran 3072.

Embedding hasil fusi tersebut kemudian menjadi input bagi model klasifikasi berbasis Gradient Boosting (CatBoost). Model akhirnya memberikan satu dari dua keputusan: "Valid", yang membuat klaim direkomendasikan untuk diprioritaskan, atau "Tidak Valid", yang memberi sinyal bagi penjual atau tim CS untuk melakukan verifikasi lanjutan manual yang lebih hati-hati.

Dengan implementasi model ini, durasi verifikasi klaim *return-refund* menjadi lebih ringkas. Selain itu, hasil prediksi dapat memberikan informasi mengenai klaim yang "perlu diperhatikan" sehingga dapat membantu dalam mitigasi perilaku *fraud* di ranah *return-refund* produk.

2 Studi Literatur

2.1 Verifikasi Dini Klaim *Return-Refund*

Beberapa penelitian telah dilakukan untuk mengatasi masalah penyalahgunaan sistem *return-refund*. Penelitian [11] mengembangkan model Logistic Regression berbasis Penalised Likelihood untuk mendeteksi indikasi awal *refund fraud*. Model yang diusulkan memungkinkan pelaku bisnis untuk mengidentifikasi 5% transaksi *refund* dengan kemungkinan *fraud* tertinggi dan mengantrekan transaksi tersebut untuk proses audit. Namun, penelitian tersebut masih terbatas pada data tabular tanpa mempertimbangkan bukti visual atau deskripsi naratif yang biasanya menjadi bagian penting dalam proses *return-refund*, terutama untuk produk yang cacat fisik atau berbeda dari deskripsi.

Lebih lanjut, penelitian [12] menggunakan pendekatan multimodal *contrastive learning* untuk mendeteksi *click fraud*, dengan menggabungkan fitur teks, gambar, dan perilaku pengguna. Model tersebut menunjukkan performa yang unggul dalam mendeteksi anomali, dan menunjukkan potensi besar dalam penanganan *fraud* yang kompleks. Meskipun konteksnya berbeda (*click fraud*), pendekatan multimodal yang digunakan menjadi inspirasi langsung untuk kasus verifikasi dini *return-refund*.

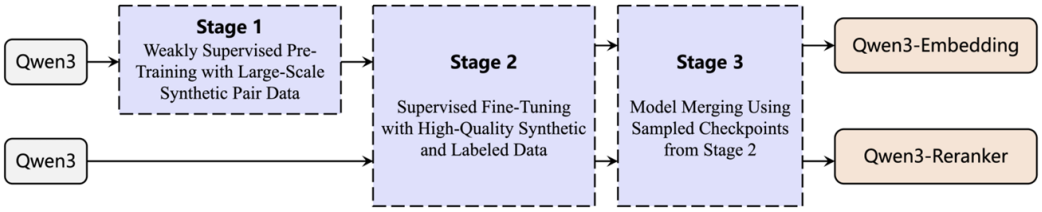
Hal ini menunjukkan adanya celah dalam penelitian terdahulu bahwa belum ada pendekatan yang secara eksplisit menggabungkan input teks dan gambar dari konsumen untuk memverifikasi validitas klaim *return-refund* secara otomatis.

2.2 Representasi Teks

Model berbasis *Recurrent Neural Network* (RNN) [13] dan *Long Short-Term Memory* (LSTM) [14] awalnya populer untuk pemrosesan bahasa alami, akan tetapi keduanya memiliki kekurangan. RNN kesulitan mempertahankan konteks dalam urutan teks yang panjang. Sedangkan, LSTM dengan sel memori yang dirancang untuk menyimpan informasi jangka panjang dan jangka pendek, berhasil mengatasi sebagian kelemahan ini. Akan tetapi, kompleksitas komputasinya yang tinggi menjadi hambatan yang signifikan, terutama pada skala besar [15 16].

Sementara itu, model berbasis Transformer seperti Bidirectional Encoder Representations (BERT) [17] dan Generative Pretraining Transformer (GPT) [18] telah merevolusi bidang pemrosesan bahasa alami dengan menerapkan mekanisme *self-attention* yang memungkinkan pemodelan hubungan kompleks antarkata secara paralel pada korpus berskala besar. Seiring waktu, berbagai arsitektur

model transformer mulai berkembang, dengan di antaranya seperti Jina Embeddings [19] dan Multilingual E5 [20] yang terbukti sangat efektif dalam uji benchmark seperti Massive Text Embedding Benchmark (MTEB) [21], mendukung pemrosesan teks multilingual dengan optimal.

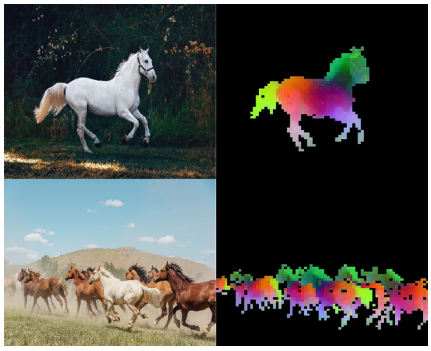


Gambar 2: *Training pipeline* untuk model Qwen3. Sumber: [9].

Model Qwen3 Embedding. Qwen3 Embedding adalah model embedding teks state-of-the-art yang mencapai kinerja tinggi dalam tugas-tugas representasi teks. Model ini dilatih dengan beberapa tahap seperti yang terlihat pada gambar 2. Detailnya, model dilatih dengan *weakly-supervised pre-training* dari dataset besar pasangan teks dan juga dengan *supervised fine-tuning* dari data sintesis berlabel berkualitas tinggi. Model mampu menghasilkan vektor representasi tunggal yang kuat untuk pengambilan informasi, pengelompokan, dan klasifikasi. Salah satu varian terkemuka dari Qwen3 adalah `Qwen3-Embedding-8B`, yang per 5 Juni 2025 menduduki peringkat teratas pada Massive Text Embedding Benchmark (MTEB) *leaderboard*. Sebagai alternatif, Qwen3 juga menyediakan varian lainnya yang jauh lebih ringan tetapi tetap memiliki performa yang mumpuni, yakni `Qwen3-Embedding-0.6B` [9].

2.3 Representasi Citra

Residual Network (ResNet) merupakan arsitektur CNN yang populer karena koneksi residualnya yang memungkinkan pelatihan jaringan yang dalam dan efektif dalam mengekstraksi fitur visual secara hierarkis [22]. Namun, karena sifat operasinya yang lokal, ResNet kurang optimal dalam menangkap hubungan spasial global. Untuk mengatasi hal ini, Vision Transformer (ViT) diperkenalkan dengan membagi citra menjadi patch yang diproses sebagai token melalui mekanisme *self-attention*, mirip dengan pendekatan pada pemrosesan teks [23]. ViT memungkinkan pemahaman spasial yang lebih menyeluruh dan terbukti unggul untuk tugas-tugas kompleks dan multimodal. Kedua model ini, setelah dilatih pada ImageNet [24], menghasilkan representasi citra yang kuat dan banyak digunakan dalam berbagai aplikasi lanjutan.



Gambar 3: Hasil PCA 3 komponen model DINOv2. Sumber: [6].

Model DINOv2. DINOv2 merupakan model yang menerapkan *self-supervised learning* untuk melatih ViT dengan memecah citra menjadi bagian-bagian kecil, sebagaimana pada Gambar 3. Terlihat bahwa setiap komponen memiliki warna tertentu, contohnya kepala yang sama-sama berwarna hijau. Strategi ini memungkinkan ViT untuk memahami tiap segmen gambar secara terpisah serta mempelajari keterkaitan antar bagiannya. Melalui metode *self-supervised learning* ini, DINOv2 dapat dilatih secara efisien menggunakan data tanpa label, sehingga menghasilkan representasi citra yang lebih umum dan adaptif [8]. DINOv2 juga menunjukkan performa yang unggul pada *benchmark* ImageNet, baik dalam skenario *self-supervised* maupun setelah *fine-tuning*, yang menegaskan kemampuannya dalam menghasilkan representasi citra dengan sangat baik.

2.4 Penggabungan Teks dan Citra dengan *Early Fusion*

Beberapa tugas yang cukup kompleks umumnya membutuhkan pemahaman konteks multimodal agar dapat memperoleh peningkatan performa. Karena setiap vektor representasi (*embedding*) dari tiap modalitas berada di ruang vektor yang berbeda, maka diperlukan suatu metode yang dapat menggabungkan informasi dari kedua modalitas tersebut. Salah satu pendekatan umum yang digunakan adalah *Early Fusion*, di mana vektor representasi dari modalitas teks dan citra digabungkan (*concat*) pada tahap awal sebelum dimasukkan ke dalam model prediktif. Pendekatan ini telah menunjukkan efektivitasnya dalam berbagai studi sebelumnya [25 26 27 28].

3 Metodologi

3.1 Dataset

Dalam penelitian ini, kami menggunakan dataset yang dikonstruksi secara mandiri karena data klaim *return-refund* pada *marketplace* merupakan bagian dari informasi yang bersifat pribadi dan sensitif, sehingga tidak tersedia secara publik. Untuk mengatasi keterbatasan akses terhadap data aktual, kami menyusun dataset simulatif yang mencerminkan struktur dan karakteristik laporan secara realistis dengan pendekatan berbasis multimodal.

Dataset ini terdiri dari tiga komponen utama, yaitu gambar produk, gambar laporan (foto bukti dari pelanggan), dan deskripsi teks laporan seperti pada Tabel 1. Gambar produk dikumpulkan melalui proses *web scraping* dari halaman utama produk di *platform* Tokopedia, yang menampilkan visual standar dari barang yang dijual. Sementara itu, gambar laporan diperoleh dari bagian ulasan pelanggan, di mana pengguna biasanya mengunggah foto kondisi produk yang diterima, termasuk produk yang rusak, cacat, atau berbeda dari yang dipesan.

Tabel 1: Struktur dataset untuk verifikasi klaim *return-refund*

Gambar Produk	Gambar Laporan	Deskripsi Laporan	Valid
		minta refund dong. pas pegang kaos ini, bahan langsung kusut dan gambar juga mulai luntur. kualitas sangat jelek.	1
		mohon refund. saat foto selfie pakai baju ini, baru ketahuan ada lubang kecil di beberapa tempat.	0

Untuk memperoleh deskripsi teks laporan pelanggan, kami menggunakan pendekatan *captioning* berbasis model BLIP (Bootstrapped Language Image Pretraining) [29] yang dikombinasikan dengan model Claude [30] untuk menghasilkan narasi keluhan yang menyerupai gaya bahasa konsumen asli. BLIP menghasilkan *caption* deskriptif berdasarkan konten visual dari gambar laporan, lalu diproses lebih lanjut oleh Claude untuk membentuk teks laporan yang lebih natural dan naratif. Untuk lebih menyerupai kondisi sebenarnya, deskripsi laporan yang di-*generate* bersifat multilingual.

Secara keseluruhan, kami mengumpulkan sebanyak 1000 sampel data dari berbagai kategori produk, seperti buku, alat elektronik, kosmetik, mainan, perlengkapan rumah tangga, sepatu, tas, dan pakaian. Kategori-kategori ini dipilih karena memiliki keragaman visual tinggi dan tergolong produk dengan tingkat pengembalian yang cukup besar.

Untuk proses *labeling*, kami melakukan *labeling* secara manual dengan aturan bahwa klaim akan dikatakan tidak valid jika memenuhi setidaknya salah satu dari poin berikut.

- Gambar produk dengan bukti gambar yang dilampirkan tidak sesuai (tetapi tetap diberi ”valid” jika deskripsi laporannya adalah ”barang yang dikirimkan salah”).
- Deskripsi dari laporan aneh atau tidak sesuai dengan bukti gambar dan/atau gambar produk.

Misalnya saja *instance* pada baris kedua di tabel 1 diberikan label ”tidak valid” karena antara gambar produk yang dipesan dan gambar produk yang dilampirkan pada laporan berbeda.

3.2 Metrik

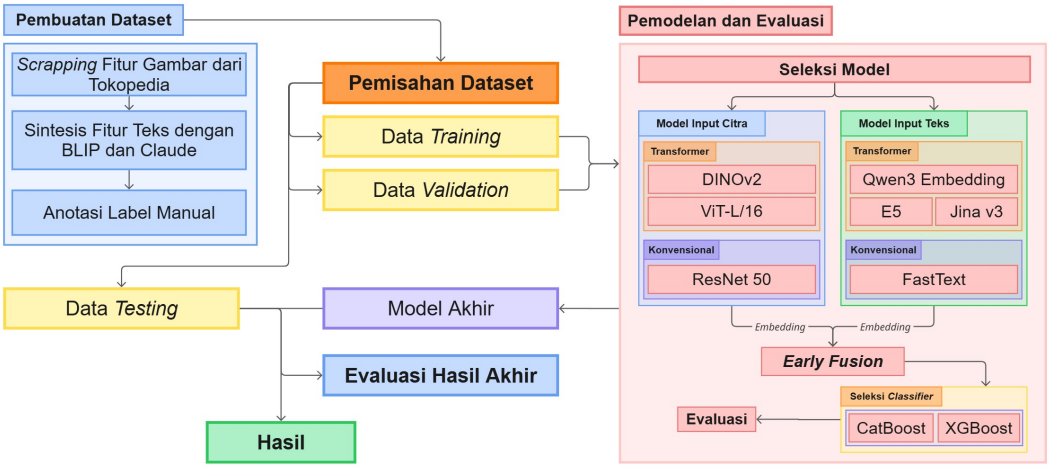
Dalam penelitian ini, akurasi dipilih sebagai metrik evaluasi utama untuk mengukur performa model klasifikasi pada tugas verifikasi klaim *return-refund*. Pemilihan metrik ini didasarkan pada asumsi bahwa setiap klaim memiliki tingkat kepentingan yang setara, baik klaim tersebut valid maupun tidak valid. Akurasi (*accuracy*) dihitung sebagai rasio antara jumlah klaim yang diklasifikasikan dengan benar (P) terhadap total seluruh klaim yang diuji (N), seperti dirumuskan pada Persamaan (1):

$$\text{Accuracy} = \frac{P}{N} \tag{1}$$

Penggunaan akurasi memberikan evaluasi yang sederhana dan menyeluruh terhadap kinerja model dalam mengklasifikasikan klaim dengan benar, tanpa memberikan bobot yang berbeda pada klaim valid ataupun tidak valid. Hal ini sesuai dengan kebutuhan sistem otomatis verifikasi *return-refund*, yang menuntut konsistensi dan keakuratan dalam keputusan klasifikasi secara keseluruhan. Meskipun distribusi kelas pada data klaim bisa saja tidak seimbang, akurasi tetap relevan karena fokus utamanya adalah pada kinerja agregat model dalam menangani kedua jenis klaim secara adil dan proporsional.

3.3 Alur Penelitian

Alur eksperimen yang dilakukan oleh peneliti dapat dilihat pada Gambar 4.



Gambar 4: Diagram Alur Eksperimen

Pertama-tama kami melakukan pengumpulan dan persiapan dataset seperti yang dijelaskan pada bagian 3.1. Setelahnya, kami mengeksplorasi berbagai kombinasi arsitektur untuk pembentukan vektor *embedding* sebagai representasi teks dan citra seperti yang disebutkan pada bagian 2.2 dan 2.3. Untuk input citra, model yang diuji mencakup DINOv2, ViT-L/16, dan ResNet 50. Sedangkan untuk input teks, model yang diuji meliputi Qwen3 Embedding, Jina v3, Multilingual E5, dan FastText. Vektor *Embedding* dari setiap model—baik konvensional maupun transformer—kemudian digabungkan (*Early Fusion*) menjadi satu vektor representasi multimodal yang akan digunakan sebagai input ke dalam model klasifikasi berbasis Gradient Boosting (CatBoost dan XGBoost). Akhirnya, performa setiap kombinasi model dievaluasi menggunakan data *testing* dan metrik akurasi, sehingga dapat dipilih model akhir dengan hasil terbaik.

3.4 Spesifikasi Model

Tabel 2 berikut adalah detail varian model yang akan diuji. Semua model tersebut merupakan *open source model* yang dapat diakses melalui Hugging Face. [2]

Tabel 2: Detail Model *Encoder*

Nama Model	Modalitas	Model Checkpoint
ResNet50	Citra	`microsoft/resnet-50`
ViT-L/16	Citra	`google/vit-large-patch16-224-in21k`
DINOv2	Citra	`facebook/dinov2-large`
FastText	Teks	`facebook/fasttext-id-vectors`
Jina v3	Teks	`jinaai/jina-embeddings-v3`
Multilingual E5	Teks	`intfloat/multilingual-e5-large-instruct`
Qwen3	Teks	`Qwen/Qwen3-Embedding-0.6B`

4 Hasil Eksperimen dan Analisis

4.1 Perbandingan Model Multimodal

Pada fase awal penelitian, kami berangkat dengan hipotesis bahwa performa model berbasis transformer akan memiliki performa yang selalu lebih baik dibanding model konvensional. Oleh karena itu, kami memanfaatkan kombinasi dari model-model konvensional sebagai *baseline*. Selanjutnya, untuk meningkatkan kinerja, dilakukan serangkaian eksperimen menggunakan arsitektur berbasis transformer. Hasil akurasi pelatihan menggunakan pendekatan Early Fusion dengan diikuti model CatBoost dan XGBoost disajikan pada Tabel 3 berikut.

Tabel 3: Perbandingan Akurasi Model

Model Multimodal	Akurasi CatBoost	Akurasi XGBoost
ResNet 50 & FastText	0.8657	0.8380
ResNet 50 & Jina v3	0.8333	0.7963
ResNet 50 & Multilingual E5	0.8148	0.8287
ResNet 50 & Qwen3	0.8611	**0.8981**
ViT-L/16 & FastText	0.8148	0.8519
ViT-L/16 & Jina v3	0.8009	0.7963
ViT-L/16 & Multilingual E5	0.8287	0.8426
ViT-L/16 & Qwen3	0.8657	0.8889
DINOv2 & FastText	0.8657	0.8333
DINOv2 & Jina v3	0.8241	0.8009
DINOv2 & Multilingual E5	0.8333	0.8194
DINOv2 & Qwen3	**0.8843**	0.8333

Hasil di atas memperlihatkan bahwa hipotesis kami sebelumnya tak sepenuhnya tepat. Model-model konvensional, seperti multimodal ResNet dengan FastText, tidak kalah bersaing dengan model-model transformer yang ada. Bahkan, model konvensional seperti FastText selalu memiliki skor akurasi yang lebih baik dibandingkan model transformer Jina v2. Meski demikian, model FastText masih tidak lebih baik jika dibandingkan model SoTA seperti Qwen3. Di sisi lain, ResNet 50 memiliki performa yang hampir serupa dengan model *encoder* citra lainnya.

[2] https://huggingface.co/

Secara khusus, penggunaan model multimodal DINOv2 bersama Qwen3 menghasilkan akurasi tertinggi pada *classifier* CatBoost sebesar 0.8843. Sedangkan, penggunaan model multimodal ResNet 50 bersama Qwen3 menghasilkan akurasi tertinggi pada *classifier* XGBoost sebesar 0.8981. Ini mengungkap bahwa representasi teks dari Qwen3 secara konsisten lebih baik dibandingkan representasi teks dari model lainnya, sebagaimana telah dibahas pada bagian 2.2. Adapun untuk representasi gambar, berbagai varian model yang diuji tidak ada yang dominan dan cenderung memiliki performa yang hampir serupa.

Selain itu, kami tertarik untuk memeriksa *classifier* mana di antara CatBoost dan XGBoost yang lebih tepat untuk digunakan pada *task* ini. Untuk perbandingan yang lebih objektif, kami membandingkan akurasi dari kedua model tersebut dengan uji statistik, yakni dengan Wilcoxon signed-rank test yang tidak mengasumsikan normalitas data. Hasilnya, diperoleh *p-value* = 0.6221 $>$ 0.05. Artinya, hipotesis *null* ditolak dan dapat disimpulkan tidak ada perbedaan signifikan antara performa CatBoost dan XGBoost.

4.2 *Ablation Test*

Pada bagian ini, peneliti melakukan serangkaian eksperimen untuk mengevaluasi kontribusi masing-masing modalitas—teks dan citra—terhadap kinerja model. Tabel 4 menyajikan hasil dari *modality ablation test*, yang menguji dua jenis modalias utama: citra dan teks. Model berbasis citra, DINOv2, memperoleh akurasi yang hanya sebesar 0.4676, sedangkan model berbasis teks, Qwen3 Embedding, dapat mencapai akurasi hingga 0.8796. Ketika kedua modalitas dikombinasikan dalam model DINOv2 + Qwen3, akurasi meningkat menjadi 0.8843. Hasil ini menunjukkan bahwa integrasi informasi visual dan tekstual mampu memberikan peningkatan performa yang signifikan dibandingkan penggunaan salah satu *modality* secara terpisah.

Tabel 4: *Modality Ablation Test*

Model	**Accuracy**
Dinov2	0.4676
Qwen3	0.8796
DINOv2 & Qwen3	**0.8843**

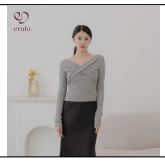
Menariknya, penggunaan modalitas teks saja dapat mencapai skor yang hampir serupa. Ini menunjukkan potensi model unimodal dengan modalitas teks, sekaligus juga mempertegas keandalan Qwen3 dalam menciptakan representasi teks yang sangat baik. Sedangkan, penggunaan modalitas gambar saja memiliki akurasi yang sangat buruk sehingga sangat perlu diperbaiki dengan penambahan modalitas teks.

4.3 Analisis Error

Pada bagian ini, peneliti akan menganalisis kesalahan klasifikasi yang terjadi saat hanya menggunakan satu modalitas serta bagaimana kesalahan tersebut dapat diperbaiki dengan menggunakan kedua modalitas secara sekaligus.

Pertama, untuk kesalahan prediksi pada kasus unimodal dengan modalitas teks, perhatikan tabel 5 berikut.

Tabel 5: Contoh *error* ketika hanya menggunakan data teks

Gambar Produk	**Gambar Laporan**	**Deskripsi Laporan**
		Saya ingin refund baju dengan label ini. Barang nyata berbeda dengan foto display produk.

Groundtruth untuk sampel pada Tabel 5 adalah 'valid' karena dapat dilihat bahwa deskripsi laporan sudah sesuai, dengan menyatakan bahwa barang yang diperoleh berbeda dengan foto *display* produk.

Model yang hanya menggunakan fitur teks mengklasifikasikan data sebagai 'tidak valid', sedangkan model yang menggunakan kedua modality berhasil mengklasifikasikan data tersebut dengan benar sebagai 'valid'. Hal ini menunjukkan bahwa informasi dari teks saja terkadang kurang memadai, terutama ketika deskripsinya bersifat ambigu. Dalam kasus seperti ini, tambahan konteks modalitas citra menjadi krusial untuk membantu menghasilkan klasifikasi yang lebih akurat.

Selanjutnya, untuk kesalahan prediksi pada kasus unimodal dengan modalitas citra, perhatikan tabel 6 berikut.

Tabel 6: Contoh *error* ketika hanya menggunakan data citra

Gambar Produk	Gambar Laporan	Deskripsi Laporan
		Mohon refund segera. Baju yang dikirim berbeda dengan gambar yang ditampilkan di website.

Groundtruth untuk sampel pada Tabel 6 adalah 'valid' karena dapat dilihat bahwa memang benar baju yang ada di *website* cukup berbeda dengan yang diterima konsumen. Masalahnya, ketika menggunakan informasi dari citra saja, model mengenalinya sebagai barang yang berbeda sehingga berpotensi untuk diklasifikasikan sebagai 'tidak valid'. Akan tetapi, informasi deskripsi laporan akan memberikan konteks atau informasi tambahan yang membuat model multimodal berhasil mengklasifikasikan data tersebut dengan benar sebagai 'valid'. Sekali lagi, hal ini menunjukkan bahwa terkadang informasi dari satu modalitas saja tidak cukup sehingga perlu konteks tambahan dari modalitas lainnya.

Terakhir, tim peneliti tertarik untuk memeriksa alasan di balik sulitnya penggunaan model unimodal pada modalitas citra seperti yang ditunjukkan pada tabel 4. Untuk memeriksanya, kami menggunakan informasi visual PCA 3 komponen dari model DINOv2.

Tabel 7: Hasil transformasi PCA 3 komponen

Gambar Produk	PCA Produk	Gambar Laporan	PCA Laporan
			

Dari visualisasi di atas, dapat diketahui bahwa model seringkali salah mengenali segmen gambar akibat banyaknya *noise* yang ada pada gambar. Sebagai contoh, di gambar laporan pada tabel 7, segmen citra yang berupa rak ditandai dengan warna merah. Masalahnya, model tidak mampu mengenali segmen rak yang ada di gambar produk. Segmen citra berwarna merah di gambar produk malah dikenai pada objek *noise* yang hadir. Kesalahan-kesalahan seperti ini membuat model tidak mengenali keduanya sebagai rak yang sama, sehingga dapat mengarah ke kesalahan prediksi berupa 'tidak valid'.

5 Penutup

5.1 Kesimpulan

Hasil eksperimen menunjukkan bahwa kombinasi representasi teks dari Qwen3 Embedding dan representasi citra dari DINOv2 menghasilkan performa terbaik jika dibandingkan kombinasi model transformer dan konvensional lainnya, dengan akurasi tertinggi sebesar 88.43% di *classifier* CatBoost. Sedangkan, model multimodel Qwen3 dengan ResNet 50 memberikan akurasi terbaik sebesar 89.81% di *classifier* XGBoost. Hasil eksperimen juga menunjukkan bahwa tidak terdapat perbedaan yang signifikan antara model konvensional dengan model berbasis transformer. Meski demikian, model SoTA berbasis transformer seperti Qwen3 dan DINOv2 secara konsisten menunjukkan stabilitas performa. Untuk *classifier* yang dibandingkan adalah model Gradient Boosting Tree berupa CatBoost dan XGBoost. Keduanya memiliki performa yang memuaskan, meskipun secara statistik tidak ada perbedaan yang signifikan.

Selain itu, hasil *ablation test* menunjukkan penggabungan dua modalitas (teks dan citra) mampu meningkatkan akurasi model jika dibandingkan pendekatan unimodal. Berdasarkan analisis *error*, dapat diketahui bahwa untuk melakukan verifikasi klaim *return-refund* secara lebih tepat, seringkali diperlukan pemahaman konteks multimodal sehingga metode unimodal saja tidak cukup. Melalui analisis *error* juga dapat diketahui bahwa informasi citra sangat rentan mengandung *noise* yang menjelaskan sangat buruknya performa model unimodal dengan modalitas citra. Sebagai penutup, pendekatan ini menunjukkan potensi besar untuk diterapkan secara praktis pada sistem verifikasi dini otomatis di *platform marketplace* guna memangkas waktu verifikasi manual serta meningkatkan efektivitas mitigasi penipuan.

5.2 Saran

Berdasarkan hasil penelitian, pendekatan multimodal menggunakan representasi citra dan teks terbukti efektif dalam memverifikasi dini klaim *return–refund* secara otomatis. Namun, terdapat beberapa aspek yang dapat dikembangkan lebih lanjut untuk meningkatkan akurasi dan generalisasi model. Pertama, penggunaan *domain-specific pretraining* atau *fine-tuning* pada model *encoder* dapat dipertimbangkan agar representasi yang dihasilkan lebih sesuai dengan karakteristik bahasa dan visual khas industri *marketplace*.

Selain itu, kualitas dataset yang digunakan masih menjadi salah satu keterbatasan utama, mengingat seluruh data dikonstruksi secara mandiri melalui proses *scraping* dan generasi otomatis. Proses tersebut dapat menghasilkan *noise* atau ketidaksesuaian. Untuk itu, disarankan adanya kerja sama langsung dengan *platform marketplace* atau penyedia layanan *e-commerce* guna memperoleh data klaim *return–refund* yang autentik, beranotasi akurat, serta mencerminkan variasi kasus yang lebih kaya dan sesuai keadaan sebenarnya.

References

[1] D. Laxhminarayan, Growing trends of e-commerce and its role in consumers buying pattern, *International Journal of Marketing, Financial Services & Management Research*, vol. 1, no. 10, pp. 200–209, 2012.

[2] K. Hjort and B. Lantz, The impact of returns policies on profitability: a fashion e-commerce case, *Journal of Business Research*, vol. 69, no. 11, pp. 4980–4985, 2016, doi: 10.1016/j.jbusres.2016.04.064.

[3] G. dos Santos and E. Koromyslova, A review on returnless refunds in e-commerce retailing: sales through leniency, *iBusiness*, vol. 12, pp. 69–80, 2020, doi: 10.4236/ib.2020.122005.

[4] S. Zhao, A review of the multidimensional impact of return policies on pricing strategies, retailers, and consumer pricing strategies, in *Proceedings of the 2024 2nd International Conference on Economic Management, Financial Innovation and Public Service (EMFIPS 2024), Advances in Economics, Business and Management Research*, vol. 327, P. Dou and K. Zhang, Eds., Atlantis Press, 2025, pp. 426–448, doi: 10.2991/978-94-6463-706-9_39.

[5] Narvar, Narvar state of returns 2024 report highlights growing impact of returns on retail margins and customer loyalty, *PR Newswire*, 2024. URL https://www.prnewswire.com/news-

releases/narvar-state-of-returns-2024-report-highlights-growing-impact-of-returns-on-retail-margins-and-customer-loyalty-302227590.html.

[6] Appriss Retail and Deloitte, 2024 Consumer returns in the retail industry report, *Appriss Retail*, Irvine, CA, USA, Feb. 2025. URL https://apprissretail.com/resources/2024-consumer-returns-report/

[7] Narvar, Defending margins, boosting profits: Narvar's new study reinvents the returns narrative, emphPR Newswire, 2023. URL https://www.prnewswire.com/news-releases/defending-margins-boosting-profits-narvars-new-study-reinvents-the-returns-narrative-301928073.html.

[8] M. Oquab, T. Darcet, T. Moutakanni, H. Vo, M. Szafraniec, V. Khalidov, P. Fernandez, D. Haziza, F. Massa, A. El-Nouby, M. Assran, N. Ballas, W. Galuba, R. Howes, P.Y. Huang, S.W. Li, I. Misra, M. Rabbat, V. Sharma, G. Synnaeve, H. Xu, H. Jegou, J. Mairal, P. Labatut, A. Joulin, and P. Bojanowski. Dinov2: Learning robust visual features without supervision, 2024.

[9] Y. Zhang, M. Li, D. Long, X. Zhang, H. Lin, B. Yang, P. Xie, A. Yang, D. Liu, J. Lin, F. Huang, and J. Zhou, Qwen3 embedding: Advancing text embedding and reranking through foundation models, *arXiv preprint arXiv:2506.05176*, 2025.

[10] J. H. Friedman, Greedy function approximation: A gradient boosting machine, *Annals of statistics*, vol. 29, no. 5, pp. 1189–1232, 2001.

[11] S. John, B. J. Shah, and P. Kartha, Refund fraud analytics for an online retail purchases, *Journal of Business Analytics*, vol. 3, no. 1, pp. 56–66, 2020, doi: 10.1080/2573234X.2020.1776164.

[12] W. Li, Q. Zhong, Q. Zhao, H. Zhang, and X. Meng, Multimodal and contrastive learning for click fraud detection, *arXiv preprint arXiv:2105.03567*, 2021.

[13] D. E. Rumelhart, G. E. Hinton, and R. J. Williams, Learning representations by back-propagating errors, *Nature*, vol. 323, no. 6088, pp. 533–536, Jan. 1986, doi: 10.1038/323533a0.

[14] Sepp Hochreiter and Jürgen Schmidhuber. Long short-term memory. *Neural computation*, vol. 9, no. 8, pp. 1735–1780, Nov. 1997.

[15] P. Bojanowski, E. Grave, A. Joulin, and T. Mikolov. Enriching word vectors with subword information. *arXiv preprint arXiv:1607.04606*, 2016.

[16] T. Mikolov, K. Chen, G. Corrado, and J. Dean. Efficient estimation of word representations in vector space. *arXiv preprint arXiv:1301.3781*, 2013.

[17] J. Devlin, M.-W. Chang, K. Lee, and K. Toutanova. Bert: Pre-training of deep bidirectional transformers for language understanding, 2019.

[18] T. B. Brown, B. Mann, N. Ryder, M. Subbiah, J. Kaplan, P. Dhariwal, A. Neelakantan, P. Shyam, G. Sastry, A. Askell, S. Agarwal, A. Herbert-Voss, G. Krueger, T. Henighan, R. Child, A. Ramesh, D. M. Ziegler, J. Wu, C. Winter, C. Hesse, M. Chen, E. Sigler, M. Litwin, S. Gray, B. Chess, J. Clark, C. Berner, S. McCandlish, A. Radford, I. Sutskever, and D. Amodei. Language models are few-shot learners, 2020.

[19] S. Sturua, I. Mohr, M. K. Akram, M. Günther, B. Wang, M. Krimmel, F. Wang, G. Mastrapas, A. Koukounas, N. Wang, and H. Xiao, jina-embeddings-v3: Multilingual embeddings With task LoRA, *arXiv preprint arXiv:2409.10173*, Sep. 2024.

[20] L. Wang, N. Yang, X. Huang, L. Yang, R. Majumder, and F. Wei. Multilingual e5 text embeddings: a technical report, 2024.

[21] N. Muennighoff, N. Tazi, L. Magne, and N. Reimers. MTEB: Massive text embedding benchmark. In A. Vlachos and I. Augenstein, editors, *Proceedings of the 17th Conference of the European Chapter of the Association for Computational Linguistics*, pages 2014–2037, Dubrovnik, Croatia, May 2023. Association for Computational Linguistics. doi:10.18653/v1/2023.eacl-main.148. URL https://aclanthology.org/2023.eacl-main.148.

[22] K. He, X. Zhang, S. Ren, and J. Sun. Deep residual learning for image recognition, 2015.

[23] A. Dosovitskiy, L. Beyer, A. Kolesnikov, D. Weissenborn, X. Zhai, T. Unterthiner, M. Dehghani, M. Minderer, G. Heigold, S. Gelly, J. Uszkoreit, and N. Houlsby. An image is worth 16x16 words: Transformers for image recognition at scale, 2021.

[24] J. Deng, W. Dong, R. Socher, L.J. Li, K. Li, and L. Fei-Fei. Imagenet: A large-scale hierarchical image database. In *2009 IEEE Conference on Computer Vision and Pattern Recognition*, pages 248–255, 2009. doi: 10.1109/CVPR. 2009.5206848.

[25] A. Radford, J. W. Kim, C. Hallacy, A. Ramesh, G. Goh, S. Agarwal, G. Sastry, A. Askell, P. Mishkin, J. Clark, G. Krueger, and I. Sutskever. Learning transferable visual models from natural language supervision, 2021.

[26] K. Gadzicki, R. Khamsehashari, and C. Zetzsche. Early vs late fusion in multimodal convolutional neural networks. In *2020 IEEE 23rd international conference on information fusion (FUSION)*, pages 1–6. IEEE, 2020.

[27] H. Gunes and M. Piccardi. Affect recognition from face and body: early fusion vs. late fusion. In *2005 IEEE international conference on systems, man and cybernetics*, volume 4, pages 3437–3443. IEEE, 2005.

[28] C. G. Snoek, M. Worring, and A. W. Smeulders. Early versus late fusion in semantic video analysis. In *Proceedings of the 13th annual ACM international conference on Multimedia*, pages 399–402, 2005.

[29] J. Li, D. Li, C. Xiong, and S. Hoi, BLIP: Bootstrapping language-image pre-training for unified vision-language understanding and generation, *arXiv preprint arXiv:2201.12086*, 2022.

[30] Anthropic, The Claude 3 model family: Opus, Sonnet, Haiku, *Anthropic, Technical Report*, Mar. 2024. URL `https://paperswithcode.com/paper/the-claude-3-model-family-opus-sonnet-haiku`