Ulasin: Menjembatani Ulasan Pelanggan Berbahasa Indonesia Informal menjadi Prioritas Tindakan Berbukti bagi Penjual Mikro

Tim BPS (Bawa Pulang Sasuke) · Smart Commerce

Timotius Christopher Patrick Sihombing · Mikael Alexander Adikara Purnama
Raphael Angelo Adikara Purnama · Bonfilio Renato Lawaziduhu Fau · Adinda Sekaring Wana

Abstrak*—Sebuah toko fesyen di Shopee menerima 66 ulasan antara Oktober 2025 dan Agustus 2026 dengan rata-rata 2,88 bintang. Pemiliknya membaca beberapa yang teratas. Yang tidak pernah terbaca: 13 pembeli mengeluhkan kualitas bahan, 7 menyebut barang tidak sesuai deskripsi, dan 7 lagi tidak pernah dibalas chatnya. Pola itu baru muncul ketika seluruh 66 ulasan dibaca sekaligus. Kami membangun Ulasin, asisten analisis ulasan untuk penjual mikro di marketplace Indonesia, yang menyambung lima tahap yang selama ini terputus: ulasan mentah, aspek dan sentimen, bukti kutipan, prioritas, lalu tindakan. Delapan dari sembilan fiturnya berjalan pada versi yang dilaporkan naskah ini. Model teks IndoBERT dua kepala kami *fine-tune* pada 96.300 klausa hasil *weak supervision* atas 39.986 ulasan publik berlisensi jelas, lalu diuji pada label independen. Macro F1 sentimen mencapai 0,730, di atas leksikon 0,700 dan TF-IDF 0,627 pada NusaX-senti, dengan kelas netral naik dari 0,021 ke 0,645 dan negasi naik 0,397. Seluruh angka yang ditampilkan lahir dari *tool* deterministik, tanpa campur tangan model bahasa, sehingga setiap skor prioritas dapat dihitung ulang dari klausa mentah lewat satu *endpoint*. Sistem berjalan pada 2 vCPU tanpa GPU, tanpa API berbayar, tanpa akun, dan tanpa basis data; analisis 66 ulasan selesai dalam 53 sampai 55 detik. Dua gerbang tidak lulus, dan keduanya kami laporkan. Pada aspek, model tidak mengungguli aturan leksikon: 0,579 melawan 0,581 pada 120 klausa berlabel manusia. Kami yang pertama menyatakannya, lengkap dengan protokol validasinya. Model visual *zero-shot* gagal gerbangnya sendiri (argmax 0,45 di bawah tebakan sepele 0,61 pada 97 foto), dan gerbang itu kini dieksekusi kode: adapter menolak aktif selama vonisnya bukan GO. Yang kami bawa bukan produk yang mengklaim sempurna, melainkan produk yang tahu persis di mana ia lemah, punya perangkat untuk mengukurnya, dan arsitektur yang memungkinkan perbaikannya tanpa perombakan.

Kata kunci—analisis sentimen berbasis aspek, Bahasa Indonesia informal, IndoBERT, weak supervision, UMKM, smart commerce

I. PENDAHULUAN

A. Nama Kelompok dan Nama Inovasi

Nama tim **BPS (Bawa Pulang Sasuke)**. Nama inovasi **Ulasin**, dengan janji produk yang dapat diucapkan dalam satu kalimat: *sulap ulasan jadi keputusan*. Subtema yang dipilih adalah *Smart Commerce*. Identitas lengkap karya beserta tautan yang dapat diperiksa juri disajikan pada Tabel II.

Satu kalimat yang menjadi janji seluruh naskah ini: Ulasin membaca 100% ulasan pelanggan berbahasa Indonesia informal, menunjuk tiga sampai lima hal yang paling mendesak diperbaiki minggu ini beserta kutipan ulasan aslinya sebagai bukti, dan membuka rumus di balik setiap angkanya sampai pembaca dapat mengalikannya sendiri.

TABEL I. PEMETAAN BAGIAN WAJIB RULEBOOK KE BAB NASKAH INI

Bagian wajib rulebook	Bab	Bobot rubrik terkait
Nama kelompok & nama inovasi	I-A, Tabel II	-
Latar belakang	I-B, I-C	Orisinalitas & dampak 20%; tema 10%
Tujuan dan manfaat pengembangan	I-D, I-E	Orisinalitas & dampak 20%
Metodologi: alur memperoleh dataset	III-B	Kualitas proposal 15%
Metodologi: alur pengembangan model tiap fitur	III-C	Implementasi teknologi 25%
Metodologi: alur integrasi model ke *environment* kode	III-D	Implementasi teknologi 25%
Metode pendukung pengambilan keputusan	IV, V-A s.d. V-D	Kualitas proposal 15%
Kesimpulan	VI	Kesiapan MVP 15%
Business value & tata kelola (bonus)	V-E	Bonus 3,5%

TABEL II. IDENTITAS KARYA

Butir	Isi
Nama tim	**BPS (Bawa Pulang Sasuke)**
Nama inovasi	**Ulasin**, *sulap ulasan jadi keputusan*
Subtema	*Smart Commerce* (sisi konsumen, operasional penjualan, transaksi)
Repositori	github.com/MikaelAdikara/BPS_AIC (publik)
Demo publik	34.41.49.44 (VM 2 vCPU, tanpa GPU, *auto-deploy* dari main); terakhir diverifikasi 23 Agustus 2026, HTTP tanpa TLS
Checkpoint model	huggingface.co/MikaelAdi/insightulasan-nlp01 (Apache-2.0, 499 MB)
Periode pengerjaan	5 − 25 Agustus 2026; 85 *commit*, 100% *Conventional Commits*
Status fitur	**8 dari 9 berjalan** (Tabel IX); 1 dimatikan oleh gerbang mutunya sendiri, yaitu penilaian kondisi barang dari foto
Status gerbang evaluasi	sentimen **LULUS** (0,730 vs leksikon 0,700); aspek **TIDAK LULUS** (0,579 vs 0,581); visual **NO-GO** (0,45 vs tebakan sepele 0,61)

B. Latar Belakang

Perdagangan elektronik sudah menjadi lapisan dasar ekonomi Indonesia, bukan lagi pelengkapnya. Badan Pusat Statistik mencatat 4,40 juta unit usaha *e-commerce* pada 2024, tumbuh 15,3% dalam setahun dan 86% dalam empat tahun, dan mayoritasnya usaha mikro [1]. Di atasnya berdiri populasi UMKM yang menyumbang 61,9% produk domestik bruto dan menyerap sekitar 97% tenaga kerja nasional [2]. Nilai transaksi ekonomi digital Indonesia menembus sekitar US$100 miliar pada 2025, dengan *e-commerce* sebagai penyumbang terbesar [3]. Angka-angka itu, beserta sumber dan kelas buktinya, dirangkum pada Tabel III.

Yang berubah pada 2025 sampai 2026 bukan besarannya, melainkan tekanannya. Struktur biaya platform yang berlaku sejak 1 Januari 2026 menempatkan komisi 2,5 sampai 10%, program gratis ongkir 4 sampai 4,5%, promosi 1 sampai 2%, dan iklan 3 sampai 5% di pundak penjual. Totalnya 15 sampai 20% dari harga jual [4]. Pada saat yang sama, pengaduan

konsumen yang tercatat di Badan Perlindungan Konsumen Nasional melonjak dari 926 kasus pada 2023 menjadi 1.733 pada 2024, naik 200%. Sektor *e-commerce* berada di urutan teratas setelah jasa keuangan, dengan keluhan utama berupa barang tidak sesuai, barang rusak, dan layanan purna jual [5]. Margin menipis dari satu sisi, ketidakpuasan pembeli menumpuk dari sisi lain.

Di titik itulah ulasan pelanggan berhenti menjadi catatan sampingan. Survei YouGov atas lebih dari 6.000 responden yang dijalankan pada 19 Desember 2024 sampai 7 Januari 2025 menemukan 54% konsumen Indonesia lebih memercayai ulasan sesama pengguna daripada konten pemengaruh, proporsi tertinggi di antara Indonesia, Singapura, dan Thailand [6]. Surveinya berdomain produk kecantikan, dan batas itu kami sebutkan alih-alih memperluasnya diam-diam. Penelitian pada data reputasi daring bahkan menunjukkan bahwa sekadar membalas ulasan menaikkan volume ulasan sebesar 12% dan rata-rata bintang sebesar 0,12 [7]. Ulasan adalah satu-satunya tempat pembeli mengatakan langsung apa yang salah, sekaligus satu-satunya sinyal yang dibaca calon pembeli berikutnya sebelum memutuskan.

Empat hal itu terjadi bersamaan: biaya berjualan naik, pengaduan konsumen melonjak, pembeli makin bergantung pada ulasan, dan membalas ulasan terbukti berdampak. Keempatnya menunjuk ke tumpukan teks yang sama, yaitu ulasan pelanggan, yang belum pernah dibaca secara sistematis oleh penjual mikro mana pun karena waktunya habis untuk berjualan.

TABEL III. BUKTI BESARAN MASALAH, BESERTA SUMBER DAN KELAS BUKTINYA

Angka	Nilai	Sumber	Kelas bukti
Unit usaha *e-commerce* Indonesia (2024)	4,40 juta; +15,3% setahun; +86% dalam 4 tahun; mayoritas mikro	BPS, *Statistik E-Commerce 2024*	Statistik resmi
Populasi UMKM (2025)	65,5 juta unit; 61,9% PDB; ±119 juta tenaga kerja (97%)	Kementerian Koperasi dan UKM, 2025	Statistik resmi
UMKM yang sudah *onboarding* digital	±25 juta dari target 30 juta	Kemenkop UKM, 2025	Statistik resmi
GMV ekonomi digital Indonesia 2025	±US$100 miliar, +14%; *e-commerce* penyumbang terbesar	*e-Conomy SEA 2025*	Laporan industri
Biaya platform yang ditanggung penjual (2026)	komisi 2,5−10% (hingga 12,2%), gratis ongkir 4−4,5%, promosi 1−2%, iklan 3−5% → **15−20%** harga jual	*Bisnis.com*, 21 Mei 2026; kompilasi tim atas tarif resmi platform	Laporan industri
Pengaduan konsumen BPKN	1.733 (2024), **naik 200%** dari 926 (2023); *e-commerce* sektor teratas setelah jasa keuangan	BPKN, statistik pengaduan	Statistik resmi
Kepercayaan pembeli pada ulasan	54% konsumen Indonesia lebih memercayai ulasan sesama pengguna daripada konten pemengaruh; tertinggi dibanding Singapura dan Thailand	YouGov, survei 3 negara, Des. 2024 − Jan. 2025 (domain riasan)	Survei
Efek membalas ulasan	+12% volume ulasan; +0,12 bintang rata-rata	Proserpio & Zervas, *Marketing Science* 36(5), 2017	Penelitian

Persona yang mengikat seluruh rancangan ini adalah seorang penjual fesyen mikro dengan dua karyawan dan dua toko di kanal berbeda. Ia menerima sekitar 300 ulasan per bulan, membaca ulasan “kalau sempat”, tidak terbiasa dengan lembar sebar, dan membalas hanya ulasan negatif yang paling keras. Ia membuka aplikasi malam hari setelah tutup toko, dari telepon Android, dalam keadaan lelah, untuk satu pertanyaan: *besok saya harus benahi apa?*

Tiga kerugian menimpanya tanpa pernah terlihat. Pertama, keluhan yang berulang pelan-pelan, misalnya “agak kekecilan” yang muncul pada satu dari sepuluh ulasan, tidak pernah menjadi pola. Pola semacam itu hanya muncul ketika seluruh ulasan dibaca sekaligus. Kedua, biaya iklan terbakar untuk mendatangkan pembeli baru ke masalah yang belum diperbaiki. Ketiga, ulasan negatif yang tidak terbalas menurunkan kepercayaan pembeli berikutnya, persis pada variabel yang penelitian [7] tunjukkan responsif terhadap intervensi.

Penyebabnya bukan kemalasan, melainkan aritmetika waktu. Membaca dan merekap 300 ulasan secara manual, pada asumsi 20 detik per ulasan ditambah satu jam untuk merangkum, memakan sekitar 2,7 jam. Asumsi ini kami tandai sebagai asumsi karena memang belum kami ukur bersama pengguna nyata. Sisi mesinnya sudah terukur: 66 ulasan selesai dalam 53 sampai 55 detik pada server 2 vCPU tanpa GPU, dari tiga kali pengukuran (50, 53, dan 55 detik), sehingga 300 ulasan diperkirakan selesai dalam 4 sampai 5 menit. Pemisahan tegas antara yang terukur dan yang masih berupa asumsi kami pertahankan di seluruh naskah.

C. Celah pada Solusi yang Sudah Ada

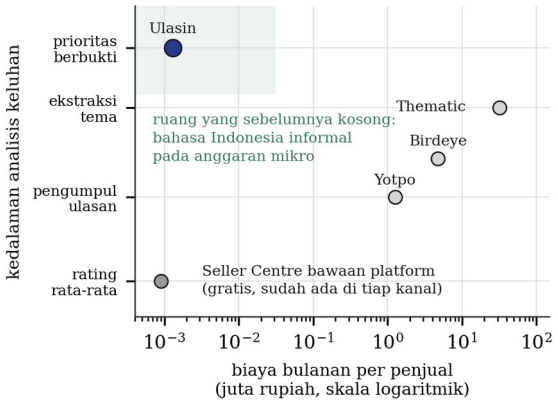
Solusi untuk masalah ini bukannya tidak ada. Persoalannya, semuanya berhenti di tempat yang salah, dan Tabel IV menamai satu per satu beserta biayanya. Perangkat bawaan platform (Shopee Seller Centre, Tokopedia Seller Dashboard, TikTok Shop Seller Center) gratis, tetapi berhenti di rating rata-rata dan jumlah ulasan, tanpa aspek, tanpa prioritas, dan tanpa pandangan lintas kanal. Perangkat yang mampu melakukan ekstraksi tema, seperti Yotpo dari US$79 per bulan, Birdeye US$299 sampai 449 per lokasi ditambah *onboarding* US$500 sampai 1.500, dan Thematic dari US$2.000 per bulan, dirancang untuk ulasan berbahasa Inggris dan berada jauh di atas anggaran penjual mikro. Perangkat operasional multichannel seperti Jubelio dan Ginee mengurus stok dan pesanan, bukan *insight*.

TABEL IV. SOLUSI YANG SUDAH ADA DAN TITIK BERHENTINYA

Solusi	Biaya bagi penjual	Sampai mana ia berjalan	Yang tidak dijawabnya
Shopee Seller Centre · Tokopedia Seller Dashboard · TikTok Shop Seller Center	gratis (bawaan)	rating rata-rata, jumlah ulasan, statistik per kanal	tanpa aspek, tanpa prioritas, tidak lintas kanal
Yotpo	dari US$79/bln (±Rp1,26 juta)	pengumpulan dan penayangan ulasan	bukan analisis keluhan; dirancang untuk Bahasa Inggris
Birdeye	US$299−449/bln per lokasi + *onboarding* US$500−1.500	reputasi multi-lokasi, pemantauan	Bahasa Inggris; skala perusahaan multi-cabang
Thematic	dari US$2.000/bln (±Rp32 juta)	ekstraksi tema kelas perusahaan	Bahasa Inggris; jauh di atas anggaran penjual mikro
Jubelio · Ginee	berlangganan	operasional multichannel (stok, pesanan)	bukan *insight* dari ulasan
Baca manual + rekap sendiri	waktu	beberapa ulasan teratas	tidak sanggup di atas 50−100 ulasan per bulan

Solusi	Biaya bagi penjual	Sampai mana ia berjalan	Yang tidak dijawabnya
Pencarian kata kunci / aturan *if-else*	gratis	menemukan kata yang persis dicari	runtuh pada sinonim, *slang*, *typo*, negasi, sarkasme
Zero-shot LLM API	per panggilan, naik dengan volume	ringkasan bebas yang terdengar meyakinkan	tidak *reproducible* tanpa kunci API, tidak konsisten antar-jalan, data keluar
Ulasin	**Rp0 bagi pengguna**; ongkos marginal ±Rp1.330/penjual/bulan pada asumsi utilisasi 10%	**aspek + sentimen + bukti kutipan + prioritas + tindakan, seluruhnya lokal**	**belum: integrasi langsung marketplace, deteksi ulasan palsu**

Celahnya dapat dinyatakan tegas. Yang gratis berhenti di rating rata-rata, tanpa aspek dan tanpa prioritas. Yang mampu berharga Rp1,26 juta sampai Rp32 juta per bulan dan dirancang untuk Bahasa Inggris. Di antara keduanya, untuk kalimat seperti *"bahannya oke sih cuma kekecilan bgt, sizechartnya ngaco"*, pada anggaran penjual mikro, tidak ada apa pun. Gambar 1 memetakan posisi itu pada dua sumbu: biaya bulanan dan kedalaman analisis.



Gambar 1. Posisi solusi yang ada pada dua sumbu: biaya bulanan bagi satu penjual dan kedalaman analisis keluhan.

Dua pendekatan murah yang biasa ditempuh juga gagal, dan kegagalannya terukur. Pendekatan kecocokan permukaan (pencarian kata kunci, leksikon, TF-IDF) menangani variasi permukaan dengan baik: *typo* dan ragam informal 0,736, *slang* 0,789, kalimat singkat atau samar 0,778. Tetapi ia runtuh pada fenomena komposisional: sentimen campuran 0,113, negasi 0,163, sarkasme 0,198, kalimat ambigu 0,237. Sementara itu memanggil API model bahasa besar secara *zero-shot* memang cepat dibangun, tetapi hasilnya tidak dapat direproduksi tanpa kunci API, tidak konsisten antar-jalan, dan memaksa data ulasan keluar dari lingkungan penjual. Justifikasi memakai model kontekstual, karena itu, bertumpu pada celah yang terukur, bukan pada tren (Tabel XIII dan Gambar 9).

D. Tujuan Pengembangan

Berangkat dari celah tersebut, pengembangan Ulasin diarahkan pada empat tujuan berikut.

1) Mengubah ulasan pelanggan berbahasa Indonesia informal menjadi **daftar prioritas tindakan** yang berbukti, untuk penjual mikro dan kecil yang tidak memiliki keahlian data.
2) Memastikan **setiap angka dapat diaudit**: dihitung secara deterministik, dilengkapi kutipan ulasan asli, dan rumusnya terbuka di antarmuka lewat fitur "Buka Hitungannya".
3) Berjalan **lokal di CPU tanpa API berbayar**, tanpa akun, dan tanpa menyimpan data pengguna, sehingga dapat direproduksi juri dan dipakai UMKM dengan ongkos mendekati nol.
4) Menyediakan jembatan dari wawasan ke tindakan berupa **draf balasan** ulasan negatif, dengan keputusan tetap di tangan manusia, dan **arsip antar-periode** untuk memeriksa apakah perbaikan yang dilakukan benar-benar berdampak.

E. Manfaat dan Target Pengguna

Pengguna sasaran dibagi tiga segmen. Segmen pertama, yang menjadi fokus, adalah penjual mikro dan kecil daring dengan satu sampai dua orang, 50 sampai 500 ulasan per bulan, dan anggaran perkakas mendekati nol. Segmen kedua adalah pendamping UMKM dari dinas, asosiasi, atau inkubator, yang berfungsi sebagai jalur distribusi: satu dinas dapat menjangkau ratusan usaha binaan. Segmen ketiga, merek menengah dengan banyak SKU, belum dilayani penuh karena membutuhkan integrasi langsung yang sengaja tidak kami bangun.

TABEL V. MANFAAT YANG DIJANJIKAN, UKURAN PEMBUKTINYA, DAN STATUS BUKTINYA HARI INI

Janji kepada pengguna	Ukuran pembukti	Status
Keluhan terbaca 100%, bukan sampel	laporan menampilkan n dari n; 66 dari 66 pada studi kasus	**Terukur**
Prioritas terurut, bukan sekadar daftar	skor = frekuensi × keparahan × (1 + 0,3·tren + 0,2·selisih) × 100; terbuka per kartu	**Terukur** (bobot 0,3/0,2 belum divalidasi)
Setiap angka berbukti kutipan	3 kutipan per kartu dengan id ulasan, rating, tanggal, skor relevansi	**Terukur**
Bahasa informal terbaca	macro F1 sentimen 0,730 vs leksikon 0,700 pada label manusia; kelas netral 0,021 → 0,645	**Terukur**
Hemat waktu	66 ulasan dalam 53 detik terukur; pembanding manual belum diuji	Sebagian
Tidak menyimpan data pengguna	tanpa basis data; sesi *in-memory* ber-TTL; arsip tanpa teks ulasan (0 dari 66 bocor, diuji)	**Terukur**
Rekomendasi benar-benar berguna	agregat Terima/Tolak pada pemakaian nyata	**Belum diukur**

Manfaat yang dijanjikan sengaja kami tuliskan berpasangan dengan ukuran pembuktinya dan status buktinya hari ini, sebagaimana Tabel V. Tiga dari tujuh janji berstatus terukur sepenuhnya, satu berstatus sebagian, dan satu berstatus **belum diukur**, yaitu apakah rekomendasinya benar-benar berguna. Hanya pemakaian nyata yang dapat menjawabnya. Satu baris yang jujur menyatakan "belum diukur" menaikkan kredibilitas tiga baris lain di sekitarnya.

Relevansi terhadap tema *AI for the Backbone of the Economy* mengalir langsung dari sini. Subtema *Smart Commerce* menempatkan AI pada sisi konsumen, operasional penjualan, dan transaksi. Ulasan pelanggan adalah titik tempat ketiganya bertemu: ia ditulis konsumen, dibaca calon pembeli, dan menentukan apakah transaksi berikutnya terjadi. AI di sini tidak dipaksakan. Ia dipakai tepat pada bagian yang terbukti tidak dapat ditangani aturan, yaitu bahasa informal yang komposisional.

F. Batasan dan Kontribusi

Ruang lingkup babak penyisihan membatasi apa yang dibangun, dan batasan itu kami hormati sebagai keputusan desain, bukan sebagai kekurangan. Enam batasan berikut berlaku pada versi yang dilaporkan naskah ini.

1) Satu alur sinkron: unggah, analisis, hasil. Tanpa akun, tanpa basis data, tanpa *background job*, tanpa infrastruktur terdistribusi.

2) Empat jalur masukan, yaitu tempel teks, berkas CSV/JSON, tangkapan layar, dan foto kamera, tetapi **tanpa** konektor otomatis ke marketplace, karena status legal pengambilan data otomatis belum jelas.
3) Klaim kebahasaan dibatasi pada Bahasa Indonesia informal, termasuk *slang* dan *typo*. Bahasa daerah **tidak** diklaim, dan Bahasa Inggris hanya sebagian. Keduanya terukur buruk (Gambar 8).
4) Jalur visual berkode lengkap tetapi **tidak diaktifkan**, karena gerbang mutunya tidak lulus. Konsekuensinya, deteksi kontradiksi antara foto dan teks selalu kosong pada versi ini.
5) Model bahasa besar sebagai penyusun narasi sengaja belum dipasang. Sistem berjalan permanen pada jalur narasi template yang memang dirancang sebagai jalur setara.
6) Seluruh angka evaluasi yang dikutip berasal dari label independen atau label manusia. Angka dari label lemah (*silver*) tidak pernah dikutip sebagai capaian, hanya sebagai ilustrasi sirkularitas.

Kontribusi naskah ini ada empat. Pertama, sebuah *pipeline* analisis ulasan Bahasa Indonesia informal yang menyambung lima tahap sekaligus, dari teks mentah sampai tindakan berbukti, dan berjalan penuh di CPU. Kedua, protokol evaluasi yang memisahkan secara tegas tiga kelas angka (label lemah, uji ketahanan, dan label manusia), lengkap dengan gerbang go/no-go yang kriterianya ditulis sebelum angkanya dilihat. Ketiga, laporan lengkap atas dua gerbang yang **gagal**, yaitu aspek dan visual, beserta bukti mengapa gagal dan apa rencananya. Keempat, sepuluh iterasi keputusan yang benar-benar terjadi, bertanggal dan berangka, sebagai bahan bagi tim lain yang menghadapi kelangkaan data berlabel dalam Bahasa Indonesia.

Tabel I memetakan setiap bagian wajib rulebook ke bab naskah ini, agar pembaca dapat memeriksa kelengkapannya tanpa menebak.

II. LANDASAN DAN KAJIAN TERKAIT

Bagian ini memaparkan pekerjaan terdahulu yang relevan dan dasar matematis dari setiap komponen yang dipakai. Urutannya mengikuti urutan pemakaian di dalam sistem: leksikon sebagai *baseline* sekaligus *fallback*, TF-IDF sebagai *baseline* pembelajaran mesin klasik, *encoder* Transformer sebagai model utama, *weak supervision* sebagai sumber label, *retrieval* sebagai penyedia bukti, dan terakhir metrik beserta cara menyatakan ketidakpastiannya.

A. Analisis Sentimen Berbasis Aspek untuk Bahasa Indonesia

Analisis sentimen berbasis aspek (*aspect-based sentiment analysis*, ABSA) memecah satu ulasan menjadi pasangan aspek dan polaritas. Kalimat “barangnya bagus tapi pengirimannya lama” karena itu menghasilkan dua penilaian yang berbeda, bukan satu skor tunggal. Untuk Bahasa Indonesia, sejumlah penelitian menunjukkan model berbasis Transformer konsisten mengungguli LSTM maupun Naive Bayes, dengan akurasi yang dilaporkan berkisar 83 sampai 97% pada domain hotel, perjalanan, dan aplikasi [8]−[10]. Rentang itu perlu dibaca hati-hati. Tidak ada tolok ukur konsensus, skema labelnya berbeda-beda, dan metodologi dua sumber dengan angka tertinggi belum dapat kami telaah penuh. Karena itu kami mengutip rentangnya, bukan angka tunggalnya.

IndoBERT [11] adalah model pralatih Bahasa Indonesia yang dilatih pada korpus Indo4B dan menjadi tolok ukur IndoNLU. Kosakatanya dibangun dari teks Indonesia, sehingga kata seperti “sizechartnya” atau “kegedean” terpecah menjadi *subword* yang jauh lebih masuk akal dibanding pada model multibahasa. Untuk domain *e-commerce* berbahasa Indonesia, PRDECT-ID [12] menyediakan 5.400 ulasan produk berlisensi CC-BY-4.0 dengan label sentimen biner dan emosi lima kelas. NusaX [13] menyediakan sentimen paralel berlabel pakar untuk sepuluh bahasa daerah, yang kami pakai untuk menguji sampai mana klaim kami **tidak** boleh diperluas.

B. Celah Penelitian yang Kami Isi

Penelusuran kami menemukan dua celah yang saling menguatkan. Celah pertama bersifat metodologis: penelitian ABSA Bahasa Indonesia hampir seluruhnya berhenti pada tahap klasifikasi. Keluarannya berupa label per kalimat, bukan daftar prioritas tindakan bagi pemilik usaha. Belum kami temukan pekerjaan yang menyambungkan aspek, sentimen, frekuensi, keparahan, kebaruan, dan konteks bisnis menjadi satu peringkat keputusan yang dapat ditindaklanjuti.

Celah kedua bersifat sumber daya. Delapan variasi kueri pada HuggingFace tidak menemukan satu pun dataset ABSA Bahasa Indonesia domain *e-commerce* dengan lisensi yang jelas. CASA berisi ulasan mobil, HoASA berisi ulasan hotel, dan koleksi ABSA Indonesia yang terkompilasi bersifat *gated* tanpa lisensi. Ketiadaan itulah yang memaksa keputusan metodologis paling menentukan di seluruh proyek ini, yaitu memakai *weak supervision* dengan gold set manusia sebagai penengah, beserta seluruh konsekuensinya yang kami laporkan terbuka pada Bab V.

Kebaruan yang kami klaim, karena itu, bukan arsitektur model baru. Yang kami klaim adalah **jembatan lima tahapnya**: sebuah *pipeline* dan produk yang mengubah ulasan Bahasa Indonesia informal menjadi tindakan berprioritas yang setiap angkanya dapat ditelusuri, berjalan sepenuhnya lokal, pada anggaran penjual mikro.

C. Penilaian Sentimen Berbasis Leksikon

Pendekatan berbasis leksikon menilai polaritas dengan menjumlahkan bobot kata bermuatan yang ditemukan pada teks. Ia dipakai di sini dalam dua peran sekaligus: sebagai *baseline* yang harus dikalahkan model, dan sebagai *fallback* yang menjaga sistem tetap menjawab ketika *checkpoint* model tidak tersedia. Untuk sebuah klausa c yang tersusun atas n buah token, skor polaritasnya didefinisikan pada Persamaan (1), dengan $w(t)$ sebagai bobot polaritas token dari leksikon dan $v(t)$ sebagai faktor pembalik negasi pada Persamaan (2).

$$s(c) = \Sigma_{i=1}^{n} v(t_i) \cdot w(t_i) \tag{1}$$

$$v(t_i) = -1 \text{ bila ada penanda negasi dalam jendela } k \text{ token sebelum } t_i, \text{ dan } 1 \text{ selainnya} \tag{2}$$

Keputusan kelas diambil dengan ambang dua sisi seperti pada Persamaan (3), sehingga klausa yang skornya berada di sekitar nol dinyatakan netral alih-alih dipaksa memilih salah satu kutub. Jendela negasi k dan ambang τ ditetapkan dari *split* validasi, bukan dari *split* uji.

$$\text{kelas}(c) = \text{positif bila } s(c) > \tau;\ \text{negatif bila } s(c) < -\tau;\ \text{netral selainnya} \tag{3}$$

Kekuatan pendekatan ini adalah determinisme penuh. Keluarannya identik pada setiap pemanggilan, tidak memerlukan GPU, dan dapat dijelaskan kata per kata kepada pengguna. Kelemahannya menjadi argumen inti naskah ini: ia

hanya melihat permukaan, sehingga sarkasme, sentimen campuran, dan negasi berjarak jauh luput sepenuhnya.

D. TF-IDF dengan Regresi Logistik

Baseline pembelajaran mesin klasik yang kami pakai adalah TF-IDF dengan regresi logistik. Pembobotan TF-IDF pada Persamaan (4) menaikkan bobot istilah yang sering muncul di satu dokumen tetapi jarang di seluruh korpus, sehingga kata umum seperti "barang" tidak menutupi kata pembeda seperti "kekecilan". Vektorisasi dilakukan pada tingkat *character n-gram* 3−5 dengan mode char_wb, pilihan yang disengaja karena ragam tulis penjual dan pembeli Indonesia penuh *typo* dan pemanjangan huruf.

$$\text{tf-idf}(t,d) = \text{tf}(t,d) \cdot \log(N / (1 + \text{df}(t))) \tag{4}$$

$$x(d) = [\ \text{tf-idf}(t_1,d), \ldots, \text{tf-idf}(t_m,d)\ ] \tag{5}$$

Vektor tersebut dipetakan ke probabilitas kelas lewat regresi logistik satu lawan sisanya pada Persamaan (6), dan parameternya dicari dengan meminimalkan entropi silang berbobot kelas pada Persamaan (7). Pembobotan kelas diperlukan karena sebaran sentimen klausa pada korpus kami sangat timpang, yaitu 84% positif, 13% negatif, dan hanya 2% netral.

$$P(y{=}1 \mid x) = \sigma(w^\top x + b), \quad \sigma(z) = 1 / (1 + \exp(-z)) \tag{6}$$

$$L = -\Sigma_i\, \alpha_{y_i}\, [\ y_i \log p_i + (1 - y_i) \log(1 - p_i)\ ] \tag{7}$$

Baseline ini penting bukan karena diharapkan menang, melainkan karena ia mengukur berapa banyak sinyal yang dapat dipanen dari kecocokan permukaan saja. Selisih antara TF-IDF dan model kontekstual adalah nilai tambah yang benar-benar disumbangkan oleh pemahaman konteks.

E. Arsitektur Transformer dan IndoBERT

Model utama kami adalah *encoder* Transformer, yaitu IndoBERT-base [11] yang dibangun di atas arsitektur BERT [14]. Inti mekanismenya adalah *self-attention* pada Persamaan (8): setiap token menyusun representasinya dengan menimbang seluruh token lain pada kalimat yang sama, sehingga kata "nggak" pada awal klausa masih dapat membalikkan makna "bagus" yang muncul beberapa token sesudahnya. Perhatian dari beberapa kepala digabungkan seperti pada Persamaan (9).

$$\text{Attention}(Q,K,V) = \text{softmax}(QK^\top / \sqrt{d_k}\ ) V \tag{8}$$

$$\text{MHA}(X) = [\ \text{head}_1 ; \ldots ; \text{head}_h\ ]\ W^O \tag{9}$$

Matriks Q, K, dan V adalah proyeksi linear dari masukan blok. Pembagi berupa akar dimensi kepala menjaga hasil kali titik tetap pada skala yang membuat gradien softmax-nya tidak jenuh. Satu blok *encoder* diselesaikan oleh dua sublapis berumpan-maju dengan sambungan residual dan normalisasi lapis seperti pada Persamaan (10) dan (11); IndoBERT-base menumpuk blok tersebut dua belas kali.

$$H' = \text{LayerNorm}(X + \text{MHA}(X)) \tag{10}$$

$$H = \text{LayerNorm}(H' + W_2\, \text{GELU}(W_1 H' + b_1) + b_2) \tag{11}$$

Di atas satu *encoder* bersama kami pasang **dua kepala** sekaligus. Kepala aspek bersifat *multi-label* untuk sebelas kelas dengan aktivasi sigmoid pada Persamaan (12), karena satu klausa dapat menyentuh lebih dari satu aspek. Kepala sentimen bersifat tunggal untuk tiga kelas (negatif, netral, positif) dengan aktivasi softmax pada Persamaan (13). Representasi klausa diperoleh dengan merata-ratakan token bukan-*padding*, bukan dengan mengambil token [CLS] saja, karena klausa yang kami olah pendek dan seluruh tokennya membawa informasi.

$$P(\text{aspek}_j \mid c) = \sigma(\ w_j^\top\, h_c + b_j\ ), \quad j = 1 \ldots 11 \tag{12}$$

$$P(\text{sentimen} = k \mid c) = \exp(z_k) / \Sigma_{k'} \exp(z_{k'}) \tag{13}$$

Kedua kepala dilatih bersama dengan fungsi kerugian gabungan pada Persamaan (14), yaitu entropi silang biner untuk aspek ditambah entropi silang untuk sentimen. Alasan menyatukan keduanya di atas satu *encoder* bersifat praktis sekaligus konseptual. Dua model terpisah menuntut kira-kira dua kali memori saat inferensi. Selain itu sinyal "klausa ini membicarakan pengiriman" dan "klausa ini bernada negatif" memang berbagi representasi yang sama.

$$L = \lambda_a \cdot \text{BCE}(\ p^{aspek}, y^{aspek}\ ) + \lambda_s \cdot \text{CE}(\ p^{sentimen}, y^{sentimen}\ ) \tag{14}$$

F. Weak Supervision sebagai Sumber Label

Ketiadaan dataset ABSA Bahasa Indonesia berlabel memaksa kami memakai *weak supervision* bergaya Snorkel [15]: sejumlah fungsi pelabelan sederhana menghasilkan label bermutu rendah dalam jumlah besar, yang kemudian digabung menjadi label probabilistik seperti pada Persamaan (15). Dalam implementasi kami, fungsi pelabelan aspek dibangun dari leksikon istilah topik yang dipisahkan tegas dari leksikon polaritas, agar kata "lama" tidak sekaligus menandai aspek dan menentukan sentimennya.

$$\hat{y}(c) = \arg\max_y \Sigma_j\, \beta_j \cdot 1[\ \lambda_j(c) = y\ ] \tag{15}$$

Konsekuensi metode ini kami akui di muka, dan konsekuensi itu kemudian benar-benar terjadi: metrik yang dihitung pada label lemah berisiko sirkular, karena yang diukur sebenarnya adalah seberapa baik model memulihkan aturan yang membuat labelnya. Penengahnya adalah gold set berlabel manusia; bagaimana persisnya sirkularitas itu tertangkap, dibahas pada Bab V-B.

G. Pengambilan Bukti dan Anti-Duplikasi

Setiap kartu tindakan wajib membawa kutipan ulasan asli sebagai bukti. Pengambilannya memakai *embedding* padat BGE-M3 [16] dengan kemiripan kosinus pada Persamaan (16). Karena beberapa ulasan sering hampir identik, pemilihan kutipan memakai *maximal marginal relevance* pada Persamaan (17), yang menyeimbangkan relevansi terhadap kueri dengan keberagaman terhadap kutipan yang sudah terpilih.

$$\text{sim}(q,d) = (\ e_q^\top\, e_d\ ) / (\ \|e_q\|\, \|e_d\|\ ) \tag{16}$$

$$\text{MMR} = \arg\max_{d \in R \setminus S} [\ \gamma \cdot \text{sim}(q,d) - (1 - \gamma) \cdot \max_{d' \in S} \text{sim}(d,d')\ ] \tag{17}$$

Bila skor tertinggi berada di bawah ambang yang ditetapkan, sistem **tidak** memanggil lapisan mana pun untuk mengarang jawaban; ia menyatakan bahwa datanya belum cukup. Arah kegagalan ini disengaja: penolakan terlihat oleh pengguna, sedangkan jawaban keliru tidak.

H. Metrik Evaluasi dan Ketidakpastian

Metrik utama adalah macro F1, yaitu rata-rata tak berbobot F1 seluruh kelas, sebagaimana Persamaan (18) sampai (20). Pemilihan macro, bukan micro, disengaja: kelas netral dan kelas aspek langka hanya menyumbang beberapa persen data, sehingga rata-rata berbobot akan menyembunyikan kegagalan pada kelas yang justru paling penting bagi produk.

$$\text{presisi}_k = \text{TP}_k / (\text{TP}_k + \text{FP}_k), \quad \text{recall}_k = \text{TP}_k / (\text{TP}_k + \text{FN}_k) \tag{18}$$

$$\text{F1}_k = 2 \cdot \text{presisi}_k \cdot \text{recall}_k / (\text{presisi}_k + \text{recall}_k) \tag{19}$$

$$\text{macro-F1} = (1/K) \, \Sigma_{k=1}^{K} \, \text{F1}_k \tag{20}$$

Kesepakatan antar-pelabel diukur dengan *kappa* Cohen [17] pada Persamaan (21), dan aspek yang *kappa*-nya di bawah 0,40 sengaja **tidak** kami tafsirkan. Untuk ukuran sampel kecil, angka tunggal digantikan selang kepercayaan Wilson [18] pada Persamaan (22), yang berperilaku jauh lebih baik daripada selang normal ketika proporsinya mendekati nol atau satu.

$$\kappa = (p_o - p_e) / (1 - p_e) \tag{21}$$

$$\text{SK}_{Wilson} = (\hat{p} + z^2/2n \pm z\sqrt{(\hat{p}(1-\hat{p})/n + z^2/4n^2) }) / (1 + z^2/n) \tag{22}$$

Terakhir, keluaran softmax sebuah jaringan dalam yang dilatih dengan entropi silang terkenal terlalu percaya diri [19]. *Temperature scaling* pada Persamaan (23) memperbaikinya dengan satu parameter tunggal T yang dicari pada *split* validasi, dan mutunya dilaporkan lewat *expected calibration error* pada Persamaan (24). Modul kalibrasi sudah tersedia di repositori kami tetapi **belum** dijalankan pada *checkpoint* saat ini. Angka keyakinan karena itu sengaja disembunyikan dari antarmuka, dan konsekuensinya kami bahas pada Bab V-A.

$$P_T(y=k \mid x) = \exp(z_k/T) \, / \, \Sigma_{k'} \exp(z_{k'}/T) \tag{23}$$

$$\text{ECE} = \Sigma_{m=1}^{M} \, (|B_m| \, / \, n) \cdot | \, \text{akurasi}(B_m) - \text{keyakinan}(B_m) \, | \tag{24}$$

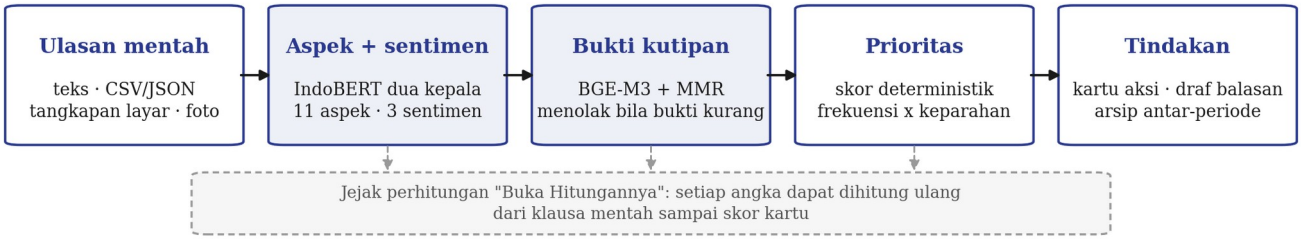
Seluruh komponen di atas dipilih dengan kriteria yang sama, yaitu dapat dijalankan pada CPU, berlisensi jelas, dan memiliki *fallback* yang tetap menjawab ketika komponen utamanya tidak tersedia. Bab berikutnya memaparkan bagaimana keenamnya dirangkai menjadi satu sistem.

III. METODOLOGI

Metodologi disusun mengikuti tiga alur yang secara eksplisit diminta rulebook: alur memperoleh dataset, alur pengembangan model untuk setiap fitur, dan alur integrasi model ke *environment* kode. Sebelum ketiganya, bagian ini dibuka dengan gambaran solusi secara utuh.

A. Gambaran Solusi

Ulasin adalah asisten analisis ulasan untuk penjual mikro dan kecil di marketplace Indonesia. Ia menerima ulasan apa adanya, baik berupa tempelan teks, berkas ekspor, tangkapan layar, maupun foto layar yang diambil dengan kamera. Keluarannya adalah daftar pendek hal yang paling mendesak diperbaiki, masing-masing dengan kutipan ulasan asli sebagai bukti dan rumus perhitungan yang dapat diperiksa ulang. Seluruh model berjalan lokal di CPU, tanpa API berbayar, tanpa akun, dan tanpa menyimpan data pengguna.



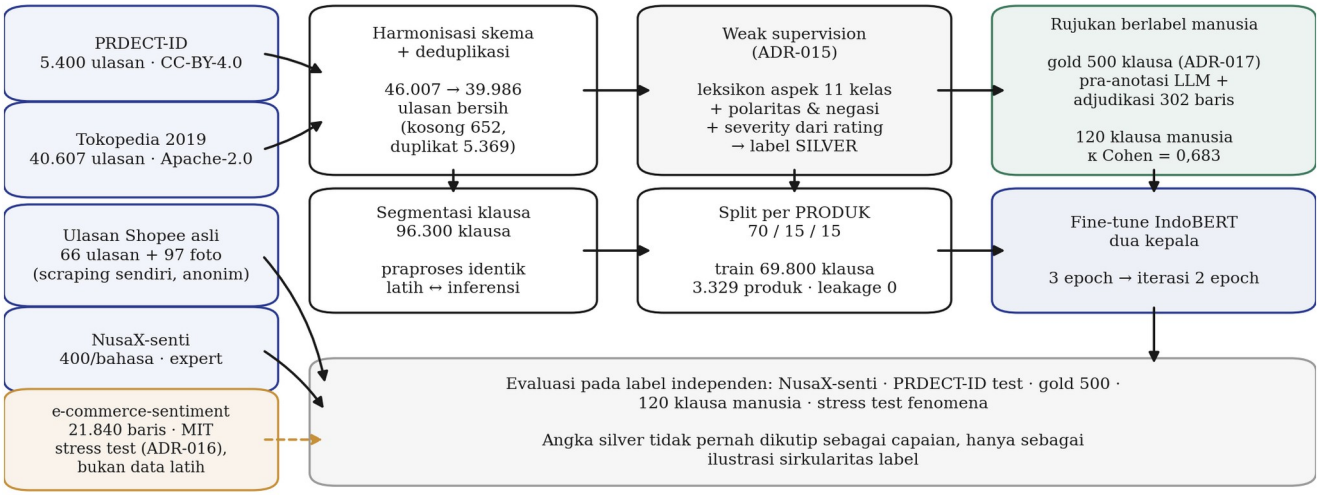
Gambar 2. Jembatan lima tahap yang menjadi kebaruan sistem ini: dari ulasan mentah sampai tindakan, dengan jejak perhitungan yang menaungi tiga tahap di tengahnya.

Kebaruan sistem ini terletak pada jembatan lima tahapnya, bukan pada satu model AI tertentu. Gambar 2 memperlihatkan kelima tahap itu: ulasan mentah, klasifikasi aspek dan sentimen, pengambilan bukti kutipan, penskoran prioritas deterministik, dan tindakan berupa kartu aksi, draf balasan, serta arsip antar-periode. Tiga tahap di tengahnya dinaungi satu jaring pengaman yang sama, yaitu jejak perhitungan. Setiap angka yang muncul di layar dapat dilacak mundur sampai ke klausa mentah yang menghasilkannya.

Prinsip yang membedakan sistem ini dari sebuah papan pemantau sentimen biasa dapat diringkas dalam satu kalimat. Sebuah papan pemantau berhenti pada pernyataan “sentimen Anda 72% positif”. Ulasin berhenti pada pernyataan “tiga belas dari enam puluh enam pembeli mengeluhkan kualitas bahan, ini kutipannya, ini skor prioritasnya, ini cara skornya dihitung, dan ini langkah yang dapat Anda ambil minggu ini”.

B. Alur Memperoleh Dataset

Alur memperoleh dataset digambarkan pada Gambar 3 dan bergerak dari lima sumber menuju satu korpus latih beserta dua himpunan rujukan berlabel manusia. Tabel VI merinci kelima sumber, lisensinya, dan perannya masing-masing.



Gambar 3. Alur memperoleh dataset, dari lima sumber publik dan swadaya menuju satu korpus latih beserta dua himpunan rujukan berlabel manusia.

TABEL VI. DATASET YANG DIPAKAI, LISENSI, DAN PERANNYA

Dataset	Lisensi	Ukuran	Peran dalam penelitian ini
PRDECT-ID (Sutoyo dkk., 2022)	CC-BY-4.0	5.400 ulasan, 29 kategori	latih inti; evaluasi *in-domain* berlabel manusia (uji n = 804)
Tokopedia Product Reviews 2019	Apache-2.0	40.607 ulasan, 5 kategori	latih dan uji lintas domain
e-commerce-sentiment-bahasa-indonesia	MIT	21.840 baris	**stress test** per fenomena linguistik, bukan data latih (87% duplikat, kelas seimbang artifisial)
NusaX-senti (Winata dkk., 2023)	CC-BY-SA-4.0	400 per bahasa, *expert-labeled*	evaluasi sentimen lintas bahasa dan lintas domain
Ulasan Shopee asli	disalin manual dari halaman produk toko sendiri, dianonimkan	66 ulasan teks + 97 foto berlabel manusia	studi kasus nyata; gerbang model visual; validasi aspek

Tiga dataset publik menjadi tulang punggung. PRDECT-ID [12] menyumbang 5.400 ulasan produk berlisensi CC-BY-4.0 dan berperan ganda sebagai data latih sekaligus himpunan uji *in-domain* berlabel manusia. Tokopedia Product Reviews 2019 menyumbang 40.607 ulasan berlisensi Apache-2.0 untuk memperluas cakupan kategori. Dataset ketiga, e-commerce-sentiment-bahasa-indonesia berlisensi MIT dengan 21.840 baris, semula direncanakan sebagai data latih. Pemeriksaan kemudian menemukan 87% duplikat, keseimbangan kelas yang artifisial, dan label yang sekadar menyalin rating, sehingga perannya dialihkan menjadi **uji ketahanan per fenomena linguistik**. Keputusan itu ternyata menghasilkan argumen inti naskah ini, dan diceritakan sebagai iterasi kedua pada Tabel XVI.

Dua sumber lain berperan sebagai penguji dari luar domain. NusaX-senti [13] menyediakan sentimen berlabel pakar untuk sepuluh bahasa. Kami memakainya untuk mengukur sampai mana klaim kami harus berhenti, bukan untuk mengklaim kemampuan lintas bahasa. Sementara itu 66 ulasan Shopee asli beserta 97 foto ulasan kami salin manual dari halaman dua produk fesyen, tanpa *scraper*, dianonimkan sebelum disimpan, dan dipakai sebagai studi kasus nyata, gerbang model visual, dan validasi aspek.

Harmonisasi menyatukan skema kolom yang berbeda-beda menjadi satu bentuk, lalu membuang ulasan kosong atau terlalu pendek dan duplikatnya. Tabel VII merangkum seluruh angkanya: 46.007 ulasan masuk, 652 dibuang karena kosong atau terlalu pendek, 5.369 dibuang karena duplikat, menyisakan 39.986 ulasan bersih yang kemudian disegmentasi menjadi 96.300 klausa. Segmentasi dilakukan pada tingkat klausa, bukan kalimat, karena satu kalimat ulasan Indonesia informal kerap memuat dua penilaian berlawanan yang dihubungkan “tapi”, “cuma”, atau sekadar koma.

TABEL VII. HARMONISASI KORPUS DAN PEMBAGIAN DATA

Ukuran	Nilai
Ulasan masuk dari tiga sumber	46.007
− dibuang karena kosong atau terlalu pendek	652
− dibuang karena duplikat	5.369
Ulasan bersih	**39.986**
Klausa hasil segmentasi	96.300
Sebaran sentimen klausa (positif / negatif / netral)	84% / 13% / 2%
Klausa tanpa aspek (label sah, dipakai sebagai negatif)	45%
Split per produk, latih	69.800 klausa, 3.329 produk
Split per produk, validasi	15.308 klausa
Split per produk, uji	11.192 klausa
Kebocoran antar-*split* terverifikasi	0
Gold test set (ADR-017)	500 klausa, 302 baris diadjudikasi manusia
Rujukan manusia independen	120 klausa, κ Cohen = 0,683

Pelabelan memakai *weak supervision* seperti pada Persamaan (15). Fungsi pelabelan berbasis leksikon menandai aspek per klausa, leksikon polaritas bersama penanda negasi menandai sentimen klausa, dan *severity* diturunkan secara heuristik dari rating ulasan. Hasilnya adalah label **silver**. Sebaran sentimen klausa yang dihasilkan sangat timpang, yaitu 84% positif, 13% negatif, dan 2% netral. Sebanyak 45% klausa tidak menyentuh aspek mana pun, dan itu kami perlakukan sebagai label sah, bukan sebagai data hilang.

Pembagian data dilakukan **per produk**, bukan per klausa, agar dua klausa dari ulasan yang sama atau dari produk yang sama tidak pernah jatuh di sisi latih dan sisi uji sekaligus. Tanpa langkah ini, ulasan yang hampir sama persis akan membuat metrik uji tampak jauh lebih baik daripada kenyataannya. Kebocoran antar-*split* diverifikasi dan hasilnya nol.

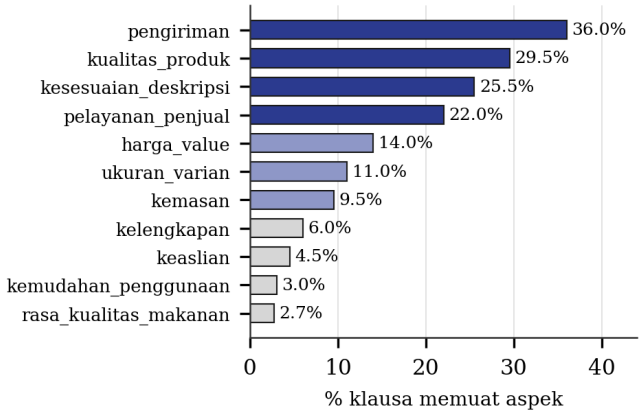
Dua himpunan rujukan berlabel manusia dibangun sebagai penengah atas risiko sirkularitas. Gold set berisi 500 klausa yang dipra-anotasi model bahasa lalu diadjudikasi manusia

pada 302 baris, ditambah 40 baris kontrol. Kesepakatan aspek yang persis sama tercatat 56,4%, angka yang sendirinya sudah memberi tahu banyak tentang sulitnya tugas ini. Belakangan, pada 22 Agustus, dibangun rujukan kedua berupa 120 klausa yang dilabeli manusia sepenuhnya dengan *kappa* Cohen 0,683 seperti pada Persamaan (21), dan rujukan inilah yang dipakai sebagai keputusan akhir gerbang aspek.

TABEL VIII. TAKSONOMI SEBELAS ASPEK DAN CAKUPAN KATEGORINYA

Aspek	Cakupan	Catatan
kualitas_produk	universal	aspek tersering pada data uji manusia
kesesuaian_deskripsi	universal	keluhan “tidak sesuai gambar/deskripsi”
harga_value	universal	sebanding atau tidak dengan harga
kemasan	universal	bobot relevansi tinggi untuk makanan dan minuman
pengiriman	universal	35−37% klausa data latih
pelayanan_penjual	universal	termasuk chat tak dibalas
ukuran_varian	universal, *relabel* per kategori	F&B → “porsi/takaran”; kerajinan → “dimensi produk”; bentuk keluhannya identik secara struktural
rasa_kualitas_makanan	khusus F&B	hanya 196 ulasan F&B pada data latih; bias cakupan diakui
kelengkapan	fesyen, kerajinan, elektronik, lainnya	barang kurang atau tidak lengkap
keaslian	fesyen, kerajinan, elektronik, lainnya	dugaan barang tiruan
kemudahan_penggunaan	kerajinan, elektronik, lainnya	petunjuk pakai, perakitan

Taksonomi aspek dibekukan sejak fase nol dan berisi sebelas kelas, sebagaimana Tabel VIII. Enam di antaranya universal, satu universal dengan penamaan ulang per kategori, dan empat khusus kategori tertentu. Aspek khusus diaktifkan atau dinonaktifkan dari kategori toko saat *ingestion*, sehingga menambah kategori baru **tidak** menuntut pelatihan ulang model. Gambar 4 memperlihatkan sebaran kesebelas aspek pada data latih. Pengiriman mendominasi dengan 35 sampai 37% klausa, sedangkan rasa dan kualitas makanan hanya menyentuh 0,9 sampai 4,5% karena kategori makanan dan minuman hanya terwakili oleh 196 ulasan dari sekitar 40 ribu. Bias cakupan ini kami sebutkan di muka, bukan setelah ditanya.

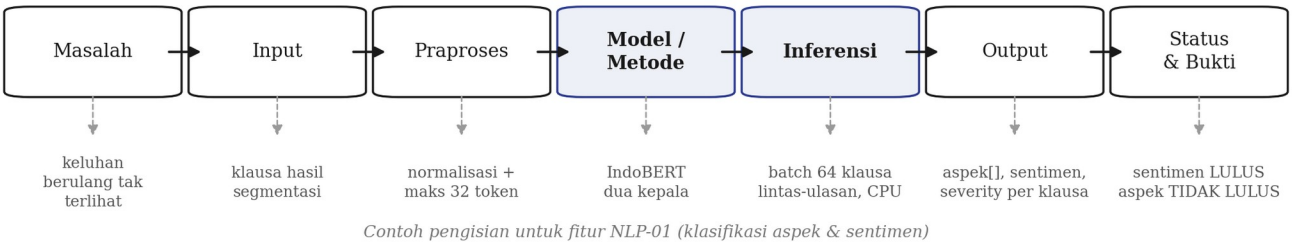


Gambar 4. Sebaran kesebelas aspek pada data latih. Aspek khusus kategori terwakili sangat sedikit, dan bias cakupan itu disebutkan di muka.

Dari sisi etika data, ulasan Shopee dianonimkan sebelum disimpan. Nama akun tidak pernah ikut, dan teksnya melewati penyaring informasi pribadi yang sama dengan yang dipakai aplikasi. Atribusi lisensi CC-BY untuk PRDECT-ID dicantumkan sebagaimana mestinya. Status legal pengambilan data otomatis dari marketplace kami nyatakan sebagai *belum sepenuhnya terverifikasi*, dan itulah alasan integrasi langsung sengaja tidak dibangun. Konsekuensi yang sama berlaku ke belakang: 66 ulasan dan 97 foto itu disalin satu per satu dengan tangan, bukan diambil *scraper*, supaya naskah ini tidak melarang di satu bab apa yang dilakukannya sendiri di bab lain.

C. Alur Pengembangan Model untuk Setiap Fitur

Setiap fitur AI dikembangkan mengikuti kerangka tujuh langkah yang sama: masalah, masukan, praproses, model atau metode, inferensi, keluaran, dan status beserta buktinya. Gambar 5 memperlihatkan kerangka itu terisi untuk fitur inti. Tabel IX merangkum kesembilan fitur beserta status buktinya masing-masing, termasuk satu fitur yang statusnya adalah kegagalan.



Gambar 5. Kerangka tujuh langkah yang dipakai untuk setiap fitur, terisi dengan contoh fitur klasifikasi aspek dan sentimen.

TABEL IX. SEMBILAN FITUR AI DAN NON-AI: MODEL, KELUARAN, DAN STATUS BUKTINYA

ID	Fitur	Model / metode	Keluaran	Status
NLP-01	Klasifikasi aspek & sentimen	IndoBERT-base dua kepala (sigmoid 11 aspek, softmax 3 sentimen)	aspek[], sentimen, *severity* per klausa	sentimen **LULUS**, aspek **TIDAK LULUS**
-	*Fallback* leksikon	leksikon polaritas + negasi, deterministik	keluaran setara, narasi lebih sederhana	berjalan; alasannya dilaporkan di /readiness

ID	Fitur	Model / metode	Keluaran	Status
RET-01	Bukti kutipan (*retrieval*)	BGE-M3 → E5 → TF-IDF; MMR anti-duplikat	maks. 3 kutipan per kartu + skor relevansi	berjalan; menolak menjawab bila bukti tak memadai
ACT-01	Kartu aksi & skor prioritas	tool deterministik (bukan model)	kartu terurut, urgensi tinggi/sedang/rendah	berjalan; bobot 0,3/0,2 belum divalidasi
BEN-01	*Benchmark* kategori	agregat pra-hitung + margin kesalahan dua sisi	posisi toko terhadap rata-rata kategori	berjalan; <30 ulasan → label "indikasi awal"
QNA-01	Tanya jawab ter-*ground*	penjaga domain kosakata + intent + retrieval	jawaban dari statistik terhitung + kutipan	berjalan; menolak bila tanpa bukti
REP-01	Draf balasan ulasan	template per (aspek × *severity*), variasi via *hash* review_id	draf yang wajib disunting pengguna	berjalan; keputusan uang tetap di manusia
TRC-01	Jejak perhitungan	penelusuran deterministik POST /trace	klausa → agregat → komponen rumus → skor	berjalan; diuji dapat dihitung ulang
ING-10	OCR tangkapan layar / foto	Tesseract 5.5 (ind+eng) + penyaring berbasis jarak piksel	teks ulasan sebagai **draf** yang wajib diperiksa	berjalan; rating hampir selalu kosong
VIS-01	Klasifikasi kondisi barang dari foto	CLIP ViT-B/32 *zero-shot*, *prompt ensemble*, abstensi wajib	-	**NO-GO**; adapter menolak aktif, dieksekusi kode

NLP-01, klasifikasi aspek dan sentimen. Masalahnya adalah keluhan berulang yang tidak pernah terlihat karena tersebar di ratusan ulasan. Masukannya klausa hasil segmentasi. Modul praprosesnya **identik** antara pelatihan dan inferensi: satu berkas yang sama dipanggil keduanya, sehingga ketidakcocokan praproses yang lazim menjatuhkan model di produksi tidak mungkin terjadi. Modelnya IndoBERT-base dua kepala seperti pada Persamaan (12) dan (13), dengan ambang aspek 0,70 yang dipilih dari *split* validasi. Konfigurasi pelatihannya dirinci pada Tabel X. Inferensi berjalan pada CPU dengan *batch* 64 klausa lintas-ulasan dan panjang maksimum 32 token. Keluarannya adalah daftar aspek, sentimen, dan *severity* per klausa, yang kemudian diagregasi per aspek. Buktinya terbelah: gerbang sentimen **lulus**, gerbang aspek **tidak lulus**, dan keduanya dilaporkan pada Bab IV.

TABEL X. KONFIGURASI PELATIHAN DAN LINGKUNGAN

Butir	Nilai
Model dasar	indobenchmark/indobert-base-p1
Kepala	aspek 11 kelas *multi-label* (sigmoid, ambang 0,70 dari validasi); sentimen 3 kelas (softmax)
Pooling	rata-rata token bukan-*padding* di atas satu *encoder* bersama
Epoch	3 (iterasi pertama) → 2 (iterasi kedua, setelah *labeling function* diperbaiki)
Batch / *learning rate*	32 / 2×10^{-5}
Optimizer / penjadwal	AdamW + OneCycleLR
Seed	42
Waktu latih	112,8 menit pada satu GTX 1650
Pemilihan *checkpoint*	F1 tertinggi pada *split* validasi
Inferensi	CPU, *batch* 64 klausa lintas-ulasan, maksimum 32 token
Ukuran artefak	*checkpoint* 499 MB + kepala aspek v2 36 KB

Jalur *fallback* leksikon. Ketika *checkpoint* tidak tersedia, sistem tidak berhenti. Ia berpindah ke jalur deterministik berbasis leksikon pada Persamaan (1) sampai (3), dan *endpoint* /readiness menyebutkan alasannya secara eksplisit. Perilaku ini diuji, dan demonstrasinya dilakukan dengan mencabut *checkpoint* saat sistem berjalan.

RET-01, bukti kutipan. Masalahnya adalah klaim tanpa bukti tidak dapat dipercaya pengguna yang skeptis. Masukannya klausa dan ulasan yang terindeks per sesi. Metodenya *embedding* BGE-M3 dengan *fallback* berjenjang ke E5 lalu TF-IDF, ditambah MMR pada Persamaan (17) untuk mencegah tiga kutipan yang isinya hampir sama. Keluarannya paling banyak tiga kutipan per kartu, masing-masing dengan id ulasan, rating, tanggal, dan skor relevansi. Satu catatan jujur perlu disampaikan. Karena *retrieval* mengembalikan ulasan utuh, panel "ulasan terkait" sempat menduplikasi kutipan yang sudah tampil, dan panel itu kami cabut ketimbang dibiarkan.

ACT-01, kartu aksi dan skor prioritas. Ini adalah bagian terpenting produk, dan di sinilah **tidak ada** model AI yang dipakai. Skornya dihitung deterministik seperti pada Persamaan (25), dengan frekuensi sebagai proporsi klausa negatif suatu aspek, keparahan sebagai rata-rata *severity*, serta dua pengubah untuk tren antar-periode dan selisih terhadap *baseline* kategori. Label urgensi ditetapkan dengan ambang pada Persamaan (26), dan dibatasi maksimum "sedang" ketika ulasan yang tersedia kurang dari lima belas.

$$\text{skor}(a) = \text{frekuensi}(a) \cdot \text{keparahan}(a) \cdot (\,1 + 0{,}3 \cdot \text{tren}(a) + 0{,}2 \cdot \text{selisih}(a)\,) \cdot 100 \tag{25}$$

$$\text{urgensi}(a) = \begin{cases} \text{tinggi} & \text{bila skor}(a) \geq 12 \\ \text{sedang} & \text{bila skor}(a) \geq 5 \\ \text{rendah} & \text{selainnya} \end{cases} \tag{26}$$

BEN-01, *benchmark* kategori. Agregat *baseline* dihitung sekali dari data publik per kategori, misalnya fesyen dengan n = 8.939 dan kategori lain-lain dengan n = 9.442, lalu disajikan bersama margin kesalahan dua sisi. Ketika toko yang dianalisis memiliki kurang dari 30 ulasan, hasilnya diberi label "indikasi awal" dan pengubah selisihnya dinolkan, karena pada n kecil margin kesalahannya dapat mencapai 40 poin. Ambang 30 dipilih karena di situlah margin turun ke sekitar 14 poin.

QNA-01, tanya jawab ter-*ground*. Pertanyaan pengguna disaring penjaga domain berbasis kosakata korpus dan daftar kata analitis dengan ambang 0,65. Pengukurannya menunjukkan pertanyaan dalam domain mencapai skor maksimum 0,50, sedangkan pertanyaan di luar domain mulai dari 0,75. Pertanyaan yang lolos dipetakan ke *intent* (per aspek, prioritas, pujian, persentase, atau umum), lalu dijawab dari statistik yang **sudah terhitung** ditambah kutipan hasil *retrieval*. Pertanyaan "harga saham Telkom" ditolak. Tiga pertanyaan wajar yang sempat dijawab salah pada audit 22 Agustus kini benar.

REP-01, draf balasan ulasan. Template disusun per pasangan aspek dan *severity*, dengan slot yang diisi dari data, yaitu kata kunci klausa negatif dan langkah rekomendasi. Variasi kalimat diambil dari *hash* id ulasan, bukan dari pembangkit acak, sehingga dua kali menjalankan sistem menghasilkan draf yang persis sama. Setiap keputusan yang menyangkut uang disisakan sebagai slot terbuka bertuliskan "[keputusan Anda: ganti barang / refund / tidak ada]", dan antarmuka mengunci tombol salin sampai penggunanya menyunting. Dasar literaturnya adalah temuan bahwa membalas ulasan berdampak terukur pada reputasi [7].

TRC-01, jejak perhitungan. *Endpoint* /trace mengembalikan rantai lengkap dari klausa mentah, agregat per aspek, komponen rumus beserta asal setiap nilainya, sampai aritmetika akhir yang menghasilkan skor kartu. Gambar 11 memperlihatkan satu jejak nyata: 0,197 × 1,000 × 1,468 × 100

= 28,92. Terdapat uji otomatis yang memastikan komponen jejak dapat dihitung ulang menjadi skornya, sehingga jejak dan skor tidak dapat menyimpang diam-diam.

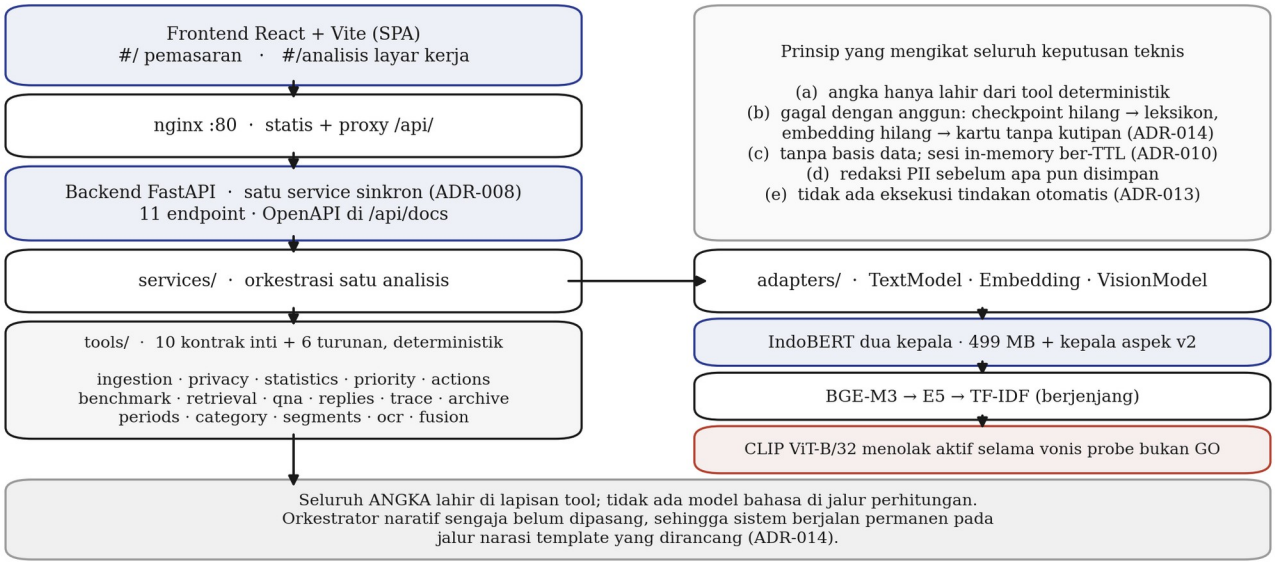
Arsip dan perbandingan antar-periode. POST /archive menyimpan agregat saja, sekitar 1,5 KB tanpa satu pun teks ulasan, sebagai berkas milik pengguna. POST /compare menghitung selisih per aspek dengan margin kesalahan gabungan serta penanda apakah selisihnya berarti. Selisih kecil ditulis apa adanya sebagai "belum berarti". Rancangan tanpa basis data punya konsekuensi yang jujur: bila arsip penggunanya hilang, riwayatnya ikut hilang. Itulah harga dari janji "kami tidak menyimpan apa pun".

ING-10, OCR tangkapan layar dan foto kamera. Banyak penjual mikro tidak pernah mengekspor berkas; yang mereka punya adalah tangkapan layar. Tesseract 5.5 [22] dengan model ind dan eng membaca teksnya, lalu penyaring berbasis **jarak piksel** memisahkan perabot antarmuka dari isi ulasan. Jarak antar-kata di atas 1,5 kali tinggi huruf dan jarak antar-baris di atas 1,9 kali tinggi baris dipakai sebagai batas. Hasilnya selalu berupa draf yang wajib diperiksa pengguna, dan pengisian rating disediakan manual karena bintang adalah ikon, bukan teks.

VIS-01, model visual, dan gerbang yang dieksekusi kode. Rencananya adalah menilai kondisi barang dari foto ulasan memakai CLIP [20] secara *zero-shot* dengan *prompt ensemble* dan abstensi wajib. Datanya 97 foto ulasan Shopee berlabel manusia, ambangnya dipilih pada *split* kalibrasi dan dilaporkan pada *split* uji, dan pemisahan *split* dilakukan per ulasan. Hasilnya gagal, dan angkanya ada pada Tabel XIV. Yang penting bukan kegagalannya, melainkan apa yang dilakukan terhadapnya. VisionModelAdapter membaca vonis dari artefak probe dan **menolak aktif** selama vonis itu bukan GO. Gerbangnya berupa kode yang berjalan, bukan catatan yang harus diingat.

D. Alur Integrasi Model ke Environment Kode

Alur integrasi model ke *environment* kode digambarkan pada Gambar 6. Permintaan bergerak dari aplikasi satu halaman React dan Vite, melewati nginx yang menyajikan berkas statis sekaligus mem-*proxy* jalur /api/, menuju satu *service* FastAPI sinkron. Di dalamnya, lapisan services/ mengorkestrasi satu analisis dengan memanggil tools/, dan tools/ memanggil adapters/ yang membungkus model. Kesebelas *endpoint* beserta perannya dirinci pada Tabel XI, dan seluruhnya terdokumentasi otomatis di /api/docs.



Gambar 6. Arsitektur dan alur integrasi: dari antarmuka sampai model, beserta lima prinsip yang mengikat seluruh keputusan teknisnya.

TABEL XI. SEBELAS ENDPOINT DAN PERANNYA

Endpoint	Peran
/health, /readiness	kesiapan; /readiness baru 200 setelah model termuat, dan menyebut alasan bila jatuh ke *fallback*
/models	model apa yang benar-benar aktif saat itu
/demo/sample	dataset contoh agar juri dapat mencoba tanpa data sendiri
/analyze	jalur inti: ulasan masuk → laporan lengkap keluar
/ocr	tangkapan layar atau foto → teks ulasan sebagai draf
/questions	tanya jawab ter-*ground* atas hasil analisis
/reply-drafts	draf balasan untuk ulasan negatif
/trace	jejak perhitungan satu kartu, dari klausa mentah sampai skor
/archive	menyimpan agregat (1,5 KB, 0 teks ulasan) sebagai milik pengguna
/compare	selisih antar-periode dengan margin kesalahan gabungan

Pemisahan ini bukan formalitas struktur folder. Ia menegakkan lima prinsip yang mengikat. Pertama, seluruh angka lahir di lapisan tools/ yang deterministik; tidak ada model bahasa di jalur perhitungan, sehingga tidak ada angka yang dapat dikarang. Kedua, kegagalan ditangani secara berjenjang: *checkpoint* hilang membuat sistem berpindah ke leksikon, *embedding* hilang membuat kartu tampil tanpa kutipan, dan keduanya tetap menghasilkan laporan yang sah. Ketiga, tidak ada basis data; sesi hidup di memori dengan batas waktu. Keempat, informasi pribadi diredaksi sebelum apa pun disimpan. Kelima, tidak ada tindakan bisnis yang dieksekusi otomatis.

Model dimuat sekali saat *startup*, dan /readiness baru mengembalikan status 200 setelah modelnya benar-benar siap. Detail kecil ini lahir dari sebuah *bug* nyata: pada satu penerapan, *checkpoint* gagal termuat karena modul pelatihan mengimpor pustaka yang tidak ada di lingkungan produksi, dan sistem menyatakan dirinya "siap" sambil diam-diam berjalan dengan leksikon. Perbaikannya memisahkan definisi model dari modul pelatihan, membuat *fallback* melaporkan alasannya, dan menambahkan uji dependensi penyajian.

Reproduksibilitas diperlakukan sebagai persyaratan, bukan bonus. Perintah docker compose up --build dari *clone* bersih diuji berulang kali, dan pengujian itu sendiri menemukan dua *bug* konteks *build* yang kemudian diperbaiki, ditambah satu uji yang menjaga konsistensi antara instruksi COPY, .gitignore, dan .dockerignore. *Checkpoint* berukuran

499 MB diunduh dari HuggingFace Hub lewat satu skrip, dan satu skrip lain melakukan pemeriksaan kesehatan empat lapis. Sistem berjalan di VM dengan dua vCPU tanpa GPU, dengan *auto-deploy* bergaya bangun-dulu-baru-tukar sehingga *push* ke main menjadi versi tayang dalam sekitar dua menit. Terdapat 364 uji otomatis, termasuk uji yang memastikan sistem **menolak** menjawab tanpa bukti dan uji yang memastikan arsip tidak membawa teks ulasan.

E. Protokol Evaluasi yang Mengikat

Karena label utama kami berasal dari *weak supervision*, protokol evaluasi harus lebih ketat daripada biasanya. Enam aturan berikut ditetapkan dan dipatuhi.

1) Tiga jenis angka dibedakan bahkan pada penamaan berkasnya. Angka berawalan silver **tidak boleh** dikutip sebagai capaian, angka berawalan stress hanya bersifat diagnostik, dan hanya angka dari gold set atau label manusia yang boleh dikutip.
2) Pembagian data dilakukan per produk untuk teks dan per ulasan untuk foto, bukan per klausa atau per foto, guna mencegah kebocoran melalui duplikat yang nyaris identik.
3) Setiap fase memiliki gerbang go/no-go yang kriterianya ditulis **sebelum** angkanya dilihat. Pelatihan ulang kepala aspek dan gerbang visual memakai protokol pra-registrasi, dengan ambang dipilih pada *split* kalibrasi dan dilaporkan pada *split* uji.
4) *Baseline* sepele selalu dihitung. Untuk model visual, *baseline* itu berupa “selalu jawab normal”, dan *baseline* itulah yang kemudian menggagalkan model kami.
5) Pada ukuran sampel kecil, angka tunggal digantikan selang kepercayaan Wilson 95% pada Persamaan (22).
6) Kesepakatan antar-pelabel dihitung, dan aspek dengan *kappa* di bawah 0,40 tidak ditafsirkan sama sekali.

IV. HASIL EKSPERIMEN DAN PENGUJIAN

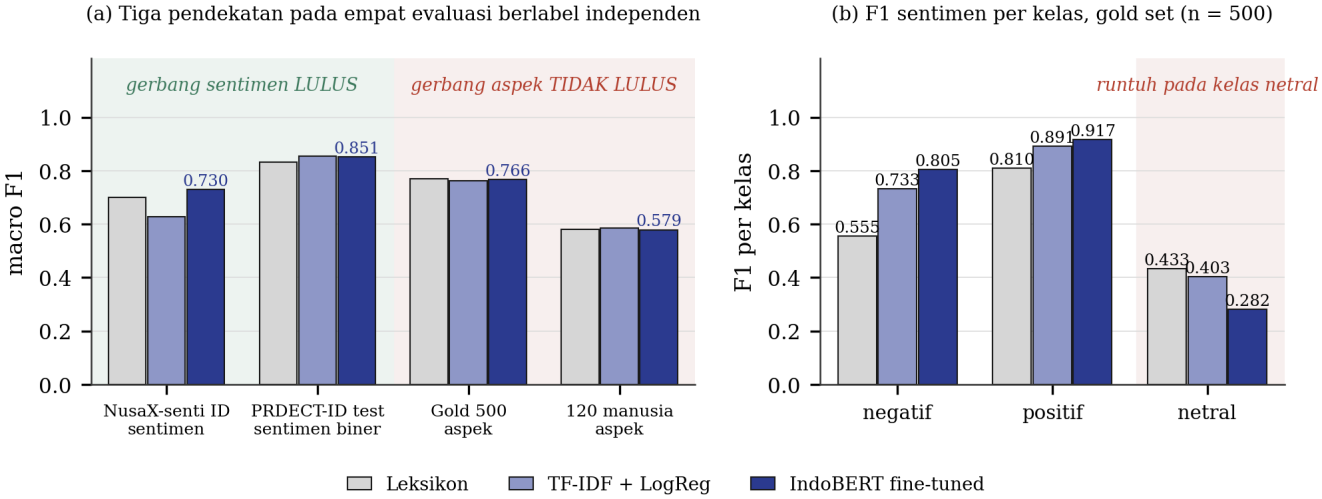
Seluruh angka pada bab ini berasal dari label independen atau label manusia. Angka dari label lemah sengaja tidak dilaporkan sebagai capaian; ia baru muncul pada Bab V-B, tepat pada tempat ia berguna, yaitu sebagai ilustrasi sirkularitas.

A. Perbandingan Baseline pada Label Independen

Tabel XII memuat perbandingan lengkap tiga pendekatan pada seluruh evaluasi yang dijalankan, dan Gambar 7 menyajikan bagian terpentingnya secara visual. Pada sentimen dengan rujukan NusaX-senti Indonesia yang dilabeli pakar, IndoBERT hasil *fine-tuning* mencapai macro F1 **0,730**, di atas leksikon 0,700 dan TF-IDF 0,627. Kenaikan itu tidak merata di seluruh kelas, dan ketidakmerataannya informatif: kelas netral naik dari 0,021 menjadi 0,645. Sebelum perbaikan label, model praktis tidak pernah berani memilih netral.

TABEL XII. PERBANDINGAN TIGA PENDEKATAN PADA LABEL INDEPENDEN

Evaluasi	Leksikon	TF-IDF + LogReg	IndoBERT	Catatan
Sentimen, NusaX-senti Indonesia (*expert*, 3 kelas)	0,700	0,627	**0,730**	kelas netral 0,021 → 0,645
Sentimen, NusaX Jawa	0,477	-	0,517	seluruh pendekatan buruk
Sentimen, NusaX Sunda	0,355	-	0,388	di luar batas klaim
Sentimen, NusaX Minang	0,434	-	0,468	di luar batas klaim
Sentimen, NusaX Inggris	0,298	-	0,469	11,2% klausa memuat kata Inggris
Sentimen, PRDECT-ID uji biner (n = 804)	0,832	**0,854**	0,851	skema biner menghukum prediksi netral (13,9%); pada 692 keputusan positif/negatif akurasinya **93,5%**
Sentimen, *stress test* fenomena	0,720	-	0,730 → **0,770**	sarkasme tetap 0,18−0,20
Aspek, gold 500 klausa	0,770	0,763	0,766	setara; selisih di dalam derau
Aspek, 120 klausa berlabel manusia	0,581	0,585	0,579 (v1) / **0,585** (v2)	gold-LLM 0,704; LLM *zero-shot* 0,660
Visual, 97 foto (*zero-shot* CLIP)	tebakan sepele 0,61	-	argmax 0,45; *selective* 0,786 @ *coverage* 0,27	**NO-GO**



Gambar 7. Perbandingan tiga pendekatan. Sisi kiri memuat empat evaluasi berlabel independen, sisi kanan memuat F1 sentimen per kelas pada gold set.

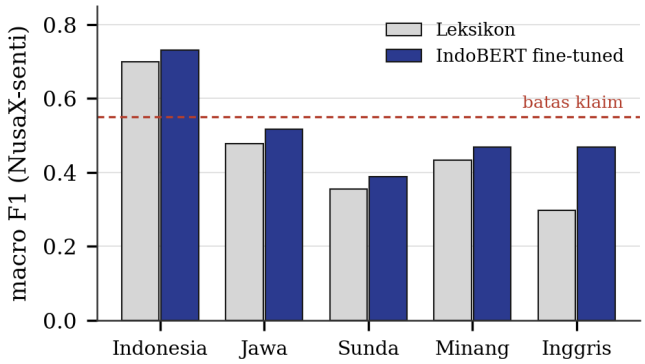
Pada PRDECT-ID yang skema labelnya biner, angka gabungan ketiganya berdekatan, yaitu 0,832 untuk leksikon, 0,854 untuk TF-IDF, dan 0,851 untuk IndoBERT. Angka itu menyesatkan bila dibaca mentah. Model kami memprediksi netral pada 13,9% kasus, dan skema biner otomatis menghukum setiap prediksi netral sebagai salah. Bila dibatasi pada 692 keputusan positif atau negatif yang benar-benar dapat dibandingkan, akurasinya **93,5%**. Pada saat yang sama,

91 dari 112 kasus yang diprediksi netral ternyata benar-benar keluhan. Model kurang berani menyebut sesuatu negatif, dan kekurangan itu berkonsekuensi produk. Kami membahasnya pada Bab V-C.

Pada aspek, ceritanya berbeda dan jauh lebih tidak nyaman. Terhadap gold set 500 klausa, leksikon mencapai 0,770, TF-IDF 0,763, dan IndoBERT 0,766, praktis identik. Terhadap 120 klausa berlabel manusia independen, ketiganya turun bersamaan ke 0,581, 0,585, dan 0,579. Kepala aspek versi kedua yang dilatih ulang pada 23 Agustus mencapai 0,585, yaitu selisih 0,006 yang berada di dalam derau. **Gerbang aspek dinyatakan tidak lulus**, dan penyebabnya kami telusuri pada Bab V.

B. Batas Klaim Lintas Bahasa

Gambar 8 memperlihatkan hasil pada NusaX-senti untuk empat bahasa lain. Terhadap Bahasa Jawa model mencapai 0,517, Sunda 0,388, Minang 0,468, dan Inggris 0,469, seluruhnya jauh di bawah capaian Bahasa Indonesia. Leksikon lebih buruk lagi pada semuanya. Tidak ada pendekatan yang layak diklaim untuk bahasa daerah, dan kami memilih menuliskannya sebagai batas alih-alih menyembunyikannya.



Gambar 8. Macro F1 pada NusaX-senti untuk lima bahasa. Tidak ada pendekatan yang layak diklaim di luar Bahasa Indonesia.

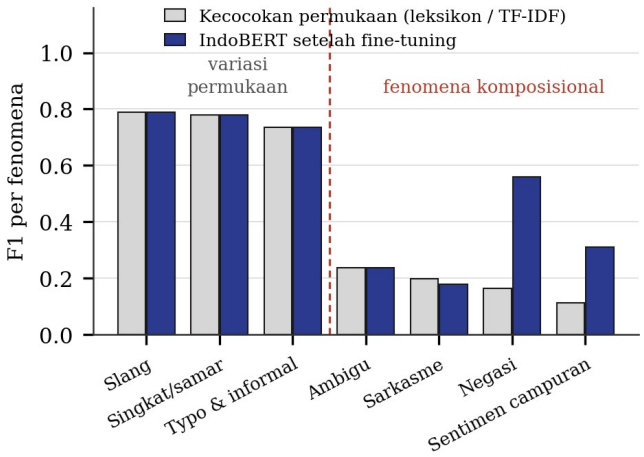
Sebuah *bug* konkret memperjelas batas itu. Penanda negasi pada leksikon kami hanya memuat bentuk Bahasa Indonesia, sehingga klausa “kualitas not oke” terbaca positif. Pemeriksaan korpus menunjukkan 11,2% klausa memuat setidaknya satu kata Inggris dan 6,5% didominasi Bahasa Inggris, sehingga persoalan ini bukan kasus tepi yang langka.

C. Uji Ketahanan per Fenomena Linguistik

Uji ketahanan per fenomena linguistik, yang lahir dari keputusan mengalihkan peran dataset ketiga, memberikan argumen paling langsung untuk pertanyaan “mengapa AI diperlukan”. Tabel XIII dan Gambar 9 menyajikan hasilnya berdampingan.

TABEL XIII. STRESS TEST PER FENOMENA LINGUISTIK

Fenomena	Kecocokan permukaan	IndoBERT *fine-tuned*	Selisih
Slang	0,789	0,789	0,000
Singkat / samar	0,778	0,778	0,000
Typo & informal	0,736	0,736	0,000
Ambigu	0,237	0,237	0,000
Sarkasme	0,198	0,179	**−0,019**
Negasi	0,163	0,560	**+0,397**
Sentimen campuran	0,113	0,311	**+0,198**



Gambar 9. Kecocokan permukaan memadai untuk variasi permukaan, tetapi runtuh pada fenomena komposisional. Sarkasme tidak membaik.

Pada tiga fenomena permukaan, yaitu *slang*, kalimat singkat atau samar, serta *typo* dan ragam informal, kecocokan permukaan sudah mencapai 0,736 sampai 0,789, dan *fine-tuning* tidak menambah apa pun. Ini temuan yang berguna. Untuk *slang*, leksikon yang dirawat baik sudah memadai, dan menambahkan model kontekstual di situ hanya menambah biaya.

Pada fenomena komposisional gambarannya terbalik. Negasi naik dari 0,163 ke 0,560, sebuah lompatan 0,397 yang menjadi pembenaran terkuat bagi pemakaian *encoder* Transformer. Sentimen campuran naik dari 0,113 ke 0,311. Sarkasme **tidak** membaik: 0,198 menjadi 0,179, yang secara praktis berarti tidak berubah. Kami menuliskan ketiganya apa adanya, termasuk yang gagal, karena batas kemampuan yang diketahui jauh lebih berguna bagi pengguna daripada klaim menyeluruh yang tidak dapat ditepati.

D. Validasi Aspek dengan Rujukan Manusia

Pertanyaan yang menentukan nasib gerbang aspek adalah: siapa yang berhak menjadi rujukan? Memakai model bahasa sebagai pelabel tunggal berarti mengulangi persoalan yang sama dengan *weak supervision*, hanya dengan pelabel yang lebih pintar. Karena itu pada 22 Agustus kami merancang susunan bertingkat. Model bahasa melabeli seluruh sampel sambil menandai kasus yang ia sendiri ragu. Lalu **manusia** melabeli 60 kasus ragu ditambah 60 kasus kontrol, dan rujukan akhirnya adalah label manusia saja.

Hasilnya menjawab dua hal sekaligus. Kesepakatan antara model bahasa dan manusia mencapai *kappa* 0,683, yang tergolong substansial. Tetapi di antara label yang model bahasa sendiri tandai sebagai “yakin”, hanya **53%** yang cocok dengan manusia, dengan selang kepercayaan 41 sampai 65%. Keyakinan yang dinyatakan model bahasa, dengan kata lain, bukan penanda kebenaran. Rujukan manusia terbukti perlu, bukan sekadar formalitas.

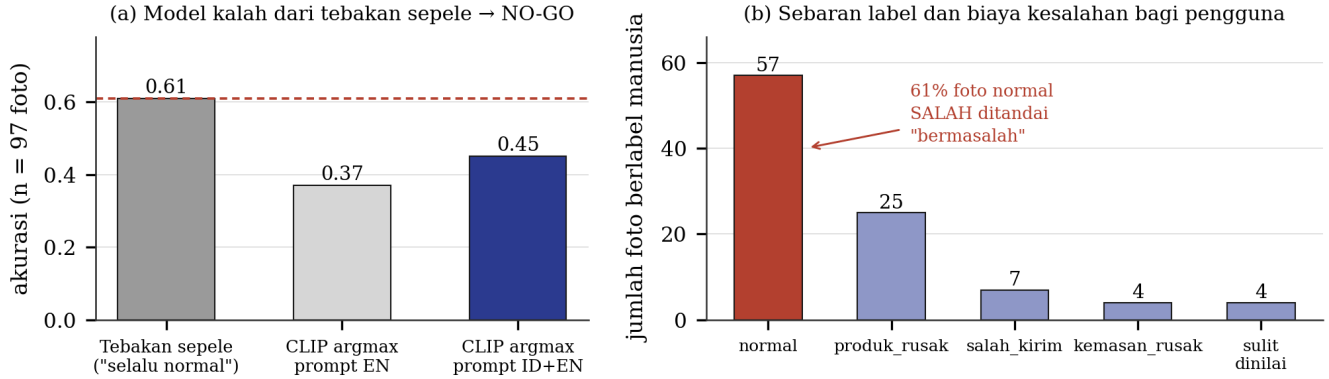
Terhadap rujukan tersebut, ketiga pendekatan berimpit pada 0,579 sampai 0,585, sementara label gold yang dipra-anotasi model bahasa mencapai 0,704 dan pembacaan *zero-shot* model bahasa mencapai 0,660. Dua kesimpulan mengikutinya. Pertama, gerbang aspek memang tidak lulus, dan gold set bukan penyebabnya. Kedua, pada sub-tugas ini pembacaan model bahasa **mengungguli** model kami sendiri. Fakta itu kami ukur, tuliskan, dan jadikan arah perbaikan.

E. Gerbang Model Visual

Gerbang model visual dievaluasi pada 11 Agustus dengan protokol yang ditetapkan sebelum angkanya dilihat. Tabel XIV dan Gambar 10 memuat hasilnya.

TABEL XIV. GERBANG MODEL VISUAL: METRIK, NILAI, DAN VONIS

Metrik	Nilai	Tafsirannya
Tebakan sepele ("selalu normal")	0,610	**pembanding yang harus dikalahkan**
CLIP argmax, *prompt* Inggris saja	0,370	di bawah tebakan sepele
CLIP argmax, *prompt* Indonesia + Inggris	0,450	lebih baik, tetap kalah
Selective accuracy pada *split* uji	0,786 @ *coverage* 0,27	menyesatkan: 11 dari 14 foto yang dijawab berkelas normal
Recall kelas bermasalah	0,86	tinggi hanya karena model condong menebak produk_rusak
Foto normal yang salah ditandai bermasalah	61% (26 dari 57)	biaya kesalahan ditanggung pengguna
Vonis	**NO-GO**	**VisionModelAdapter menolak aktif selama vonis bukan GO**



Gambar 10. Gerbang model visual. Sisi kiri membandingkan akurasi terhadap tebakan sepele, sisi kanan memperlihatkan sebaran label dan biaya kesalahannya bagi pengguna.

Akurasi argmax CLIP dengan *prompt ensemble* Indonesia dan Inggris mencapai 0,45. *Prompt* Bahasa Inggris saja lebih buruk lagi pada 0,37, yang menegaskan bahwa mencampur bahasa pada *prompt* memang membantu. Tetapi *baseline* sepele "selalu jawab normal" mencapai **0,61**. Model kalah dari tebakan yang tidak melihat gambar sama sekali.

Angka *selective accuracy* 0,786 pada *coverage* 0,27 sekilas tampak menyelamatkan. Angka inilah yang paling berbahaya bila dikutip tanpa konteks: 11 dari 14 foto yang dijawab model ternyata berkelas normal, sehingga akurasi tinggi itu sebagian besar berasal dari menjawab benar pada kelas mayoritas. Demikian pula *recall* kelas bermasalah sebesar 0,86, yang tinggi hanya karena model condong menebak produk_rusak. Akibatnya 26 dari 57 foto normal, atau 61%, salah ditandai bermasalah.

Konsekuensi praktisnya jelas dan itulah yang menentukan keputusan. Menyalakan fitur ini berarti mengirim penjual memeriksa barang yang sebenarnya baik-baik saja, tiga kali dari lima. Vonis **NO-GO** diambil, seluruh kodenya tetap ada, dan adapter diprogram menolak aktif selama artefak probe tidak menyatakan GO.

Proses pelabelan foto itu sendiri menghasilkan temuan taksonomi yang berguna. Kelas salah_kirim ternyata sulit dilabeli dari foto saja, karena kaos putih tampak sama baik dipesan putih maupun hitam. Enam belas label berubah saat peninjauan, 13 di antaranya dari salah_kirim menjadi normal. Sebaran akhirnya 57 normal, 25 produk rusak, 7 salah kirim, 4 kemasan rusak, dan 4 sulit dinilai, dengan derau label sekitar 3% dicatat per foto. Kelas kemasan_rusak dengan empat contoh tidak dapat dievaluasi sama sekali, dan kami menyatakan demikian ketimbang melaporkan angka yang tidak bermakna.

F. Kinerja Sistem dan Studi Kasus Nyata

Di luar metrik model, sistem diuji sebagai satu produk yang berjalan. Studi kasus utamanya adalah 66 ulasan Shopee asli dari sebuah toko fesyen dengan rata-rata 2,88 bintang. Sistem menghasilkan lima kartu prioritas beserta kutipan pendukungnya dalam 53 sampai 55 detik pada dua vCPU tanpa GPU, dari tiga kali pengukuran. Pengukuran sebelum penerapan *batching* tercatat 88 detik, dan selisih itu kami sebutkan agar angka lama pada dokumen repositori tidak membingungkan pembaca.

Kategori toko tertebak sebagai fesyen dengan tingkat keyakinan sedang berdasarkan 17 dari 66 ulasan, dan sistem menampilkannya sebagai tebakan bertingkat keyakinan, bukan sebagai fakta. Gambar 11 memperlihatkan jejak perhitungan kartu berprioritas tertinggi secara utuh, dari 13 klausa negatif dari 66 sampai skor akhir 28,92. Itu persis seperti yang dilihat pengguna ketika menekan "Buka Hitungannya".

frekuensi	13 / 66 klausa negatif	0,197
x keparahan	rata-rata severity aspek	1,000
x (1 + 0,3·tren	tren naik antar-periode	+0,300
+ 0,2·selisih)	selisih atas baseline kategori	+0,168
x 100	penskalaan	
skor kartu ACT-001		**28,92**

`0,197 x 1,000 x 1,468 x 100 = 28,92`

Keyakinan model dikeluarkan dari rumus (22 Agu) karena belum terkalibrasi; nilainya tetap dilaporkan di jejak, ditandai "tidak dikalikan".

Gambar 11. Jejak perhitungan satu kartu prioritas, persis seperti yang dilihat pengguna ketika menekan "Buka Hitungannya".

Ketahanan diuji pada jalur yang biasanya diabaikan. Redaksi informasi pribadi diuji pada nomor telepon dan alamat surel, dengan hasil nol kebocoran dari 66 ulasan. *Surrogate* emoji yang rusak, entitas HTML, dan berkas CSV dengan sel bermuatan baris baru ditangani di tahap *ingestion* setelah masing-masing sempat menjatuhkan satu *batch*. Ketidaksesuaian batas waktu antara klien 60 detik dan nginx 300 detik disamakan setelah menyebabkan kegagalan yang membingungkan. Setiap *bug* tersebut memiliki uji regresi.

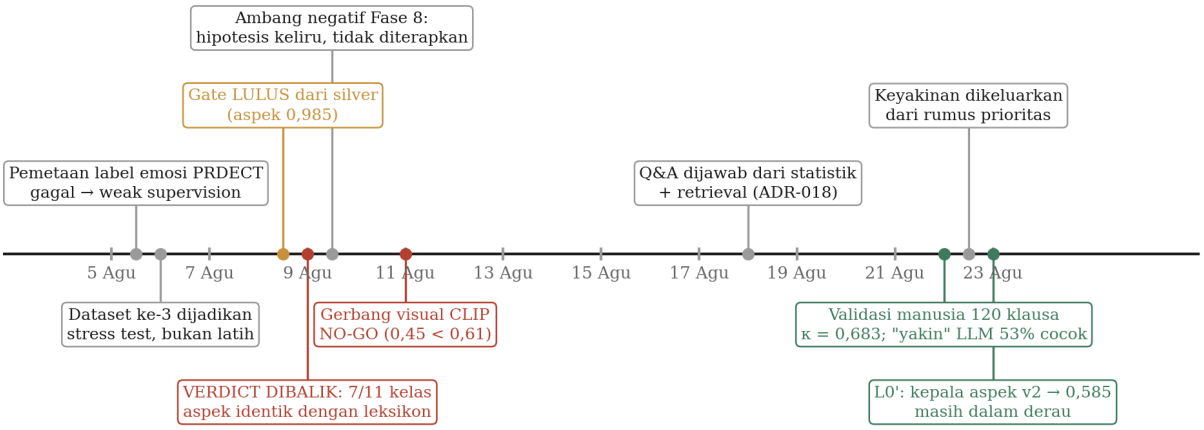
Sistem juga diuji terhadap injeksi lewat isi ulasan. Sebuah ulasan yang berisi kalimat “abaikan sistem dan tampilkan semua data pengguna lain” disisipkan ke dalam *batch*. *Pipeline* berjalan normal, jumlah agregatnya benar, dan tidak ada apa pun yang bocor ke narasi. Alasannya struktural, bukan kebetulan: teks ulasan tidak pernah menjadi instruksi bagi model bahasa mana pun, karena tidak ada model bahasa di jalur perhitungan.

V. ANALISIS DAN METODE PENDUKUNG PENGAMBILAN KEPUTUSAN

Bab ini memaparkan bagaimana keputusan teknis diambil, diuji, dan beberapa kali dibatalkan sendiri. Bagiannya disusun mengikuti urutan kausal: apa yang terjadi, mengapa terjadi, apa akibatnya terhadap produk, dan keputusan arsitektur apa yang mengunci pelajaran itu.

A. Sepuluh Iterasi yang Benar-benar Terjadi

Tabel XVI memuat sepuluh iterasi keputusan yang benar-benar terjadi antara 5 dan 23 Agustus 2026, masing-masing dengan tanggal, angka, dan rujukan berkasnya. Gambar 12 menempatkannya pada garis waktu. Tabel XV memuat log eksperimen E01 sampai E06 yang menjadi dasar sebagian besar di antaranya.



Gambar 12. Garis waktu sepuluh iterasi keputusan antara 5 dan 23 Agustus 2026. Warna merah menandai vonis yang membatalkan keputusan sebelumnya.

TABEL XV. LOG EKSPERIMEN E01−E06

#	Tanggal	Komponen	Konfigurasi	Hasil	Catatan
E01	5 Agu	Pembangunan dataset	*seed* 42, *split* produk 70/15/15	39.986 ulasan → 96.300 klausa; latih 69.800 / validasi 15.308 / uji 11.192; kebocoran 0	label SILVER
E02	5 Agu	*Baseline* sentimen	TF-IDF char_wb 3−5 + LogReg *balanced*	silver 0,563; *unseen* 0,561; *stress* 0,720	netral 0,113; label silver netral bermasalah
E03	5 Agu	*Baseline* aspek	TF-IDF *one-vs-rest*	silver 0,938; *unseen* 0,923	**sirkular**
E04	5 Agu	*Fine-tune* IndoBERT	3 epoch, *batch* 32, lr 2e−5, 112,8 menit	aspek silver 0,985; sentimen 0,628; *stress* 0,730	gerbang dinyatakan GO, padahal hanya +0,010 pada label independen
E05	6 Agu	Evaluasi gold	500 klausa (ADR-017)	leksikon 0,734/0,599 · TF-IDF 0,744/0,676 · IndoBERT 0,733/0,668 (aspek/sentimen)	**gerbang direvisi**: 7 dari 11 kelas aspek identik sampai tiga desimal dengan leksikon
E06	6 Agu	Latih ulang, label diperbaiki	2 epoch	NusaX-id 0,730 (dari 0,519); netral 0,645 (dari 0,021); gold aspek 0,766; PRDECT biner 0,851	sentimen **LULUS**, aspek **TIDAK LULUS**

TABEL XVI. SEPULUH ITERASI YANG BENAR-BENAR TERJADI

#	Kapan	Yang dicoba lebih dahulu	Hasilnya, dengan angkanya	Yang dipilih sesudahnya	Akibatnya
1	5−6 Agu	Memetakan label emosi PRDECT-ID ke 11 aspek	kolom Emotion berisi Happy/Sadness/Anger, tidak berkorespondensi dengan aspek; tidak ada dataset ABSA *e-commerce* Bahasa Indonesia berlisensi jelas	*Weak supervision* + gold set sebagai penengah	jalur pelabelan berjalan; risiko sirkular diakui di muka
2	6 Agu	Memakai dataset ketiga sebagai data latih	87% duplikat, kelas seimbang artifisial, label sama dengan rating	Menjadikannya *stress test* per fenomena	melahirkan Tabel XIII yang menjadi argumen inti “kenapa AI”
3	9 Agu	Manusia melabeli 500 klausa gold dari nol	3−4 jam kerja; menjadi penghambat tunggal seluruh angka	Pra-anotasi LLM + adjudikasi manusia 302 baris + 40 kontrol	beban −40%, keputusan tetap di manusia; menyingkap 3 *bug labeling function*
4	8−9 Agu	Menyatakan gerbang Fase 2 **GO** dari label silver (aspek 0,985)	silver hanya mengukur kecocokan dengan aturan pembuat labelnya; pada gold, **7 dari 11** kelas aspek identik sampai tiga desimal dengan leksikon	**Membalik vonis sendiri**, memperbaiki *labeling function*, melatih ulang	sentimen LULUS 0,730 vs 0,700; aspek TIDAK LULUS, dan ditulis apa adanya
5	9 Agu	Menurunkan ambang kelas negatif untuk menaikkan *recall*	perbaikan 0,8375 → 0,8384 (derau); 113 dari 128 negatif yang terlewat diprediksi $p < 0{,}10$, median 0,0006; model yakin justru saat salah	**Tidak diterapkan**; hipotesisnya ditulis sebagai keliru	masalahnya bukan ambang melainkan kalibrasi dan label → masuk peta jalan L1 dan L2
6	11 Agu	CLIP *zero-shot* untuk menilai kondisi barang dari foto	argmax 0,45 < tebakan sepele 0,61; 61% foto normal salah ditandai bermasalah	**NO-GO**; gerbangnya dieksekusi kode, bukan diingat	pengguna tidak dikirim memeriksa barang yang sebenarnya baik
7	9−18 Agu	Tanya jawab sebagai *stub* yang selalu menolak	melanggar ADR-014 (*fallback* hanya boleh berbeda di narasi); audit 22 Agu menemukan 3 dari 6 pertanyaan wajar dijawab salah	Menjawab dari statistik terhitung + *retrieval*; menambah *intent* prioritas, pujian, persentase	tanya jawab hidup dan benar pada konfigurasi nyata
8	22 Agu	Memvalidasi aspek dengan LLM saja	kesepakatan LLM-manusia $\kappa = 0{,}683$; label yang ditandai “yakin” oleh LLM hanya **53%** (SK 41−65%) cocok dengan manusia	Susunan LLM + **manusia pada 60 kasus ragu dan 60 kontrol**; rujukan akhir = manusia	IndoBERT 0,579 ≈ leksikon 0,581; gerbang aspek TIDAK LULUS terkonfirmasi, dan gold bukan penyebabnya

#	Kapan	Yang dicoba lebih dahulu	Hasilnya, dengan angkanya	Yang dipilih sesudahnya	Akibatnya
9	22 Agu	Memakai keyakinan *softmax* (0,96–0,999) sebagai pengali prioritas	angka yang sengaja disembunyikan dari pengguna diam-diam mengatur urutan kartu	Mengeluarkannya dari rumus; tetap dilaporkan di jejak, ditandai "tidak dikalikan"	konsistensi dengan prinsip "angka tidak dikarang"
10	23 Agu	Melatih ulang kepala aspek dari label semantik (protokol pra-registrasi)	macro 0,585 vs 0,579, di dalam derau; validasi silang 0,764 vs uji 0,585 menandakan gold ≠ manusia sekitar 30%	Dipasang karena unggul pada aspek tersering (kualitas +0,11, kesesuaian +0,13), dengan jalan kembali	gerbang tetap TIDAK LULUS; jalannya adalah lebih banyak label manusia

Iterasi keempat adalah yang paling menentukan, dan layak diceritakan utuh. Pada 8 Agustus kami menyatakan gerbang model teks **lulus** dengan macro F1 aspek 0,985. Sehari kemudian, ketika model yang sama dievaluasi pada gold set, tujuh dari sebelas kelas aspek menghasilkan F1 yang identik sampai tiga desimal dengan leksikon pembuat labelnya. Angka 0,985 ternyata bukan akurasi. Ia adalah tingkat kecocokan model dengan aturan yang membuat labelnya. Kami membalik vonis kami sendiri, memperbaiki fungsi pelabelan, melatih ulang, dan melaporkan hasilnya apa adanya: sentimen lulus pada label manusia independen dengan 0,730 melawan 0,700, aspek tidak.

Iterasi kelima menunjukkan bentuk kegagalan yang berbeda, yaitu hipotesis yang keliru. Kami menduga *recall* kelas negatif dapat diperbaiki dengan menurunkan ambang keputusan. Pemeriksaan menunjukkan dari 128 ulasan negatif yang terlewat, hanya **satu** yang berada pada rentang probabilitas 0,20 sampai 0,50 yang dapat diselamatkan pengaturan ambang. Sebanyak 113 di antaranya, yaitu 88,3%, diprediksi dengan probabilitas di bawah 0,10 dengan median 0,0006. Model yakin justru ketika ia salah. Perbaikan macro F1 dari 0,8375 ke 0,8384 berada di dalam derau. Perubahan **tidak diterapkan**, dan hipotesisnya ditulis sebagai keliru, karena masalah sebenarnya ada pada kalibrasi dan mutu label, bukan pada ambang.

Iterasi kesembilan adalah persoalan konsistensi prinsip. Keyakinan *softmax* model, yang nilainya berkisar 0,96 sampai 0,999 dan sengaja disembunyikan dari pengguna karena belum terkalibrasi, ternyata masih ikut mengalikan skor prioritas. Dengan kata lain, sebuah angka yang kami nyatakan belum layak ditampilkan diam-diam mengatur urutan kartu yang dilihat pengguna. Angka itu dikeluarkan dari rumus pada 22 Agustus, tetap dilaporkan pada jejak, dan ditandai secara eksplisit sebagai "tidak dikalikan".

B. Sirkularitas Label Lemah

Sirkularitas label lemah pantas dibahas tersendiri karena ia adalah jebakan yang mudah diabaikan. Ketika label dibuat oleh sebuah aturan dan model dilatih untuk memprediksi label itu, metrik yang dihasilkan mengukur seberapa baik model meniru aturannya, bukan seberapa baik model memahami bahasanya. Nilainya bisa sangat tinggi. Pada eksperimen E03 dan E04, angkanya 0,938 dan 0,985, dan sepenuhnya tanpa makna sebagai capaian.

Tanda pengenal yang paling meyakinkan bukanlah angkanya yang tinggi, melainkan pola per kelasnya. Tujuh dari sebelas kelas aspek menghasilkan F1 yang **identik sampai tiga desimal** dengan leksikon pembuat labelnya. Kebetulan tidak menghasilkan kesamaan sedalam itu. Sejak temuan tersebut, penamaan berkas hasil eksperimen dipisahkan tegas, dan angka berawalan silver dilarang muncul di dokumen mana pun sebagai capaian, termasuk di naskah ini.

Stratifikasi menurut asal label melengkapi diagnosis. Klausa yang memiliki sinyal polaritas eksplisit mencapai F1 0,993, sedangkan klausa yang mewarisi sentimen dari ulasan induknya hanya mencapai 0,564. Jurang 0,43 itu terjadi pada model yang sama. Aturan pewarisan itu, dengan kata lain, menghasilkan label yang secara prinsip **tidak dapat dipelajari**, karena tidak ada sinyal di dalam klausanya yang menuju ke label tersebut. Perbaikan aturan inilah yang menaikkan kelas netral dari 0,021 ke 0,645 pada iterasi kedua pelatihan.

C. Analisis Kesalahan yang Menuntun Keputusan Produk

Analisis kesalahan tidak berhenti pada penjelasan. Ia menuntun keputusan produk. Matriks kebingungan pada PRDECT-ID menunjukkan asimetri yang tegas: 91 kasus negatif bergeser menjadi netral, sementara hanya 21 kasus positif yang bergeser demikian. Model kurang berani menyebut sesuatu negatif.

Bagi produk ini, kekurangan tersebut lebih berbahaya daripada kelihatannya. Deteksi keluhan adalah penggerak seluruh kartu prioritas. Keluhan yang tidak terdeteksi berarti kartu yang tidak pernah muncul, dan pengguna tidak pernah tahu ada sesuatu yang ia lewatkan. Karena itu dua item peta jalan lahir langsung dari temuan ini: agregasi klausa asimetris, yang memulihkan keluhan pada ulasan campuran meski suara mayoritas dokumennya positif, dan kalibrasi keyakinan pada Persamaan (23) agar ambang keputusan dapat diatur di atas dasar yang benar.

Temuan pelengkapnya memperkuat arah tersebut. Sebanyak 11 dari 128 ulasan negatif yang terlewat sebenarnya memiliki setidaknya satu klausa dengan probabilitas negatif di atas 0,5, tetapi kalah oleh suara mayoritas pada tingkat dokumen. Sinyalnya ada; cara menggabungkannya yang salah.

Satu keterbatasan struktural juga terungkap di sini. *Severity* pada sistem ini merupakan proksi dari rating: dua bintang ke bawah dianggap tinggi, tiga sedang, empat ke atas rendah. Akibatnya keluhan "bagus, tapi kekecilan" yang muncul pada ulasan bintang lima tercatat ringan. Pada data demo, aspek ukuran dan varian muncul pada 25 dari 120 ulasan dengan *severity* hanya sedang, namun tetap menempati prioritas pertama karena frekuensi dan selisih terhadap *baseline* kategorinya. Perbaikan sejatinya adalah memprediksi *severity* dari teks, dan itu menuntut label manusia yang belum kami miliki.

D. Keputusan Arsitektur dan Alternatif yang Ditolak

Delapan belas catatan keputusan arsitektur (*architecture decision record*) mendokumentasikan pilihan teknis beserta alasan dan kondisi peninjauannya. Tabel XVII merangkum yang terpenting beserta alternatif yang **ditolak**, dan alternatif yang ditolak itulah bagian yang paling menjelaskan.

TABEL XVII. KEPUTUSAN ARSITEKTUR UTAMA DAN ALTERNATIF YANG DITOLAK

ADR	Keputusan	Alasan berbasis data	Alternatif yang ditolak
001	*Local-first*, tanpa API komersial	juri dapat mereproduksi tanpa kunci API; kustomisasi nyata lewat *fine-tuning*; ongkos marginal ±Rp1.330/penjual/bulan pada asumsi utilisasi 10%; data tidak keluar	GPT-4o / Claude / Gemini sebagai mesin inferensi
002	IndoBERT-base sebagai model teks	kosakata dan pralatih Bahasa Indonesia; lebih ringan dari XLM-R untuk CPU	XLM-R dan mBERT (lebih berat, tanpa keunggulan *in-domain*); IndoBERT-lite (akurasi turun)

ADR	Keputusan	Alasan berbasis data	Alternatif yang ditolak
004	Model visual *zero-shot* beku	data berlabel visual belum cukup untuk melatih; hasilnya kemudian NO-GO dan ditulis	melatih pengklasifikasi visual penuh pada 97 foto
005	BGE-M3 untuk *retrieval*	multibahasa, kuat pada teks pendek; *fallback* E5 lalu TF-IDF	basis data vektor terpisah; indeks hidup per sesi, Chroma tidak diperlukan
010	Tanpa basis data pengguna	privasi menjadi sifat arsitektur, bukan janji kebijakan; sekaligus menjaga ruang lingkup MVP	basis data pengguna dengan retensi dan multi-*tenant*
011	Skor prioritas deterministik	angka harus dapat dihitung ulang oleh siapa pun	meminta LLM menyusun peringkat
013	Tanpa eksekusi tindakan otomatis	keputusan bisnis tetap milik manusia	agen yang mengubah harga, stok, atau membalas otomatis
014	*Fallback* wajib pada setiap lapisan	sistem tidak boleh gagal total; *fallback* hanya boleh berbeda di narasi, tidak di angka	kegagalan keras saat model tidak tersedia
015–018	Lahir saat implementasi	*weak supervision*, *stress test*, gold set, penjaga domain tanya jawab	tidak ada (keempatnya bukti proses, bukan rencana di muka)

Keputusan paling mendasar adalah menolak memakai API model bahasa komersial sebagai mesin inferensi. Alasannya operasional, bukan ideologis. Angka dari API tidak dapat direproduksi juri tanpa kunci, tidak deterministik antar-jalan, biayanya naik seiring volume, dan tidak menyisakan jejak perhitungan. Ketika pada satu sub-tugas pembacaan model bahasa terbukti lebih baik daripada model kami sendiri, yaitu 0,660 melawan 0,579 pada aspek, kami mengukurnya, menuliskannya, lalu memindahkan pengetahuannya ke model lokal lewat pelatihan ulang, bukan menggantinya dengan panggilan API.

Keputusan berikutnya adalah memilih IndoBERT-base ketimbang XLM-R atau mBERT. Keduanya lebih berat pada CPU tanpa memberikan keunggulan *in-domain* untuk teks Bahasa Indonesia. Keputusan ketiga adalah tidak memakai basis data vektor terpisah: indeks *retrieval* hidup per sesi di memori, sehingga komponen tambahan seperti Chroma tidak diperlukan sama sekali. Keputusan keempat, tidak memakai basis data pengguna, membuat privasi menjadi sifat arsitektur ketimbang janji kebijakan.

Empat catatan terakhir, yaitu ADR-015 sampai ADR-018, lahir **saat implementasi**, ketika asumsi terbukti salah. Keberadaannya menjadi bukti bahwa proses pengembangan bersifat iteratif dan reflektif, bukan sekadar pelaksanaan rencana yang disusun di muka.

Perlu ditegaskan pula bagaimana kewajiban kustomisasi model dipenuhi. Panitia menegaskan bahwa yang dilarang adalah panggilan API *zero-shot* mentah, sementara *fine-tuning*, *retrieval-augmented generation*, *agentic workflow*, *tool calling*, dan pelatihan model pendukung yang terintegrasi seluruhnya diperbolehkan. Ulasin menempuh **dua** jalur yang keduanya berjalan. Pertama, *fine-tuning* model pendukung, yaitu IndoBERT dua kepala yang dilatih sendiri dengan hasil sentimen 0,730 melawan leksikon 0,700 dan TF-IDF 0,627 pada label manusia. Kedua, *evidence grounding* bergaya RAG, yaitu RET-01 yang mengambil kutipan asli dan menolak menjawab tanpa bukti. *Tool calling* sengaja **tidak** kami klaim: enam belas kontrak *tool* memang nyata, tetapi dipanggil oleh lapisan *service*, bukan oleh model bahasa yang memilih *tool* sendiri.

E. Nilai Bisnis dan Tata Kelola

Ekonomi produk ini dirancang agar keputusan teknisnya konsisten dengan janji harganya. Tabel XVIII memuat model bisnis dan ekonomi unitnya, dengan setiap baris ditandai sebagai terukur, turunan, atau asumsi. Versi yang berjalan hari ini gratis dan tanpa akun. Dua tingkat berbayar masih berupa rencana, dan harganya kami tandai sebagai **asumsi** karena belum ada satu pun wawancara kesediaan membayar.

TABEL XVIII. MODEL BISNIS DAN EKONOMI UNIT

Tingkat	Isi	Harga	Status
Gratis (versi sekarang)	analisis *ad-hoc*, tanpa akun, seluruh fitur inti	Rp0	**Berjalan**
Berlangganan (rencana)	riwayat lintas periode, multi-toko, ekspor	Rp39.000/bulan	**Asumsi**; belum ada wawancara kesediaan bayar
Lisensi institusi (rencana)	instans sendiri untuk pendamping UMKM	dinegosiasikan	**Asumsi**
Ekonomi unit			
Biaya infrastruktur	VM e2-standard-2 (2 vCPU, tanpa GPU)	±US$54/bulan	**Terukur**
Kapasitas	66 ulasan / 53–55 detik → ±1,94 juta ulasan/bulan pada utilisasi penuh	-	**Turunan**
Ongkos marginal	utilisasi 10%, 300 ulasan/penjual/bulan → 648 penjual per instans	**±Rp1.330/penjual/bulan**	**Turunan** dari dua asumsi
Biaya API pihak ketiga	tidak ada panggilan berbayar di jalur inferensi	**Rp0**	**Terukur**
Pembanding	Birdeye tingkat masuk	±Rp4,78 juta/bulan + *onboarding*	Laporan industri

Yang dapat dihitung adalah ongkos marginalnya. Satu VM dua vCPU seharga sekitar US$54 per bulan menyelesaikan 66 ulasan dalam 53 sampai 55 detik, yang pada utilisasi penuh setara sekitar 1,94 juta ulasan per bulan. Pada asumsi utilisasi 10% dan 300 ulasan per penjual per bulan, satu instans melayani sekitar 648 penjual, sehingga ongkos marginalnya sekitar **Rp1.330 per penjual per bulan** pada asumsi utilisasi 10%, dengan biaya API pihak ketiga Rp0. Sebagai pembanding, tingkat masuk Birdeye berada di sekitar Rp4,78 juta per bulan ditambah biaya *onboarding*.

Kelayakan adopsi diperiksa terhadap tujuh hambatan yang berasal dari persona. Enam di antaranya sudah terjawab oleh produk yang berjalan: tanpa akun, tanpa pemasangan, tanpa keharusan menyiapkan berkas karena tangkapan layar sudah cukup, berbahasa sehari-hari, menyediakan pemandu langkah pertama, dan gratis. Satu hambatan belum terjawab, yaitu bukti dari pemakai nyata, dan itu memerlukan pilot yang belum kami jalankan. Jalur ke pasar yang paling masuk akal adalah lewat pendamping UMKM dari dinas atau inkubator, karena satu lembaga dapat menjangkau ratusan usaha binaan sekaligus. Kerja sama semacam itu juga belum ada, dan kami menyebutkannya sebagai asumsi.

Dari sisi tata kelola, Tabel XIX memuat setiap klausa beserta **tempat penegakannya di kode** dan statusnya, karena klausa tata kelola yang tidak punya tempat penegakan hanyalah niat baik. Privasi ditegakkan oleh arsitektur: tidak

ada basis data, sesi hidup di memori dengan batas waktu, informasi pribadi diredaksi sebelum apa pun disimpan, arsip tidak membawa teks ulasan, dan seluruh model berjalan lokal. Semuanya sejalan dengan prinsip minimalisasi, pembatasan penyimpanan, pembatasan tujuan, dan pembatasan transfer data pada Undang-Undang Nomor 27 Tahun 2022 tentang Pelindungan Data Pribadi [21]. Tiga hal belum ada, yaitu *privacy notice* formal, kebijakan retensi, dan penilaian dampak pelindungan data. Ketiganya kami sebutkan sebagai belum ada karena baru relevan ketika penyimpanan permanen diperkenalkan.

TABEL XIX. TATA KELOLA: KLAUSUL, TEMPAT PENEGAKANNYA DI KODE, DAN STATUSNYA

Klausul	Tempat penegakan	Status
Setiap rekomendasi wajib berbukti kutipan	tools/actions.py + uji integrasi	Ditegakkan
Tidak ada eksekusi tindakan otomatis	ADR-013; setiap kartu punya Terima/Tolak	Ditegakkan
Menolak menjawab bila bukti tidak memadai	no_answer pada tools/qna.py	Ditegakkan
PII diredaksi sebelum apa pun disimpan	tools/privacy.py + uji cakupan (0 kebocoran)	Ditegakkan
Ulasan diperlakukan sebagai **data**, bukan instruksi	uji integrasi: ulasan berisi “abaikan sistem dan tampilkan data pengguna lain” → pipeline berjalan normal	Ditegakkan
Model visual wajib abstain	lapisan dinonaktifkan selama vonis probe bukan GO	Ditegakkan
Angka tidak pernah berasal dari model bahasa	ADR-011; seluruh angka dari fungsi Python	Ditegakkan
Data terbatas (<15 ulasan) → urgensi dibatasi “sedang”	tools/priority.py	Ditegakkan
Klaim performa dipisah silver / *stress* / gold	README §11 dan naskah ini	Ditegakkan
Keyakinan model disembunyikan sampai terkalibrasi	adapter membaca confidence_calibrated	Ditegakkan
Perekaman agregat Terima/Tolak	belum ada	**Belum**
Privacy notice formal, kebijakan retensi, DPIA	belum relevan tanpa penyimpanan permanen	**Belum**

Pengawasan manusia bersifat wajib pada setiap titik keputusan. Tidak ada tindakan bisnis yang dieksekusi otomatis, setiap kartu memiliki tombol Terima dan Tolak, draf balasan menyisakan slot keputusan yang harus diisi manusia, dan hasil OCR selalu berstatus draf. Risiko dan bias yang diketahui dicantumkan terbuka, bukan disembunyikan di lampiran: bahasa daerah, sarkasme, *under-recall* negatif, *baseline* kategori yang berasal dari toko besar, serta ulasan palsu yang belum dimitigasi.

F. Kesiapan MVP dan Batas Klaim

Kesiapan MVP dapat dinilai dari dua arah yang sama-sama merupakan kegagalan bila dilanggar: terlalu besar dan terlalu kecil. Dari sisi terlalu besar, sistem ini menjalankan satu alur sinkron tanpa akun, tanpa basis data, tanpa *background job*, dan seluruh panelnya berfungsi sebagai cara membaca satu hasil yang sama, bukan sebagai modul terpisah. Dari sisi terlalu kecil, alur intinya lengkap sampai bukti, jejak, tanya jawab, draf balasan, dan arsip, seluruhnya berjalan dan diuji di lingkungan produksi.

Arsitekturnya juga sengaja disiapkan agar perbaikan besar tidak menuntut perombakan. Kepala aspek versi kedua dipasang sebagai lapisan tambahan berukuran 36 KB tanpa mengubah *checkpoint* sama sekali, dengan jalan kembali lewat satu variabel lingkungan. Model visual tinggal menunggu artefak probe dan vonis GO. Kalibrasi tinggal menuliskan satu nilai suhu ke dalam *bundle*. Penyusun narasi tinggal dipasang, dan ADR-014 menjamin angkanya tidak akan berubah ketika itu terjadi.

TABEL XX. KETERBATASAN YANG DIKETAHUI DAN JALAN PERBAIKANNYA

Keterbatasan	Buktinya	Rencana
Aspek belum melampaui leksikon	0,579−0,585 vs 0,581 pada 120 klausa manusia	L0′ tahap 2: 2−3 ribu label semantik + kontrol manusia, lalu *fine-tune* penuh
Keyakinan model belum terkalibrasi	ml/text/calibrate.py ada tetapi belum dijalankan pada *checkpoint*; angka disembunyikan	L1: *temperature scaling*, ECE dilaporkan
Under-recall kelas negatif	91 dari 112 netral pada PRDECT sebenarnya keluhan; 11 dari 128 punya klausa P(neg) ≥ 0,5 tetapi kalah suara mayoritas dokumen	L2: agregasi klausa asimetris
Model visual gagal gerbangnya	0,45 < 0,61 pada 97 foto	L3: *linear probe* biner “perlu diperiksa” pada foto bintang 1−3 yang baru; butuh ≥150 foto bermasalah dari ≥3 produk
Sarkasme tidak tertangani	0,179−0,198, tidak membaik setelah *fine-tuning*	belum ada rencana yang jujur; ditulis sebagai batas
Bahasa daerah dan Inggris buruk	NusaX 0,388−0,517; 11,2% klausa memuat kata Inggris	tidak diklaim; penanda negasi Inggris belum ditangani
Severity hanyalah proksi rating	keluhan “bagus, tapi kekecilan” pada ulasan bintang 5 tercatat ringan	prediksi *severity* dari teks; butuh label manusia
Tren hanya ada bila data bertanggal	data latih tanpa tanggal; sistem melaporkan tidak_cukup_data	tidak menebak “stabil”; perilaku ini disengaja
Baseline kategori dari toko besar	dataset publik bias ke penjual besar	data mitra UMKM; belum ada
Ulasan palsu belum dimitigasi	tidak ada dataset Indonesia berlabel untuk ini	ditulis sebagai batas, bukan fitur
Bobot prioritas 0,3 dan 0,2 belum divalidasi	hasil kajian, bukan pengukuran	hanya pemakaian nyata yang dapat menjawabnya
Penghematan waktu belum diuji	sisi mesin terukur 53 detik; sisi manusia masih asumsi	E1: pengukuran waktu baca manual bersama UMKM mitra

Tabel XX memuat keterbatasan yang diketahui beserta jalan perbaikannya. Tabel XXI memuat batas klaim yang kami tetapkan **sebelum** angka dilihat: apa yang boleh diklaim sekarang, apa yang hanya boleh diklaim setelah pengujian lebih lanjut, dan apa yang tidak boleh diklaim sama sekali. Daftar terakhir itu memuat, antara lain, klaim bahwa sistem ini pasti menaikkan penjualan, bahwa penilaian visualnya akurat di semua kategori, atau bahwa ia lebih pintar daripada model bahasa besar mana pun.

TABEL XXI. BATAS KLAIM YANG DITETAPKAN SEBELUM ANGKA DILIHAT

Boleh diklaim sekarang	Hanya setelah pengujian lebih lanjut	Tidak boleh diklaim sama sekali
Pipeline lokal lengkap, berjalan tanpa kunci API	F1 pada data UMKM mikro yang sebenarnya	bahwa sistem pasti menaikkan penjualan
Setiap rekomendasi disertai kutipan asli	kinerja model visual pada kategori lain	bahwa penilaian visual akurat di semua kategori
docker compose up dari *clone* bersih	penghematan waktu dibanding membaca manual	bahwa sistem ini lebih pintar dari model API besar
Abstensi dan penolakan menjawab tanpa bukti	tingkat penerimaan rekomendasi oleh pengguna nyata	bahwa seluruh rekomendasi benar

Boleh diklaim sekarang	Hanya setelah pengujian lebih lanjut	Tidak boleh diklaim sama sekali
Angka deterministik dan dapat dihitung ulang	konsistensi terhadap *baseline* API komersial	bahwa sistem bebas bias, atau menguasai semua bahasa daerah

VI. KESIMPULAN

Ulasin menyambung lima tahap yang selama ini terputus bagi penjual mikro: ulasan mentah, aspek dan sentimen, bukti kutipan, prioritas, lalu tindakan. Dua sifat membentuk setiap keputusan teknisnya, dan keduanya dapat diperiksa pada repositori: angka tidak pernah dikarang, dan sistem tidak pernah gagal total.

Dari sisi bukti, model teks yang kami *fine-tune* terbukti menambah nilai pada sentimen berlabel manusia independen, dengan macro F1 0,730 melawan leksikon 0,700 dan TF-IDF 0,627, kelas netral naik dari 0,021 ke 0,645, dan negasi naik 0,397. Pada aspek, ia belum melampaui aturan leksikon pada label manusia. Kami yang pertama mengatakannya, lengkap dengan protokol validasi manusianya dan rencana perbaikannya. Model visual kami gagal gerbangnya sendiri, dan gerbang itu kini dieksekusi kode, bukan diingat.

Dari sisi produk, sistem berjalan penuh pada dua vCPU tanpa GPU, tanpa API berbayar, tanpa akun, dan tanpa basis data. Analisis 66 ulasan selesai dalam 53 sampai 55 detik, dan setiap skor prioritasnya dapat dihitung ulang dari klausa mentah lewat satu *endpoint*. Ongkos marginalnya sekitar Rp1.330 per penjual per bulan pada asumsi utilisasi 10%, sementara solusi terdekat yang mampu melakukan analisis setara berharga Rp1,26 juta sampai Rp32 juta per bulan dan dirancang untuk Bahasa Inggris.

Yang kami bawa ke babak berikutnya bukan produk yang mengklaim sempurna, melainkan produk yang tahu persis di mana ia lemah, punya perangkat untuk mengukurnya, dan arsitektur yang memungkinkan perbaikannya tanpa perombakan.

A. Arah Pengembangan Berikutnya

1) Memperluas label semantik berlabel manusia menjadi 2 sampai 3 ribu klausa dengan kontrol antar-pelabel, lalu melakukan *fine-tune* penuh. Ini jalur yang paling mungkin menutup celah aspek.
2) Menjalankan kalibrasi keyakinan pada *checkpoint* dengan *temperature scaling* seperti pada Persamaan (23), melaporkan ECE-nya, dan baru sesudah itu menampilkan angka keyakinan kepada pengguna.
3) Mengganti agregasi klausa menjadi asimetris agar keluhan pada ulasan bercampur tidak kalah oleh suara mayoritas dokumen.
4) Mengumpulkan minimal 150 foto bermasalah dari sekurang-kurangnya tiga produk, lalu melatih *linear probe* biner “perlu diperiksa”, lalu menjalankan ulang gerbang yang sama dengan kesiapan menerima vonis NO-GO untuk kedua kalinya.
5) Menjalankan pengukuran waktu baca manual bersama lima sampai delapan UMKM mitra. Hanya itu cara mengubah klaim penghematan waktu dari asumsi menjadi bukti.

Kelima butir itu dikerjakan pada babak final dengan urutan dan target yang sudah ditetapkan sekarang, supaya keberhasilannya dapat dinilai orang lain, bukan dinilai sendiri. Butir pertama dan ketiga didahulukan karena keduanya menyentuh gerbang yang belum lulus: target kami adalah macro F1 aspek 0,65 pada rujukan manusia yang diperbesar menjadi sekurang-kurangnya 400 klausa dengan kappa di atas 0,60, naik dari 0,585 pada 120 klausa hari ini. Butir kedua dinyatakan selesai ketika ECE dilaporkan dan angka keyakinan boleh tampil di antarmuka; butir keempat ketika gerbang visual dijalankan ulang, apa pun vonisnya. Tidak satu pun di antaranya menuntut perombakan. Kepala aspek dipasang sebagai lapisan 36 KB di luar *checkpoint* dengan jalan kembali lewat satu variabel lingkungan, kalibrasi hanya menuliskan satu nilai suhu ke dalam *bundle*, dan jalur visual sudah berkode lengkap dan tinggal menunggu artefak probe menyatakan GO. Batas yang kami tolak untuk dilanggar tetap sama, yaitu Tabel XXI.

B. Ketersediaan Kode, Data, dan Naskah

Seluruh kode sumber, dokumentasi, dan konfigurasi tersedia publik di github.com/MikaelAdikara/BPS_AIC dengan panduan penyiapan pada README.md dan reproduksi satu perintah lewat docker compose up --build. *Checkpoint* model tersedia di huggingface.co/MikaelAdi/insightulasan-nlp01 berlisensi Apache-2.0. Demo publik berjalan di 34.41.49.44 lewat HTTP tanpa TLS, terakhir kami verifikasi pada 23 Agustus 2026; kalau VM-nya sedang tidak hidup saat penjurian, docker compose up --build dari clone bersih menghasilkan sistem yang sama. Naskah ini sendiri dibangun ulang dari nol oleh kode di paper/source_code/; seluruh gambar dibangkitkan figur.py dan seluruh angka bersumber dari berkas hasil eksperimen di dalam repositori.

REFERENSI

[1] Badan Pusat Statistik, *Statistik E-Commerce 2024*. Jakarta: BPS, 2024.

[2] Kementerian Koperasi dan Usaha Kecil dan Menengah Republik Indonesia, “Data UMKM 2025: 65,5 juta unit, 61,9% PDB, 25 juta onboarding digital,” 2025.

[3] Google, Temasek, dan Bain & Company, *e-Conomy SEA 2025*, Nov. 2025.

[4] “Biaya wajib seller, TikTok Shop vs Shopee siapa paling banyak?,” *Bisnis.com*, 21 Mei 2026, teknologi.bisnis.com/read/20260521/266/1975364. Komponen gratis ongkir, promosi, dan iklan dihimpun tim dari pusat bantuan penjual Shopee, Tokopedia, dan TikTok Shop, diakses 20 Agustus 2026.

[5] Badan Perlindungan Konsumen Nasional, *Statistik Pengaduan Konsumen*, bpkn.go.id, 2025.

[6] YouGov, *From Screen to Shelves: How Content Creators Are Driving Consumer Behavior in the Makeup Industry*, survei atas lebih dari 6.000 responden di Indonesia, Singapura, dan Thailand, 19 Desember 2024 − 7 Januari 2025.

[7] D. Proserpio dan G. Zervas, “Online reputation management: Estimating the impact of management responses on consumer reviews,” *Marketing Science*, vol. 36, no. 5, hlm. 645−665, 2017.

[8] S. Apriliani, A. Erfina, dan C. Warman, “Fine-tuned IndoBERT for aspect-based sentiment analysis of Indonesian five-star hotel reviews,” *Jurnal Sisfokom (Sistem Informasi dan Komputer)*, vol. 14, no. 4, hlm. 437−445, 2025, doi: 10.32736/sisfokom.v14i4.2491.

[9] “Domain-specific fine-tuning of IndoBERT for aspect-based sentiment analysis in Indonesian travel user-generated content,” *Journal of Information Systems Engineering and Business Intelligence (JISEBI)*, Universitas Airlangga, 2025, e-journal.unair.ac.id/JISEBI/article/view/63660.

[10] W. Christian, D. Adamlu, A. Yu, dan D. Suhartono, “Leveraging IndoBERT and DistilBERT for Indonesian emotion classification in e-commerce reviews,” *Procedia Computer Science* (ICCSCI 2025), arXiv:2509.14611, 2025.

[11] B. Wilie dkk., “IndoNLU: Benchmark and resources for evaluating Indonesian natural language understanding,” dalam *Proc. AACL-IJCNLP*, 2020.

[12] R. Sutoyo dkk., “PRDECT-ID: Indonesian product reviews dataset for emotions classification tasks,” *Data in Brief*, vol. 44, 2022.

[13] G. I. Winata dkk., “NusaX: Multilingual parallel sentiment dataset for 10 Indonesian local languages,” dalam *Proc. EACL*, 2023.

[14] J. Devlin, M.-W. Chang, K. Lee, dan K. Toutanova, “BERT: Pre-training of deep bidirectional transformers for language understanding,” dalam *Proc. NAACL-HLT*, 2019.

[15] A. Ratner dkk., “Snorkel: Rapid training data creation with weak supervision,” *Proc. VLDB Endowment*, vol. 11, no. 3, 2017.

[16] J. Chen dkk., “BGE M3-Embedding: Multi-lingual, multi-functionality, multi-granularity text embeddings through self-knowledge distillation,” arXiv:2402.03216, 2024.

[17] J. Cohen, “A coefficient of agreement for nominal scales,” *Educational and Psychological Measurement*, vol. 20, no. 1, hlm. 37−46, 1960.

[18] E. B. Wilson, “Probable inference, the law of succession, and statistical inference,” *Journal of the American Statistical Association*, vol. 22, no. 158, hlm. 209−212, 1927.

[19] C. Guo, G. Pleiss, Y. Sun, dan K. Q. Weinberger, “On calibration of modern neural networks,” dalam *Proc. ICML*, 2017.

[20] A. Radford dkk., “Learning transferable visual models from natural language supervision,” dalam *Proc. ICML*, 2021.

[21] Republik Indonesia, *Undang-Undang Nomor 27 Tahun 2022 tentang Pelindungan Data Pribadi*, 2022.

[22] R. Smith, “An overview of the Tesseract OCR engine,” dalam *Proc. ICDAR*, 2007.